

«Московский физико-технический институт»
Физтех-школа радиотехники и компьютерных технологий

Конспект лекций по теории массового обслуживания

Лектор:

Буртаков И.А.

Верстка:

Лепин В.Д.



г. Долгопрудный, 2026

Оглавление

1	Лекция 1: Математические основы непрерывных цепей Маркова	5
1.1	Непрерывные цепи Маркова	5
1.1.1	Основные понятия	5
1.1.2	Допущение о регулярности траекторий	6
1.1.3	Непрерывность переходных вероятностей в нуле	6
1.1.4	Непрерывность на всей временной оси	9
1.1.5	Дифференцируемость переходных вероятностей и матрица интенсивностей	10
1.1.6	Дифференциальные уравнения Колмогорова — Феллера	11
1.1.7	Вероятностный смысл элементов матрицы интенсивностей	12
1.1.8	Время пребывания в состоянии и смысл величины q_{ii}	13
2	Лекция 2. Эргодические цепи Маркова и потоки событий	17
2.1	Вероятностный смысл элементов матрицы интенсивностей и механика скачков	17
2.2	Эргодические непрерывные цепи Маркова	18
2.2.1	Классификация состояний и их свойства	19
2.2.2	Эргодические теоремы	20
2.3	Примеры решения задач	21
2.4	Потоки событий	24
2.4.1	Марковская природа потоков без последствия	25
2.4.2	Интенсивности переходов в потоке без последствия	25
2.4.3	Ординарность и эквивалентные определения пуассоновского процесса	27
3	Лекция 3. Введение в СМО, нотация Кендалла, формула Литтла	29
3.1	Примеры простейших систем массового обслуживания	29
3.2	Классификация систем массового обслуживания и нотация Кендалла	34
3.3	Формула Литтла	35

4	Лекция 4. Свойство PASTA и система $M M 1$	39
4.1	Применение формулы Литтла и соотношения в системах $G/G/c$	39
4.1.1	Фундаментальные соотношения для систем $G/G/c$	40
4.2	Напоминание: Пуассоновский процесс и порядковые статистики	42
4.3	Связь пуассоновского потока и равномерного распределения	44
4.3.1	Интерпретация	45
4.4	Свойство PASTA	46
4.5	Система $M M 1$	46
5	Лекция 5. Системы $M M 1$ и $M M c$	49
5.1	Характеристики эффективности системы $M M 1$	49
5.2	Многоканальная система обслуживания $M M c$	53
5.3	Оптимальный выбор числа каналов и режимы масштабирования	60
6	Лекция 6. Системы $M M c K$ и $M G 1$	63
6.1	Система массового обслуживания $M M c K$	63
6.1.1	Распределение состояний в моменты поступления заявок	67
6.1.2	Системы с отказами ($M M c c$) и формула Эрланга	69
6.2	Система массового обслуживания $M G 1$ и формула Полячека — Хинчина	71
7	Лекция 7. Система $M^{[X]} M 1$	79
8	Лекция 8. Система $M Er_k 1$. Протоколы множественного доступа	85
8.1	Системы с фазовым обслуживанием. Модель $M Er_k 1$	85
8.2	Протоколы множественного доступа. Алгоритмы ALOHA	88
8.2.1	Асинхронная ALOHA	89
8.2.2	Синхронная (слотированная) ALOHA при бесконечном числе устройств	91
8.2.3	Синхронная ALOHA при конечном числе устройств	92
9	Лекция 9. Древовидные стек-алгоритмы и введение в CSMA	95
9.1	Стек-алгоритмы	95
9.2	Протоколы с прослушиванием несущей (CSMA)	98

9.2.1	Ненастойчивый протокол CSMA (Non-persistent CSMA)	102
9.2.2	1-настойчивый протокол CSMA (1-persistent CSMA)	105
9.3	Анализ протоколов CSMA при разной топологии сети	108
9.4	Анализ средней задержки передачи	111
10	Лекция 10. Новый взгляд на цепи Маркова: полугруппы и генераторы	113
10.1	Полугруппы операторов и инфинитезимальные генераторы	113

Глава 1

Лекция 1: Математические основы непрерывных цепей Маркова

1.1 Непрерывные цепи Маркова

В данном разделе мы переходим к изучению марковских процессов с дискретным множеством состояний $S \subseteq \mathbb{Z}$, но протекающих в непрерывном времени $T = [0, +\infty)$. Переход к непрерывному времени требует уточнения как самого определения процесса, так и свойств его траекторий.

1.1.1 Основные понятия

Марковская цепь с непрерывным временем

Случайный процесс $\{X(t), t \geq 0\}$ называется *марковской цепью с непрерывным временем*, если для любых моментов времени $t_0 < t_1 < \dots < t_n < t$ и любых состояний $x_0, x_1, \dots, x_n, j \in S$ выполняется условие:

$$\mathbb{P}(X(t) = j \mid X(t_n) = x_n, \dots, X(t_0) = x_0) = \mathbb{P}(X(t) = j \mid X(t_n) = x_n).$$

Иными словами, будущее состояние процесса зависит от прошлого только через настоящее состояние.

Основной характеристикой цепи являются вероятности перехода за время от s до t ($s \leq t$):

$$p_{ij}(s, t) \doteq \mathbb{P}(X(t) = j \mid X(s) = i).$$

Эти вероятности обладают следующими естественными свойствами:

1. $0 \leq p_{ij}(s, t) \leq 1$ для любых i, j, s, t .
2. $\sum_{j \in S} p_{ij}(s, t) = 1$ (условие нормировки: из состояния i за время $t - s$ процесс обязательно перейдет в какое-то состояние $j \in S$).
3. $p_{ii}(t, t) = 1$ и $p_{ij}(t, t) = 0$ при $i \neq j$ (в фиксированный момент времени состояние не меняется).

Матрица, составленная из этих вероятностей, называется *матрицей перехода*:

$$P(s, t) \doteq \|p_{ij}(s, t)\|_{i, j \in S}.$$

Теорема. Уравнение Колмогорова — Чепмена

Для любых моментов времени $t_1 \leq t \leq t_2$ матрица перехода удовлетворяет следующему соотношению:

$$P(t_1, t_2) = P(t_1, t) \cdot P(t, t_2).$$

Пусть $\pi_i(t) \doteq \mathbb{P}(X(t) = i)$ — вероятность того, что в момент времени t цепь находится в состоянии i . Тогда $\pi(t) = (\pi_0(t), \pi_1(t), \dots)^T$ эволюционирует согласно матричному уравнению:

$$\pi(t) = P^T(s, t) \cdot \pi(s), \quad s \leq t.$$

Здесь мы используем транспонированную матрицу, так как работаем с вектором-столбцом распределения вероятностей.

Цепь называется *однородной*, если вероятности перехода зависят только от длины интервала времени $\Delta t = t - s$. В этом случае:

$$P(s, s + t) = P(0, t) \equiv P(t).$$

Уравнение Колмогорова — Чепмена для однородных цепей принимает вид $P(t + s) = P(t) \cdot P(s)$.

1.1.2 Допущение о регулярности траекторий

Для построения математически строгой теории необходимо определить, в каком классе функций мы рассматриваем реализации случайного процесса $X(t)$. Возникает вопрос: любые ли траектории подходят для описания эволюции матрицы перехода $P(t)$?

Если не накладывать ограничений на свойства траекторий, возможны «патологические» случаи. Например, может возникнуть ситуация, когда в любой окрестности момента скачка происходит бесконечное число переходов за конечное время (эффект «взрыва»). Чтобы исключить подобные сценарии и обеспечить дифференцируемость вероятностных характеристик, мы вводим следующее фундаментальное допущение.

! Замечание !

Мы будем рассматривать только такие марковские цепи, траектории которых **почти наверное** являются **непрерывными справа** функциями времени.

Это условие означает, что после совершения любого скачка цепь обязательно остается в новом состоянии в течение некоторого положительного времени $\Delta t > 0$. Визуально такие траектории представляют собой ступенчатые функции, значения которых в точках разрыва совпадают с пределом справа (см. рис. 1.1).

1.1.3 Непрерывность переходных вероятностей в нуле

Выбранный класс траекторий позволяет гарантировать «хорошее» поведение переходных вероятностей при малых приращениях времени.




Рис. 1.1: Типичная траектория непрерывной цепи Маркова со ступенчатой структурой и непрерывностью справа.

Теорема 1. О непрерывности матрицы перехода в нуле

Пусть $\{X(t), t \geq 0\}$ — однородная марковская цепь с непрерывными справа траекториями. Тогда матрица перехода $P(t)$ непрерывна в нуле справа:

$$\lim_{t \rightarrow 0+0} P(t) = I,$$

что для элементов матрицы означает:

$$\lim_{t \rightarrow 0+0} p_{ii}(t) = 1, \quad \lim_{t \rightarrow 0+0} p_{ij}(t) = 0 \text{ при } i \neq j.$$

Доказательство. Рассмотрим произвольное состояние $i \in S$, для которого $\mathbb{P}(X(t) = i) > 0$. По определению условной вероятности имеем:

$$p_{ii}(t, t) = \mathbb{P}(X(t) = i \mid X(t) = i) = 1.$$

Перепишем это равенство через пространство элементарных исходов Ω :

$$\mathbb{P}(\{\omega \in \Omega : X(\omega, t) = i\} \mid X(t) = i) = 1.$$

Для дальнейшего доказательства введем определение непрерывности справа для процессов с дискретным пространством состояний. Траектория $X(\omega, t)$ называется непрерывной справа в точке t , если для данного исхода ω существует такое $\delta(\omega) > 0$, что для любого $\tau \in [t, t + \delta(\omega))$ выполняется равенство $X(\omega, \tau) = X(\omega, t)$. Это означает, что на некотором малом интервале времени справа состояние процесса остается неизменным.

Пусть $E \subset \Omega$ — подмножество исходов, для которых траектории непрерывны справа. По условию $\mathbb{P}(E) = 1$, следовательно, вероятность дополнения равна нулю: $\mathbb{P}(\Omega \setminus E) = 0$. Представим исходное событие $\{\omega \in \Omega : X(\omega, t) = i\}$ как объединение двух непересекающихся множеств, принадлежащих E и $\Omega \setminus E$

соответственно:

$$\{\omega \in \Omega : X(\omega, t) = i\} = \{\omega \in E : X(\omega, t) = i\} \cup \{\omega \in \Omega \setminus E : X(\omega, t) = i\}.$$

В силу аддитивности вероятности и того факта, что $\mathbb{P}(\Omega \setminus E) = 0$, вероятность второго слагаемого зануляется:

$$\mathbb{P}(\{\omega \in \Omega \setminus E : X(\omega, t) = i\} \mid X(t) = i) \leq \frac{\mathbb{P}(\Omega \setminus E)}{\mathbb{P}(X(t) = i)} = 0.$$

Таким образом, полная мера сосредоточена на множестве регулярных исходов E .

Рассмотрим последовательность моментов времени $\{t_n\}$, стремящуюся к t сверху ($t_n \rightarrow t+0$). Согласно определению непрерывности справа, для каждого $\omega \in E$, если система находится в состоянии i в момент t , то она обязательно будет находиться в нем во все моменты t_k при достаточно больших k . Формально это записывается через предел вложенных множеств:

$$\{\omega \in E : X(\omega, t) = i\} = \bigcup_{n=1}^{\infty} \bigcap_{k \geq n} \{\omega \in E : X(\omega, t_k) = i\}.$$

События $B_n = \bigcap_{k \geq n} \{\omega \in E : X(\omega, t_k) = i\}$ являются монотонно растущими по n ($B_n \subset B_{n+1}$). Воспользуемся свойством непрерывности вероятностной меры:

$$1 = \mathbb{P} \left(\bigcup_{n=1}^{\infty} B_n \mid X(t) = i \right) = \lim_{n \rightarrow \infty} \mathbb{P} \left(\bigcap_{k \geq n} \{X(\omega, t_k) = i\} \mid X(t) = i \right).$$

Заметим, что для любого фиксированного n выполняется включение $B_n \subseteq \{X(\omega, t_n) = i\}$. Следовательно, для вероятностей справедливо неравенство:

$$\mathbb{P}(B_n \mid X(t) = i) \leq \mathbb{P}(X(t_n) = i \mid X(t) = i) = p_{ii}(t, t_n).$$

Переходя к пределу при $n \rightarrow \infty$ и учитывая, что любая вероятность не превосходит единицу, получаем:

$$1 \leq \lim_{n \rightarrow \infty} p_{ii}(t, t_n) \leq 1 \implies \lim_{n \rightarrow \infty} p_{ii}(t, t_n) = 1.$$

В силу произвольности последовательности $\{t_n\}$ и однородности цепи имеем $\lim_{t \rightarrow 0+0} p_{ii}(t) = 1$.

Теперь оценим внедиагональные элементы $p_{ij}(t)$ при $i \neq j$. Из условия нормировки суммы вероятностей в строке матрицы перехода следует:

$$\sum_{k \in S} p_{ik}(t) = p_{ii}(t) + \sum_{j \neq i} p_{ij}(t) = 1.$$

Для любого конкретного $j \neq i$ справедливо:

$$0 \leq p_{ij}(t) \leq \sum_{k \neq i} p_{ik}(t) = 1 - p_{ii}(t).$$

Так как $\lim_{t \rightarrow 0+0} (1 - p_{ii}(t)) = 0$, то по теореме о зажатой функции получаем:

$$\lim_{t \rightarrow 0+0} p_{ij}(t) = 0 \quad \forall i \neq j.$$

Таким образом, предел матрицы перехода при стремлении времени к нулю равен единичной матрице: $\lim_{t \rightarrow 0+0} P(t) = I$.

На основе полученных свойств мы можем дать классификацию рассматриваемых процессов.

Стандартная стохастическая полугруппа

Семейство матриц $\{P(t)\}_{t \geq 0}$ называется *стандартной стохастической полугруппой*, если выполняются следующие условия:

1. $P(0) = I$;
2. $P(t + s) = P(t) \cdot P(s)$ для всех $t, s \geq 0$ (полугрупповое свойство);
3. $\lim_{t \rightarrow 0+0} P(t) = I$ (условие стандартности).

Стандартная марковская цепь

Марковская цепь, матрица перехода которой образует стандартную стохастическую полугруппу, называется *стандартной*.

1.1.4 Непрерывность на всей временной оси

Установив поведение матрицы перехода в нуле, мы можем показать, что свойство непрерывности характерно для стандартной цепи Маркова в любой момент времени $t \geq 0$.

Теорема 2. О непрерывности матрицы перехода

Матрица перехода $P(t)$ конечной стандартной цепи Маркова непрерывна для любого момента времени $t \in T$.

Доказательство. Согласно условию стандартности, при стремлении приращения времени к нулю матрица перехода стремится к единичной: $\lim_{h \rightarrow 0+0} P(h) = I$. Поскольку предел матрицы равен I , существует такая малая правая окрестность нуля, в которой определитель $\det P(h)$ отличен от нуля. Это гарантирует **обратимость** матрицы $P(h)$ при достаточно малых $h > 0$. Можно также показать, что для обратной матрицы выполняется аналогичное предельное соотношение:

$$\lim_{h \rightarrow 0+0} P^{-1}(h) = I.$$

Непрерывность справа. Рассмотрим поведение функции в произвольной точке t при положительном приращении h . Воспользуемся полугрупповым свойством $P(t + h) = P(t) \cdot P(h)$. Переходя к пределу, получаем:

$$\lim_{h \rightarrow 0+0} P(t + h) = P(t) \cdot \lim_{h \rightarrow 0+0} P(h) = P(t) \cdot I = P(t).$$

Это подтверждает непрерывность матрицы перехода справа.

Непрерывность слева. Для проверки предела слева рассмотрим значение матрицы в точке $t - h$. Согласно полугрупповому свойству, справедливо равенство $P(t) = P(t - h) \cdot P(h)$. Отсюда выразим

искомую матрицу через обратную:

$$P(t - h) = P(t) \cdot P^{-1}(h).$$

Устремляя h к нулю и учитывая доказанное выше свойство обратной матрицы, находим:

$$\lim_{h \rightarrow 0+0} P(t - h) = P(t) \cdot \lim_{h \rightarrow 0+0} P^{-1}(h) = P(t) \cdot I = P(t).$$

Таким образом, совпадение односторонних пределов со значением $P(t)$ доказывает непрерывность матрицы перехода в любой точке $t \in T$. ■

1.1.5 Дифференцируемость переходных вероятностей и матрица интенсивностей

Установленное ранее свойство глобальной непрерывности позволяет наложить более строгие аналитические условия на поведение матрицы перехода, что необходимо для вывода уравнений эволюции процесса в дифференциальной форме.

Теорема 3. О дифференцируемости матрицы перехода

При соблюдении тех же условий регулярности, что и в теореме 2, матрица перехода $P(t)$ является дифференцируемой для любого момента времени $t \in T$. Более того, матрица $P(t)$ является дифференцируемой справа в точке $t = 0$ даже для случая цепей со счетным множеством состояний, если допустить, что значения производных диагональных элементов $p_{ii}(t)$ могут быть равны $-\infty$.

Наличие производной в нуле позволяет ввести фундаментальную характеристику непрерывной цепи Маркова — матрицу интенсивностей переходов (инфинитезимальный генератор).

Теорема 4. О существовании инфинитезимальной матрицы

Для матрицы перехода $P(t)$ стандартной цепи Маркова существует предел при $h \rightarrow 0 + 0$:

$$\exists Q \doteq \lim_{h \rightarrow 0+0} \frac{P(h) - I}{h},$$

где $Q = \|q_{ij}\|$ — матрица интенсивностей. Элементы данной матрицы обладают следующими свойствами:

1. Все внедиагональные элементы конечны и неотрицательны: $0 \leq q_{ij} < \infty$ при $i \neq j$.
2. Диагональные элементы определяются как $q_{ii} \doteq -q_i$, где q_i — интенсивность выхода из состояния i , при этом $q_i \in [0, +\infty]$.

! Замечание !

В случае конечного числа состояний интенсивность выхода $q_i = \sum_{j \neq i} q_{ij}$ всегда конечна как сумма конечного числа слагаемых. Однако в цепях со счетным множеством состояний, несмотря на конечность каждой отдельной интенсивности перехода ($q_{ij} < \infty$), их бесконечная сумма может расходиться, что приводит к ситуации $q_i = \infty$.

Для корректного суммирования по строкам и анализа устойчивости процесса вводится следующее понятие.

Консервативная цепь Маркова

Цепь Маркова называется *консервативной*, если для всех её состояний интенсивность выхода конечна ($q_i < \infty$) и сумма интенсивностей в каждой строке матрицы Q равна нулю:

$$\sum_{j \in S} q_{ij} = 0, \quad \forall i \in S.$$

Заметим, что любая цепь с конечным числом состояний всегда является консервативной. Для счетных же цепей консервативность является дополнительным условием, гарантирующим, что за конечное время не произойдет «ухода» процесса в бесконечность.

1.1.6 Дифференциальные уравнения Колмогорова — Феллера

В теории однородных дискретных цепей Маркова динамика системы описывалась матрицей перехода за один шаг. В случае же конечных однородных стандартных цепей Маркова с непрерывными справа траекториями динамика матрицы перехода полностью определяется её поведением в нуле, то есть матрицей интенсивностей Q .

Теорема 5. Уравнения Колмогорова

Пусть $P(t)$ - матрица перехода конечной стандартной цепи Маркова. Тогда она удовлетворяет следующей системе дифференциальных уравнений:

$$\dot{P}(t) = P(t) \cdot Q, \quad P(0) = I \quad (\text{прямое уравнение}),$$

$$\dot{P}(t) = Q \cdot P(t), \quad P(0) = I \quad (\text{обратное уравнение}).$$

Данные уравнения имеют единственное решение, выражающееся через матричную экспоненту:

$$P(t) = \exp(Q \cdot t).$$

Доказательство. Согласно определению матрицы интенсивностей, предел разностного отношения в нуле равен $Q = \lim_{h \rightarrow 0+0} \frac{P(h) - I}{h}$. Воспользуемся полугрупповым свойством матрицы перехода $P(t+h) = P(t) \cdot P(h) = P(h) \cdot P(t)$

Для вывода **прямого уравнения** рассмотрим приращение матрицы перехода справа:

$$\frac{P(t+h) - P(t)}{h} = \frac{P(t) \cdot P(h) - P(t)}{h} = P(t) \cdot \frac{P(h) - I}{h}.$$

Переходя к пределу при $h \rightarrow 0+0$, в правой части получаем произведение $P(t) \cdot Q$. Таким образом, $\dot{P}(t) = P(t) \cdot Q$.

Для вывода **обратного уравнения** воспользуемся коммутативностью матриц в полугрупповом свойстве:

$$\frac{P(t+h) - P(t)}{h} = \frac{P(h) \cdot P(t) - P(t)}{h} = \frac{P(h) - I}{h} \cdot P(t).$$

Аналогично, при $h \rightarrow 0 + 0$ предел левой части дает производную $\dot{P}(t)$, а правая часть стремится к $Q \cdot P(t)$. С учетом начального условия $P(0) = I$, решение данной системы в теории матричных функций представляется как $P(t) = e^{Qt}$. ■

! Замечание !

Стоит учитывать, что в случае цепей со счетным числом состояний «зеркальность» уравнений Колмогорова может нарушаться. Обратное уравнение обычно сохраняется в исходном виде, в то время как для справедливости прямого уравнения требуется дополнительное условие равномерной сходимости разностного отношения $\frac{P(h)-I}{h}$ к матрице Q по строкам

1.1.7 Вероятностный смысл элементов матрицы интенсивностей

Ранее было показано, что динамика матрицы перехода полностью определяется матрицей Q . Теперь рассмотрим, как эволюционирует вектор распределения вероятностей состояний $\pi(t) = (\pi_0(t), \pi_1(t), \dots)^T$. Из матричного уравнения эволюции $\pi(t+h) = P^T(h) \cdot \pi(t)$ и свойств дифференцируемости, установленных в предыдущих теоремах, при $h \rightarrow 0$ мы получаем систему дифференциальных уравнений:

$$\dot{\pi}(t) = Q^T \cdot \pi(t)$$

с начальным условием $\pi(0) = \pi_0$. Таким образом, все переходные вероятности и распределения в любой момент времени однозначно определяются матрицей Q , которая не зависит от времени t .

Матрица интенсивностей

Матрица Q , называемая также *матрицей интенсивностей* или *инфинитезимальным генератором*, состоит из элементов, которые определяются как пределы переходных вероятностей при стремлении временного интервала к нулю:

$$q_{ii} \doteq \lim_{h \rightarrow 0+0} \frac{p_{ii}(h) - 1}{h}, \quad q_{ij} \doteq \lim_{h \rightarrow 0+0} \frac{p_{ij}(h)}{h} \quad \text{при } i \neq j.$$

Данные предельные соотношения позволяют записать асимптотическое разложение переходных вероятностей для малых промежутков времени h :

$$p_{ii}(h) = 1 + q_{ii} \cdot h + o(h), \quad p_{ij}(h) = q_{ij} \cdot h + o(h) \quad \text{при } i \neq j.$$

Хотя эти формулы представляют собой лишь линейную аппроксимацию (разложение первого порядка по h), они полностью и однозначно определяют поведение цепи на любом конечном интервале времени через матричную экспоненту $P(t) = e^{Qt}$.

▽ **Утв.** Для любого $i \neq j$ число q_{ij} называется *интенсивностью перехода* из состояния i в состояние j . Это значение характеризует мгновенную скорость, с которой процесс покидает текущее состояние в пользу другого.

Воспользуемся условием нормировки суммы переходных вероятностей $\sum_{j \in S} p_{ij}(h) = 1$ для вывода связи между диагональными и внедиагональными элементами. Подставляя асимптотические разложения, получаем:

$$(1 + q_{ii} \cdot h + o(h)) + \sum_{j \neq i} (q_{ij} \cdot h + o(h)) = 1.$$

Сокращая единицу и деля на h при $h \rightarrow 0$, приходим к равенству, которое, впрочем, нам уже знакомо:

$$q_{ii} + \sum_{j \neq i} q_{ij} = 0 \implies \sum_{j \neq i} q_{ij} = -q_{ii}.$$

! Замечание !

Величину $q_i \doteq -q_{ii}$ называют *интенсивностью выхода* из состояния i . Она суммирует интенсивности всех возможных способов покинуть данное состояние. Таким образом, в консервативной цепи интенсивность выхода в точности равна сумме интенсивностей переходов во все остальные возможные состояния.

1.1.8 Время пребывания в состоянии и смысл величины q_{ii}

Рассмотрим консервативную марковскую цепь $\{X(t), t \geq 0\}$ с непрерывными справа траекториями и конечным или счётным числом состояний. Нам необходимо выяснить, как долго процесс задерживается в выбранном состоянии i до того, как совершит первый скачок в любое другое состояние.

Время пребывания в состоянии

Для любого состояния $i \in S$ определим величину $\tau_i(\omega)$ как *время пребывания в состоянии i* при условии, что в начальный момент времени процесс находился в этом состоянии ($X(0) = i$):

$$\tau_i(\omega) \doteq \inf\{t > 0 : X(\omega, t) \neq i \mid X(0) = i\}.$$

Наша цель — найти функцию распределения этой случайной величины, в частности, вероятность $\mathbb{P}(\tau_i > t)$.

Проблема измеримости и переход к счётным множествам

При вычислении инфимума по несчётному множеству времени $T = [0, +\infty)$ возникают технические сложности с доказательством того, что τ_i действительно является случайной величиной. В несчётном случае пересечение событий $\bigcap_{t \in [0, \tau]} \{X(t) = i\}$ может не принадлежать σ -алгебре событий $\mathcal{F}$.

Для обхода этой проблемы введём произвольное счётное всюду плотное в T множество D . Положим:

$$\tau_i^D(\omega) \doteq \inf\{t \in D : X(\omega, t) \neq i \mid X(0) = i\}.$$




Рис. 1.2: Визуализация времени пребывания τ_i в состоянии i до момента первого скачка.

Утв. В силу предположения о непрерывности траекторий справа, почти наверное (п.н.) выполняется равенство:

$$\tau_i(\omega) = \tau_i^D(\omega).$$

Доказательство. Поскольку инфимум по подмножеству всегда не меньше инфимума по всему множеству, очевидно, что $\tau_i(\omega) \leq \tau_i^D(\omega)$. Если $\tau_i(\omega) = \infty$, равенство тривиально.

В обратную сторону: так как D всюду плотно в T , то существует последовательность $\{t_n\} \subset D$, такая что $t_n \rightarrow \tau_i(\omega) + 0$ (справа). В силу непрерывности траекторий справа, если процесс покинул состояние i в момент τ_i , то в достаточно малой окрестности справа он также будет находиться в состоянии $j \neq i$. Следовательно, для достаточно больших n выполняется $X(t_n) \neq i$, что влечёт $\tau_i^D(\omega) \leq t_n$. Переходя к пределу, получаем $\tau_i^D(\omega) \leq \tau_i(\omega)$. Таким образом, $\tau_i^D = \tau_i$ почти наверное. ■

! Замечание !

Введение счётного множества D позволяет строго обосновать, что τ_i^D является случайной величиной. Действительно, событие $\{\omega : \tau_i^D(\omega) > t\}$ можно представить как счётное пересечение измеримых событий:

$$\{\omega : \tau_i^D(\omega) > t\} = \bigcap_{d \in D \cap [0, t]} \{\omega : X(\omega, d) = i\}.$$

Поскольку каждое событие $\{X(\omega, d) = i\}$ принадлежит σ -алгебре $\mathcal{F}$, их счётное пересечение также принадлежит $\mathcal{F}$, что гарантирует измеримость τ_i^D .

Вывод распределения времени пребывания


Для явного нахождения распределения величины τ_i воспользуемся конструкцией всюду плотного множества на отрезке $[0, t]$, основанной на двоично-рациональных точках (сетке Дирихле).

Рассмотрим на произвольном фиксированном интервале $[0, t]$ последовательность вложенных множеств D_n :

$$D_n \doteq \left\{ \frac{jt}{2^n} \right\}_{j=0}^{2^n} = \left\{ 0, \frac{t}{2^n}, \frac{2t}{2^n}, \dots, t \right\}.$$

Легко заметить, что $D_n \subset D_{n+1}$, так как при увеличении n на единицу в сетку добавляются середины предыдущих интервалов. Объединение всех таких сеток образует счетное всюду плотное множество на $[0, t]$:

$$D(t) \doteq \bigcup_{n=0}^{\infty} D_n.$$



Для того чтобы получить счетное всюду плотное множество D на всей полупрямой $[0, +\infty)$, достаточно рассмотреть объединение таких множеств для расширяющихся интервалов, например: $D \doteq \bigcup_{N \in \mathbb{N} \cup \{0\}} D(t \cdot 2^N)$.

Теорема. О распределении времени пребывания

Пусть $\{X(t), t \geq 0\}$ — однородная стандартная цепь Маркова с интенсивностью выхода $q_i \in [0, +\infty)$ из состояния i . Тогда время пребывания τ_i в состоянии i имеет показательное (экспоненциальное) распределение с параметром q_i :

$$\mathbb{P}(\tau_i > t \mid X(0) = i) = e^{-q_i t}, \quad t \geq 0.$$

Доказательство. Рассмотрим вероятность того, что процесс не покидает состояние i до момента времени t при условии $X(0) = i$. Согласно ранее доказанному свойству о непрерывности траекторий, эта вероятность эквивалентна вероятности того, что процесс находится в состоянии i во всех точках счетного всюду плотного множества $D(t)$.

Воспользуемся непрерывностью вероятностной меры и тем фактом, что последовательность событий $A_n = \{\text{процесс в состоянии } i \text{ во всех точках } D_n\}$ является монотонно убывающей ($A_{n+1} \subset A_n$):

$$\mathbb{P}(\tau_i > t \mid X(0) = i) = \mathbb{P} \left(\bigcap_{n=0}^{\infty} \bigcap_{j=1}^{2^n} \left\{ X \left(\frac{jt}{2^n} \right) = i \right\} \mid X(0) = i \right) = \lim_{n \rightarrow \infty} \mathbb{P} \left(\bigcap_{j=1}^{2^n} \left\{ X \left(\frac{jt}{2^n} \right) = i \right\} \mid X(0) = i \right).$$

Применим марковское свойство и свойство однородности. Вероятность того, что в каждый из 2^n моментов времени с шагом $\Delta t = \frac{t}{2^n}$ процесс окажется в состоянии i , при условии, что он начал в i , равна произведению соответствующих переходных вероятностей:

$$\mathbb{P} \left(\bigcap_{j=1}^{2^n} \left\{ X \left(\frac{jt}{2^n} \right) = i \right\} \mid X(0) = i \right) = \prod_{j=1}^{2^n} \mathbb{P} \left(X \left(\frac{jt}{2^n} \right) = i \mid X \left(\frac{(j-1)t}{2^n} \right) = i \right).$$

В силу однородности каждая вероятность в произведении равна $p_{ii} \left(\frac{t}{2^n} \right)$. Тогда:

$$\mathbb{P}(\tau_i > t \mid X(0) = i) = \lim_{n \rightarrow \infty} \left[p_{ii} \left(\frac{t}{2^n} \right) \right]^{2^n}.$$

Воспользуемся полученным ранее асимптотическим разложением для переходной вероятности $p_{ii}(h) = 1 + q_{ii}h + o(h)$ при $h \rightarrow 0$. Подставляя $h = \frac{t}{2^n}$:

$$\mathbb{P}(\tau_i > t \mid X(0) = i) = \lim_{n \rightarrow \infty} \left(1 + q_{ii} \frac{t}{2^n} + o \left(\frac{t}{2^n} \right) \right)^{2^n}.$$

Данный предел является классическим определением экспоненты (второй замечательный предел):

$$\lim_{n \rightarrow \infty} \left(1 + \frac{q_{ii}t}{2^n} \right)^{2^n} = e^{q_{ii}t}.$$

Итого, с учетом обозначения $q_{ii} = -q_i$, получаем:

$$\mathbb{P}(\tau_i > t \mid X(0) = i) = e^{q_{ii}t} = e^{-q_i t}.$$

Для безусловной вероятности $\mathbb{P}(\tau_i > t) = \mathbb{P}(\tau_i > t \mid X(0) = i) \cdot \mathbb{P}(X(0) = i)$. Обозначим $\pi_i(0) \doteq \mathbb{P}(X(0) = i)$, тогда:

$$\mathbb{P}(\tau_i > t) = e^{-q_i t} \cdot \pi_i(0).$$

Если в начальный момент времени процесс находился в состоянии i с вероятностью 1 ($\pi_i(0) = 1$), то:

$$\mathbb{P}(\tau_i > t) = e^{-q_i t}, \quad \text{следовательно, } \tau_i \sim \text{Exp}(q_i).$$

! Замечание !

Полученный результат раскрывает глубокий физический и вероятностный смысл интенсивности q_i . Величина, обратная интенсивности выхода, $\mathbb{E}\tau_i = \frac{1}{q_i}$, представляет собой **среднее время пребывания** процесса в состоянии i . Чем выше интенсивность q_i , тем меньше времени (в среднем) система проводит в данном состоянии до совершения скачка.

Отсутствие памяти у показательного распределения согласуется с марковским свойством: будущее поведение процесса после момента t при условии $\{X(t) = i\}$ не зависит от того, как долго процесс уже находился в этом состоянии до момента t .

Глава 2

Лекция 2. Эргодические цепи Маркова и потоки событий

2.1 Вероятностный смысл элементов матрицы интенсивностей и механика скачков

На предыдущей лекции мы установили смысл диагональных элементов матрицы интенсивностей Q : величина $q_{ii} = -q_i$ определяет интенсивность выхода из состояния i , а время пребывания в этом состоянии распределено экспоненциально с параметром q_i . Теперь перейдем к рассмотрению внедиагональных элементов q_{ij} при $i \neq j$ и выясним, как они определяют вероятности переходов (скачков) между различными состояниями.

Вероятность перехода в момент скачка

Обозначим через $F_{ij}(h)$ условную вероятность того, что цепь Маркова в момент времени $t + h$ окажется в состоянии j , при условии, что в момент t она находилась в состоянии i , и к моменту $t + h$ произошло изменение состояния (цепь не находится в i):

$$F_{ij}(h) \doteq \mathbb{P}(X(t+h) = j \mid X(t) = i, X(t+h) \neq i), \quad i \neq j. \quad (2.1)$$

Рассмотрим предельную вероятность такого перехода при стремлении временного интервала h к нулю.

Утв. Для непрерывной цепи Маркова предел условной вероятности перехода в состояние j в момент скачка из состояния i равен отношению соответствующей интенсивности к суммарной интенсивности выхода из i :

$$\lim_{h \rightarrow 0} F_{ij}(h) = \frac{q_{ij}}{q_i}. \quad (2.2)$$

Доказательство. Воспользуемся определением условной вероятности $\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$. Заметим, что событие $\{X(t+h) = j\}$ при $j \neq i$ влечет за собой событие $\{X(t+h) \neq i\}$. Следовательно, их пересечение совпадает с первым событием: $\{X(t+h) = j\} \cap \{X(t+h) \neq i\} = \{X(t+h) = j\}$.

Тогда искомая вероятность записывается как:

$$F_{ij}(h) = \frac{\mathbb{P}(X(t+h) = j \mid X(t) = i)}{\mathbb{P}(X(t+h) \neq i \mid X(t) = i)}. \quad (2.3)$$

Применим асимптотические разложения переходных вероятностей при $h \rightarrow 0$:

1. В числителе: $P_{ij}(h) = q_{ij}h + o(h)$ для всех $i \neq j$.

2. В знаменателе: вероятность выхода из состояния i есть дополнение к вероятности остаться в нем:

$$1 - P_{ii}(h) = 1 - (1 + q_{ii}h + o(h)) = -q_{ii}h - o(h) = q_i h + o(h).$$

Подставляя эти разложения, получаем:

$$F_{ij}(h) = \frac{q_{ij}h + o(h)}{q_i h + o(h)} = \frac{q_{ij} + \frac{o(h)}{h}}{q_i + \frac{o(h)}{h}}. \quad (2.4)$$

Переходя к пределу при $h \rightarrow 0$, все члены порядка $\frac{o(h)}{h}$ исчезают, и мы получаем окончательный результат:

$$\lim_{h \rightarrow 0} F_{ij}(h) = \frac{q_{ij}}{q_i}. \quad (2.5)$$

Таким образом, внедиагональные элементы q_{ij} определяют «приоритетность» выбора конкретного состояния j в момент, когда процесс покидает состояние i .

! Замечание !

Данный результат согласуется с конструкцией, предложенной Кай Лаем. Можно строго доказать, что времена пребывания в состояниях независимы в совокупности, а выбор следующего состояния не зависит от времени, проведенного в текущем.

Механика поведения цепи

На основе полученных свойств можно описать эволюцию цепи Маркова как дискретно-событийный процесс:

1. Пусть в начальный момент времени $t = 0$ процесс находится в некотором состоянии $i \in S$.
2. Процесс «задерживается» в состоянии i в течение случайного времени τ_i , имеющего экспоненциальное распределение с параметром q_i (то есть $\tau_i \sim \text{Exp}(q_i)$).
3. В момент завершения времени ожидания процесс совершает скачок в новое состояние $j \neq i$ с вероятностью $\frac{q_{ij}}{q_i}$.
4. После перехода в состояние j процесс снова «задерживается» в нем на время $\tau_j \sim \text{Exp}(q_j)$, и цикл повторяется.

2.2 Эргодические непрерывные цепи Маркова

Перейдем к изучению асимптотического поведения непрерывных цепей Маркова при $t \rightarrow \infty$. Как и в дискретном случае, центральное место здесь занимает понятие стационарного распределения и классификация состояний.

Стационарное распределение

Вектор вероятностей π_0 называется стационарным распределением непрерывной цепи Маркова, если для любого момента времени $t > 0$ выполняется уравнение:

$$P^T(t) \cdot \pi_0 = \pi_0. \quad (2.6)$$

Для однородной цепи с матрицей интенсивностей Q стационарное распределение находится из **стационарного уравнения Колмогорова**:

$$Q^T \pi_0 = 0. \quad (2.7)$$

2.2.1 Классификация состояний и их свойства

Классификация состояний в непрерывном времени $t \in [0, +\infty)$ строится аналогично дискретному случаю, однако вместо числа шагов n мы рассматриваем интегральные характеристики на всей временной оси.

Сообщаемость и существенность

1. Состояние j *достижимо* из i ($i \rightarrow j$), если $\exists t > 0 : p_{ij}(t) > 0$.
2. Состояния i и j *сообщаются* ($i \leftrightarrow j$), если $i \rightarrow j$ и $j \rightarrow i$.
3. Состояние i называется *существенным*, если из того, что $i \rightarrow j$, следует $j \rightarrow i$.

Теорема о солидарности

Для неразложимой цепи Маркова (где все состояния сообщаются, $i \leftrightarrow j$) все состояния имеют один и тот же тип: они либо все невозвратны, либо все нулевые возвратные, либо все положительно возвратные.

! Замечание !

В отличие от дискретных цепей, в непрерывном случае понятие **периодичности** не вводится. Поскольку время перехода между состояниями является случайной величиной с экспоненциальным распределением, возможен возврат за любое время $t > 0$, что делает невозможным существование фиксированного шага (периода) $d > 1$. Таким образом, все состояния в непрерывных цепях апериодичны.

Для введения понятий возвратности обозначим через $\tau_{ii} \doteq \inf\{t > J_1 : X(t) = i \mid X(0) = i\}$ случайную величину времени первого возвращения в состояние i (после первого скачка J_1).

Типы возвратности

1. Состояние i называется *возвратным*, если $\mathbb{P}(\tau_{ii} < \infty) = 1$. Аналогично можно показать, что данное определение в терминах переходных вероятностей это эквивалентно:

$$\int_0^{+\infty} p_{ii}(t) dt = \infty. \quad (2.8)$$

2. Если $\mathbb{P}(\tau_{ii} < \infty) < 1$ (или интеграл выше сходится), состояние называется *невозвратным*.

3. Возвратное состояние i называется *положительно возвратным*, если среднее время возврата конечно ($\mathbb{E}\tau_{ii} < \infty$). Это эквивалентно условию, что предельная вероятность пребывания в состоянии строго положительна:

$$\lim_{t \rightarrow \infty} p_{ii}(t) = \pi_i > 0. \quad (2.9)$$

4. Возвратное состояние i называется *нулевым возвратным*, если среднее время возврата бесконечно ($\mathbb{E}\tau_{ii} = \infty$). В этом случае, несмотря на неизбежность возвращения, вероятность застать её в состоянии i стремится к нулю:

$$\lim_{t \rightarrow \infty} p_{ii}(t) = 0. \quad (2.10)$$

▽ Утв. [**Классификация состояний в конечных цепях**] В конечной непрерывной цепи Маркова:

- Все состояния в закрытых классах являются положительно возвратными и существенными.
- Все состояния в открытых классах являются нулевыми, невозвратными и несущественными.
- Нулевых возвратных состояний в конечных цепях не существует.

2.2.2 Эргодические теоремы

Сильная эргодичность

Непрерывная цепь Маркова называется *сильно эргодической*, если $\forall i, j \in S$ существует предел $\lim_{t \rightarrow \infty} p_{ij}(t) = p_j > 0$, не зависящий от начального состояния i .

Эргодическая теорема для конечных цепей

Конечная непрерывная цепь Маркова *сильно эргодична* тогда и только тогда, когда она неразложима.

Доказательство. $\Rightarrow$ Пусть цепь сильно эргодична. Тогда $\lim_{t \rightarrow \infty} p_{ij}(t) = p_j > 0$, что влечет существование такого T , что при всех $t \geq T$ выполняется $p_{ij}(t) > 0$. Это означает, что любое состояние достижимо из любого другого, то есть цепь неразложима.

$\Leftarrow$ В дискретном случае требовалась априодичность. Как уже было отмечено, в непрерывном времени $p_{ii}(t) > 0$ для всех $t \geq 0$, поэтому неразложимости достаточно для того, чтобы за некоторое время T установилась строгая положительность всех $p_{ij}(t)$. Это свойство выполняется в силу того, что время жизни в каждом состоянии распределено по закону $\text{Exp}(q_i)$, а условие неразложимости гарантирует наличие пути между любыми состояниями. Поскольку скачок в соседнее состояние возможен за сколь угодно малое время, из любого i можно попасть в любое j с ненулевой вероятностью за любое время $t > 0$. Далее доказательство сводится к дискретному случаю. ■

Эргодическое свойство средних*

В конечной однородной неразложимой непрерывной цепи Маркова почти наверное выполняется:

$$\frac{1}{T} \int_0^T I(X(t) = j) dt \xrightarrow[T \rightarrow \infty]{\text{п.н.}} p_j, \quad (2.11)$$

где p_j — стационарная вероятность, выражающаяся через среднее время пребывания в состоянии $1/q_j$ и среднее время возврата $\mathbb{E}\tau_{jj}$:


$$p_j = \frac{1/q_j}{\mathbb{E}\tau_{jj}}. \quad (2.12)$$

! Замечание !

Физический смысл $p_j = \frac{\mathbb{E}\text{Exp}(q_j)}{\mathbb{E}\tau_{jj}}$ заключается в том, что предельная доля времени нахождения в состоянии j равна отношению среднего времени одного визита в это состояние к среднему времени между циклами возвращения.

2.3 Примеры решения задач**Пример: Нахождение вероятностей состояний и переходной матрицы**

Рассмотрим непрерывную цепь Маркова с двумя состояниями $S = \{0, 1\}$. Граф интенсивностей переходов задан следующим образом:



Где $\lambda > 0$ и $\mu > 0$ — заданные интенсивности. Требуется найти вектор вероятностей состояний $\pi(t)$ и матрицу переходных вероятностей $P(t)$.

Решение. 1. Формирование матрицы интенсивностей. Согласно определению матрицы Q , внедиагональные элементы q_{ij} равны интенсивностям соответствующих переходов. Диагональные элементы q_{ii} определяются из условия равенства нулю суммы элементов каждой строки:

$$Q = \begin{pmatrix} -\lambda & \lambda \\ \mu & -\mu \end{pmatrix}. \quad (2.13)$$

Транспонированная матрица, необходимая для уравнений Колмогорова, имеет вид:

$$Q^T = \begin{pmatrix} -\lambda & \mu \\ \lambda & -\mu \end{pmatrix}. \quad (2.14)$$

2. Решение системы дифференциальных уравнений. Вектор вероятностей $\pi(t) = (\pi_0(t), \pi_1(t))^T$

удовлетворяет системе $\dot{\pi}(t) = Q^T \pi(t)$:

$$\begin{cases} \dot{\pi}_0(t) = -\lambda\pi_0(t) + \mu\pi_1(t) \\ \dot{\pi}_1(t) = \lambda\pi_0(t) - \mu\pi_1(t) \end{cases} \quad (2.15)$$

Воспользуемся условием нормировки $\pi_0(t) + \pi_1(t) = 1$, откуда $\pi_1(t) = 1 - \pi_0(t)$. Подставим это в первое уравнение:

$$\dot{\pi}_0(t) = -\lambda\pi_0(t) + \mu(1 - \pi_0(t)) = -(\lambda + \mu)\pi_0(t) + \mu. \quad (2.16)$$

Это линейное неоднородное уравнение первого порядка. Общее решение соответствующего однородного уравнения: $\pi_{0,\text{одн}}(t) = Ce^{-(\lambda+\mu)t}$. Частное решение ищем в виде константы (стационарное состояние $\dot{\pi}_0 = 0$):

$$0 = -(\lambda + \mu)\pi_0^* + \mu \implies \pi_0^* = \frac{\mu}{\lambda + \mu}. \quad (2.17)$$

Тогда общее решение:

$$\pi_0(t) = \frac{\mu}{\lambda + \mu} + Ce^{-(\lambda+\mu)t}. \quad (2.18)$$

Из начального условия при $t = 0$ находим $C = \pi_0(0) - \frac{\mu}{\lambda+\mu}$. Окончательно:

$$\pi_0(t) = \frac{\mu}{\lambda + \mu} + \left(\pi_0(0) - \frac{\mu}{\lambda + \mu} \right) e^{-(\lambda+\mu)t}, \quad \pi_1(t) = 1 - \pi_0(t). \quad (2.19)$$

3. Нахождение переходной матрицы $P(t)$. Матрица $P(t)$ удовлетворяет уравнению $\dot{P}(t) = P(t)Q$ с начальным условием $P(0) = I$. Заметим, что каждая строка матрицы $P(t)$ — это вектор вероятностей состояний при специфическом начальном распределении (либо $(1, 0)$ или $(0, 1)$).

Для первой строки $(p_{00}(t), p_{01}(t))$ начальное условие $p_{00}(0) = 1$. Подставляя его в решение для $\pi_0(t)$:

$$p_{00}(t) = \frac{\mu}{\lambda + \mu} + \left(1 - \frac{\mu}{\lambda + \mu} \right) e^{-(\lambda+\mu)t} = \frac{\mu}{\lambda + \mu} + \frac{\lambda}{\lambda + \mu} e^{-(\lambda+\mu)t}. \quad (2.20)$$

Для второй строки $(p_{10}(t), p_{11}(t))$ начальное условие $p_{10}(0) = 0$:

$$p_{10}(t) = \frac{\mu}{\lambda + \mu} + \left(0 - \frac{\mu}{\lambda + \mu} \right) e^{-(\lambda+\mu)t} = \frac{\mu}{\lambda + \mu} - \frac{\mu}{\lambda + \mu} e^{-(\lambda+\mu)t}. \quad (2.21)$$

Остальные элементы находятся как $p_{01} = 1 - p_{00}$ и $p_{11} = 1 - p_{10}$.

4. Стационарный режим. Поскольку цепь неразложима ($\lambda, \mu > 0$), существует единственное стационарное распределение π , которое является пределом $P(t)$ при $t \rightarrow \infty$. Решая алгебраическую систему $Q^T \pi = 0$:

$$\begin{cases} -\lambda\pi_0 + \mu\pi_1 = 0 \\ \pi_0 + \pi_1 = 1 \end{cases} \implies \pi_0 = \frac{\mu}{\lambda + \mu}, \quad \pi_1 = \frac{\lambda}{\lambda + \mu}. \quad (2.22)$$


Этот результат полностью согласуется с пределом $t \rightarrow \infty$ в динамическом решении. ■

! Замечание !

В данном примере мы явно увидели проявление эргодичности: независимо от начального состояния (выбора строки в $P(t)$ или начального вектора $\pi(0)$), система стремится к одному и тому же распределению вероятностей.

Пример: Процесс рождения и гибели

Однородная непрерывная цепь Маркова называется процессом рождения — гибели, если её стохастический граф имеет линейную структуру, где переходы возможны только между соседними состояниями:



Здесь $\lambda_i > 0$ — интенсивности рождения, $\mu_i > 0$ — интенсивности гибели, а количество состояний N может быть как конечным, так и бесконечным. Процесс является непрерывным аналогом случайных блужданий. Найдем для него явный вид стационарных вероятностей состояний π_i .

Решение. Прежде всего отметим, что стационарное распределение существует, является единственным и совпадает с предельным распределением вероятностей по эргодической теореме, поскольку рассматриваемая цепь образует замкнутый класс. Найдем стационарное распределение π° . Матрица интенсивностей Q для такого процесса является трехдиагональной:

$$Q = \begin{pmatrix} -\lambda_0 & \lambda_0 & 0 & 0 & \dots \\ \mu_1 & -(\mu_1 + \lambda_1) & \lambda_1 & 0 & \dots \\ 0 & \mu_2 & -(\mu_2 + \lambda_2) & \lambda_2 & \dots \\ \vdots & \vdots & \ddots & \ddots & \ddots \end{pmatrix} \quad (2.23)$$

Для нахождения π° решим уравнение $\pi^\circ Q = 0$. Распишем систему по столбцам:

$$1) \quad -\pi_0 \lambda_0 + \pi_1 \mu_1 = 0 \implies \pi_1 = \pi_0 \frac{\lambda_0}{\mu_1}$$

$$2) \quad \pi_0 \lambda_0 - \pi_1 (\lambda_1 + \mu_1) + \pi_2 \mu_2 = 0. \text{ Подставляя } \pi_0 \lambda_0 = \pi_1 \mu_1, \text{ получаем:}$$

$$\pi_1 \mu_1 - \pi_1 \lambda_1 - \pi_1 \mu_1 + \pi_2 \mu_2 = 0 \implies \pi_2 = \pi_1 \frac{\lambda_1}{\mu_2} = \pi_0 \frac{\lambda_0 \lambda_1}{\mu_1 \mu_2} \quad (2.24)$$

По индукции для любого $k \geq 1$ получаем общее уравнение баланса $\pi_i \lambda_i = \pi_{i+1} \mu_{i+1}$, откуда:

$$\pi_k = \pi_0 \prod_{i=1}^k \frac{\lambda_{i-1}}{\mu_i} \quad (2.25)$$

Вероятность π_0 находится из условия нормировки $\sum_{k=0}^{N-1} \pi_k = 1$:

$$\pi_0 \left(1 + \sum_{k=1}^{N-1} \prod_{i=1}^k \frac{\lambda_{i-1}}{\mu_i} \right) = 1 \implies \pi_0 = \left[1 + \sum_{k=1}^{N-1} \prod_{i=1}^k \frac{\lambda_{i-1}}{\mu_i} \right]^{-1} \quad (2.26)$$

Пуассоновский процесс (определение через процесс рождения)

Пусть $K(t), t \geq 0$ — непрерывная цепь Маркова с $S = \{0, 1, 2, \dots\}$, непрерывными справа траекториями, являющаяся процессом чистого рождения с постоянными интенсивностями:

$$\lambda_i = \lambda > 0, \quad \mu_i = 0 \quad \forall i. \quad (2.27)$$

Тогда $K(t)$ называется пуассоновским процессом с интенсивностью λ .

! Замечание !

Поскольку пуассоновский процесс обладает независимыми приращениями, он автоматически удовлетворяет марковскому свойству. В данной интерпретации мы рассматриваем его как вырожденный случай процесса рождения-гибели, где «гибель» невозможна.

2.4 Потоки событий

Поток событий

Потоком событий называется последовательность одинаково распределённых событий, происходящих одно за другим через случайные промежутки времени.



Пусть $t_1, t_2 > 0$. Обозначим через $n(t_1, t_2)$ случайную величину, равную числу событий из потока, попавших в полуинтервал $[t_1, t_2)$.

Свойства потоков

1. Поток называется **однородным (стационарным)**, если распределения случайных величин $n(t_1, t_2)$ и $n(t_1 + s, t_2 + s)$ совпадают для любого $s > 0$. Для таких потоков вводится обозначение $n(t) \doteq n(0, t)$.
2. Рассмотрим моменты времени $0 = t_0 \leq t_1 \leq \dots \leq t_{m+1}$ и соответствующие приращения $\xi_k = n(t_k, t_{k+1})$. Поток называется **поток без последействия**, если совокупность случайных величин $\{\xi_0, \dots, \xi_m\}$ независима в совокупности.

Дополнительно введем ограничение: между любыми двумя событиями в потоке проходит конечное (но случайное) время. Это означает, что после наступления события наступает интервал положительной длительности, в течение которого новых событий не происходит, но по истечении которого событие обязательно наступит. Это допущение эквивалентно требованию **непрерывности справа** траекторий процесса $n(t)$.

2.4.1 Марковская природа потоков без последействия

Исследуем структуру такого потока. Заметим, что:

1. $n(t_k, t_{k+1}) = n(t_{k+1}) - n(t_k)$ независимы в совокупности по определению отсутствия последействия.
2. Следовательно, $n(t)$ является процессом с **независимыми приращениями**.
3. Любой процесс с независимыми приращениями обладает марковским свойством.

Так как процесс $n(t)$ определен на непрерывном времени $t \in [0, +\infty)$, а его фазовое пространство дискретно ($S = \mathbb{N}_0$), то $n(t)$ представляет собой **непрерывную цепь Маркова**. Если поток однороден, то и цепь Маркова является однородной.

Тот факт, что траектории $n(t)$ непрерывны справа, делает эту цепь **стандартной**. Из этого вытекают фундаментальные аналитические свойства:

$$P(t) \xrightarrow[t \rightarrow 0+]{} I, \quad P(t) \in C[0, +\infty). \quad (2.28)$$

2.4.2 Интенсивности переходов в потоке без последействия

Рассмотрим вопрос об интенсивностях переходов в марковской цепи, описывающей поток событий. Исходя из свойств траекторий процесса $n(t)$, мы можем сделать ряд важных выводов о структуре матрицы интенсивностей.

Утв. Для марковской цепи, соответствующей однородному потоку без последействия, интенсивности переходов λ_{ij} не зависят от текущего состояния i и отличны от нуля только для переходов в непосредственно следующее состояние ($j = i + 1$). При этом диагональные элементы λ_{ii} конечны и равны по модулю интенсивности потока.

Доказательство. 1. **Анализ переходных вероятностей.** Так как траектории процесса $n(t)$ являются неубывающими по определению (количество событий не может уменьшаться), то переходные вероятности $p_{ij}(t)$ отличны от нуля только при $j \geq i$. Для стандартной цепи Маркова при $j > i$ существуют конечные интенсивности переходов:

$$\exists \lambda_{ij} = \dot{p}_{ij}(0), \quad 0 \leq \lambda_{ij} < \infty.$$

Для диагональных элементов $\lambda_{ii} = \dot{p}_{ii}(0)$ априори допускается значение $-\infty$, однако покажем, что в данном случае они конечны.

2. **Строгая положительность интенсивности выхода.** Заметим, что $\lambda_{ii} < 0$ (так как $p_{ii}(t)$ убывает от 1). Предположим, что $\lambda_{ii} = 0$. Тогда, воспользовавшись мультипликативным свойством и перейдя к пределу, получим:

$$p_{ii}(t) = \left[p_{ii}\left(\frac{t}{n}\right) \right]^n = \left(1 + \dot{p}_{ii}(0) \frac{t}{n} + o\left(\frac{t}{n}\right) \right)^n = \left(1 + 0 \cdot \frac{t}{n} + o\left(\frac{t}{n}\right) \right)^n \xrightarrow[n \rightarrow \infty]{} 1.$$

Следовательно, $p_{ii}(t) \equiv 1$ для всех $t \geq 0$. Это означает, что система никогда не покидает состояние i , что прямо противоречит условию о том, что между событиями проходит конечное время. Таким образом, $\lambda_{ii} < 0$.

3. Независимость от состояния (однородность). Предположим, что λ_{ii} конечна. Рассмотрим вероятность того, что на интервале длины h не произойдет ни одного события:

$$p_{ii}(h) = \mathbb{P}(n(t+h) = i \mid n(t) = i) = \mathbb{P}(n(t+h) - n(t) = 0 \mid n(t) = i).$$

В силу свойства независимости приращений, данная вероятность совпадает с безусловной вероятностью того, что за время h приращение процесса составит 0:

$$p_{ii}(h) = \mathbb{P}(n(h) = 0).$$

Отсюда следует, что величина $p_{ii}(h)$ (а значит, и её производная в нуле λ_{ii}) не зависит от индекса состояния i . Обозначим $-\lambda_{ii} \doteq \lambda$. Как было показано ранее, время пребывания в состоянии в таком случае распределено экспоненциально: $\tau_i \sim \text{Exp}(\lambda)$.

4. Отсутствие групповых скачков. Рассмотрим переход из i в $i+1$. Аналогично предыдущему пункту:

$$p_{i,i+1}(h) = \mathbb{P}(n(t+h) - n(t) = 1 \mid n(t) = i) = \mathbb{P}(n(h) = 1).$$

Это означает, что интенсивность перехода $\lambda_{i,i+1}$ также не зависит от i . Обозначим её за λ . Тогда:

$$\frac{p_{i,i+1}(h)}{h} \xrightarrow{h \rightarrow 0} \lambda.$$

Рассмотрим переходы типа $i \rightarrow i+k$ при $k > 1$ (например, $0 \rightarrow 2$). По условию, между любыми двумя событиями проходит конечное время. Это исключает возможность мгновенного скачка через несколько состояний (групповое поступление событий). Следовательно, такие интенсивности равны нулю: $\lambda_{ij} = 0$ при $j > i+1$. ■

Визуально структуру переходов в такой цепи можно представить следующей диаграммой:




Рис. 2.1: Схема интенсивностей переходов пуассоновского процесса.

! Замечание !

Таким образом, мы получили непрерывную цепь Маркова со счетным фазовым пространством $S = \mathbb{N}_0$, стартующую из нуля, имеющую независимые приращения и экспоненциальные времена между скачка-

ми. Данная конструкция (схема переходов $0 \rightarrow 1 \rightarrow 2 \rightarrow \dots$) полностью определяет **пуассоновский процесс**.

2.4.3 Ординарность и эквивалентные определения пуассоновского процесса

В предыдущих рассуждениях мы существенно опирались на допущение о том, что между любыми двумя последовательными событиями в потоке проходит конечное время, и интенсивности выхода из состояний удовлетворяют условию $0 < \lambda_i < \infty$. Данные условия гарантируют *стандартность* цепи Маркова, а также определяют структуру времени пребывания в состояниях и вероятности скачков.

Если мы рассматриваем поток, в котором на любом конечном интервале времени происходит конечное число событий, условие $\lambda_i < \infty$ выполняется автоматически. При этом требование конечности межсобытийных интервалов эквивалентно требованию *непрерывности справа* траекторий процесса $n(t)$.

Формально условия на структуру приращений процесса можно переписать через свойство ординарности.

▼ **УТВ.** Для однородного потока событий с интенсивностью $0 < \lambda < \infty$ вероятности изменения состояния на малом интервале времени $h \rightarrow 0$ представимы в виде:

$$\begin{cases} \mathbb{P}(n(t, t+h) = 1) = \lambda h + o(h), \\ \mathbb{P}(n(t, t+h) = 0) = 1 - \lambda h + o(h). \end{cases} \quad (2.29)$$

Отсюда, в силу нормировки, следует, что вероятность наступления двух и более событий за малое время пренебрежимо мала:

$$\mathbb{P}(n(t, t+h) \geq 2) = o(h), \quad h \rightarrow 0.$$

Данное свойство называется **ординарностью** потока и исключает возможность группового поступления событий.

Теперь мы можем дать строгое определение рассматриваемому процессу.

Пуассоновский процесс

Пусть дан однородный ординарный поток без последействия с интенсивностью λ . Тогда случайный процесс $K(t) \doteq n(0, t)$, равный числу событий, произошедших на полуинтервале $[0, t)$, называется **пуассоновским процессом** с интенсивностью λ (или простейшим пуассоновским потоком).

! Замечание !

В случае отказа от условия однородности интенсивность становится функцией времени:

$$\lambda(t) \doteq \lim_{h \rightarrow 0} \frac{\mathbb{P}(n(t, t+h) > 0)}{h}.$$

Тогда свойство ординарности принимает локальный вид:

$$\mathbb{P}(n(t, t+h) = 1) = \lambda(t)h + o(h),$$

$$\mathbb{P}(n(t, t+h) = 0) = 1 - \lambda(t)h + o(h).$$

Такой процесс называется *неоднородным пуассоновским процессом*.

Подводя итог изучению данного класса процессов, перечислим четыре эквивалентных подхода к его определению, которые мы встретили в рамках курса:

1. **Аксиоматическое определение:** через свойства независимых и стационарных приращений, распределенных по закону Пуассона.
2. **Явная конструкция:** как процесс, в котором времена между скачками независимы и распределены экспоненциально с параметром λ .
3. **Процесс гибели и размножения:** как частный случай (чистый процесс рождения) марковской цепи с непрерывным временем и линейной структурой переходов.
4. **Потоковое определение:** как однородный ординарный поток без последствия.

Глава 3

Лекция 3. Введение в СМО, нотация Кендалла, формула Литтла

3.1 Примеры простейших систем массового обслуживания

Математическим аппаратом для моделирования систем массового обслуживания (СМО) традиционно служат однородные марковские цепи с непрерывным временем. Эволюция такой цепи полностью определяется заданием начального распределения и матрицы переходных вероятностей $P(t)$.

В случае сильной эргодичности цепи существует единственное стационарное распределение π , которое совпадает с предельным распределением вероятностей состояний и не зависит от начального состояния системы. Прямое вычисление элементов матрицы $P(t)$ через дифференциальные уравнения Колмогорова зачастую сопряжено со значительными аналитическими трудностями. На практике задача нахождения стационарных характеристик сводится к построению матрицы интенсивностей переходов Q (инфинитезимального генератора) и последующему решению алгебраической системы $Q^T \pi = 0$.

Пример: Двухканальная СМО с отказами

Рассмотрим систему массового обслуживания, состоящую из двух параллельных каналов. На вход системы поступает пуассоновский поток заявок с интенсивностью λ . Времена обслуживания заявок в каналах независимы и распределены по показательному закону с параметрами μ_1 и μ_2 соответственно. Алгоритм маршрутизации задается следующими правилами:

- Если оба канала свободны, заявка занимает один из них с равной вероятностью.
- Если свободен только один канал, поступающая заявка направляется в него.
- Если оба канала заняты, заявка получает отказ и покидает систему.

Требуется построить стохастический граф переходов и найти стационарное распределение вероятностей состояний системы.

Решение. Определим фазовое пространство системы $S = \{0, 1, 2, 3\}$. Введем случайный процесс $X(t) \in S$, характеризующий состояние системы в момент времени t :

- 0 — в системе нет заявок (оба канала свободны);
- 1 — занят только первый канал;

- 2 — занят только второй канал;
- 3 — заняты оба канала.

Предполагается, что траектории процесса $X(t)$ являются непрерывными справа функциями времени.




Схема интенсивностей переходов двухканальной СМО.

Вычислим элементы матрицы интенсивностей $Q = \|q_{ij}\|$. Рассмотрим поведение переходных вероятностей $p_{ij}(h)$ при $h \rightarrow 0+0$:

- **Переходы из состояния 0:** За малое время h в систему поступает одна заявка с вероятностью $\lambda h + o(h)$. Согласно условию, выбор свободного канала равновероятен. Следовательно, вероятности переходов равны $p_{01}(h) = \frac{1}{2}(\lambda h + o(h))$ и $p_{02}(h) = \frac{1}{2}(\lambda h + o(h))$. Переходя к пределу, находим $q_{01} = q_{02} = \frac{\lambda}{2}$. Вероятность одновременного поступления двух заявок есть $o(h)$, поэтому $q_{03} = 0$.
- **Переходы из состояния 1:** Система переходит в состояние 3, если поступает новая заявка (вероятность $\lambda h + o(h)$), а обслуживание текущей заявки не завершается (вероятность $1 - \mu_1 h + o(h)$). В силу независимости событий их совместная вероятность равна $(\lambda h + o(h))(1 - \mu_1 h + o(h)) = \lambda h + o(h)$, откуда $q_{13} = \lambda$. Переход в состояние 0 происходит при завершении обслуживания (вероятность $\mu_1 h + o(h)$) и отсутствии новых заявок ($1 - \lambda h + o(h)$), что дает $q_{10} = \mu_1$.
- **Переходы из состояния 2:** В силу симметрии рассуждений получаем $q_{23} = \lambda$ и $q_{20} = \mu_2$.
- **Переходы из состояния 3:** Система переполнена, новые заявки отбрасываются. Изменение состояния возможно лишь при завершении обслуживания. Если обработка заканчивается в первом канале, он освобождается, и система переходит в состояние 2: $q_{32} = \mu_1$. Аналогично при освобождении второго канала $q_{31} = \mu_2$.

Диагональные элементы определяются из свойства консервативности цепи $q_{ii} = -\sum_{j \neq i} q_{ij}$. Матрица интенсивностей принимает вид:

$$Q = \begin{pmatrix} -\lambda & \frac{\lambda}{2} & \frac{\lambda}{2} & 0 \\ \mu_1 & -(\mu_1 + \lambda) & 0 & \lambda \\ \mu_2 & 0 & -(\mu_2 + \lambda) & \lambda \\ 0 & \mu_2 & \mu_1 & -(\mu_1 + \mu_2) \end{pmatrix}$$

Рассматриваемая цепь Маркова конечна и неразложима. По теореме об эргодичности конечных цепей она является сильно эргодической, что гарантирует существование единственного стационарного распределения $\pi = (\pi_0, \pi_1, \pi_2, \pi_3)^T$. Решим матричное уравнение $Q^T \pi = 0$, которое расписывается в систему балансных уравнений:

$$\begin{cases} -\lambda\pi_0 + \mu_1\pi_1 + \mu_2\pi_2 = 0, \\ \frac{\lambda}{2}\pi_0 - (\mu_1 + \lambda)\pi_1 + \mu_2\pi_3 = 0, \\ \frac{\lambda}{2}\pi_0 - (\mu_2 + \lambda)\pi_2 + \mu_1\pi_3 = 0, \\ \lambda\pi_1 + \lambda\pi_2 - (\mu_1 + \mu_2)\pi_3 = 0. \end{cases}$$

Выразим π_1 и π_2 через π_3 . Вычитая третье уравнение из второго, получаем:

$$(\lambda + \mu_1)\pi_1 - (\lambda + \mu_2)\pi_2 = (\mu_2 - \mu_1)\pi_3.$$

Из четвертого уравнения следует $\lambda(\pi_1 + \pi_2) = (\mu_1 + \mu_2)\pi_3$. Выражая π_2 и подставляя в полученную разность, находим точные соотношения:

$$\pi_1 = \frac{\mu_2}{\lambda}\pi_3, \quad \pi_2 = \frac{\mu_1}{\lambda}\pi_3.$$

Подставляя найденное π_1 во второе уравнение системы, определяем π_0 :

$$\frac{\lambda}{2}\pi_0 - (\mu_1 + \lambda)\frac{\mu_2}{\lambda}\pi_3 + \mu_2\pi_3 = 0 \implies \frac{\lambda}{2}\pi_0 = \frac{\mu_1\mu_2}{\lambda}\pi_3 \implies \pi_0 = \frac{2\mu_1\mu_2}{\lambda^2}\pi_3.$$

Окончательное решение восстанавливается из условия нормировки $\pi_0 + \pi_1 + \pi_2 + \pi_3 = 1$. Вынеся π_3 за скобки, получаем:

$$\pi_3 \left(\frac{2\mu_1\mu_2}{\lambda^2} + \frac{\mu_2}{\lambda} + \frac{\mu_1}{\lambda} + 1 \right) = 1.$$

Обозначим константу нормировки как $C = \frac{2\mu_1\mu_2}{\lambda^2} + \frac{\mu_2}{\lambda} + \frac{\mu_1}{\lambda} + 1$. Тогда стационарные вероятности задаются вектором:

$$\pi_0 = \frac{2\mu_1\mu_2}{C\lambda^2}, \quad \pi_1 = \frac{\mu_2}{C\lambda}, \quad \pi_2 = \frac{\mu_1}{C\lambda}, \quad \pi_3 = \frac{1}{C}.$$

Пример: Многоканальная СМО с ограниченной емкостью $(M|M|c|K)$

Рассмотрим систему массового обслуживания, функционирующую по следующим правилам:

1. Входящий поток заявок является пуассоновским с интенсивностью λ .
2. Система содержит c идентичных и независимых каналов обслуживания. Время обслуживания заявки в каждом канале распределено экспоненциально с параметром μ .
3. Общая емкость системы ограничена числом K ($K \geq c$). Это означает, что в системе одновременно может находиться не более K заявок (из них c на обслуживании и $K - c$ в очереди).
4. Дисциплина обслуживания: если все каналы заняты, новая заявка становится в очередь, если в ней

есть свободные места. Если в системе уже находится K заявок, вновь прибывшая заявка получает отказ и теряется.

Требуется:

1. Показав, что число заявок в системе $X(t)$ является процессом рождения и гибели, построить граф интенсивностей переходов.
2. Найти стационарное распределение вероятностей состояний.
3. Записать выражения для среднего числа заявок в системе и средней длины очереди.

Решение. 1. Анализ процесса и построение графа. Определим состояние системы $X(t)$ как число заявок, находящихся в системе в момент времени t . Фазовое пространство системы конечно: $S = \{0, 1, \dots, K\}$. Рассмотрим переходы за малый промежуток времени h :

- **Интенсивность рождения (поступления заявки):** Пусть в системе находится $i < K$ заявок. Вероятность поступления новой заявки за время h равна $\lambda h + o(h)$. Поскольку поток ординарен, вероятность поступления двух и более заявок есть $o(h)$.

$$p_{i,i+1}(h) = \lambda h + o(h) \implies \lambda_{i,i+1} = \lambda, \quad 0 \leq i < K.$$

Если $i = K$, новые заявки отбрасываются, переход в состояние $K + 1$ невозможен ($\lambda_{K,K+1} = 0$).

- **Интенсивность гибели (обслуживания заявки):** Пусть в системе находится $i > 0$ заявок. Рассмотрим два случая:

а) *Неполная загрузка каналов* ($0 < i \leq c$). Заняты i каналов. Обслуживание закончится, если хотя бы один из i каналов завершит работу. Вероятность завершения обслуживания в конкретном канале равна $\mu h + o(h)$. Вероятность того, что завершится обслуживание ровно в одном из i каналов (сумма вероятностей несовместных событий):

$$p_{i,i-1}(h) = C_i^1(\mu h + o(h))(1 - \mu h + o(h))^{i-1} = i\mu h + o(h).$$


б) *Полная загрузка каналов* ($c < i \leq K$). Работают все c каналов (остальные $i - c$ заявок ждут в очереди). Интенсивность выхода определяется только работающими каналами:

$$p_{i,i-1}(h) = C_c^1(\mu h + o(h))(1 - \mu h + o(h))^{c-1} = c\mu h + o(h).$$

Объединяя результаты, получаем выражение для интенсивности гибели μ_i :

$$\mu_i = \min\{i, c\} \cdot \mu = \begin{cases} i\mu, & 0 < i \leq c, \\ c\mu, & c < i \leq K. \end{cases}$$

Поскольку переходы возможны только в соседние состояния, процесс $X(t)$ является процессом рождения и гибели. Построим граф переходов:



2. Стационарное распределение. Цепь Маркова конечна и неразложима, следовательно, она является сильно эргодической и существует единственное стационарное распределение $\pi = (\pi_0, \dots, \pi_K)$. Воспользуемся общей формулой для процессов рождения и гибели:

$$\pi_j = \frac{\lambda_{j-1} \cdot \lambda_{j-2} \cdot \dots \cdot \lambda_0}{\mu_j \cdot \mu_{j-1} \cdot \dots \cdot \mu_1} \pi_0.$$

Введем обозначение $r = \frac{\lambda}{\mu}$ (приведенная интенсивность потока).

Для $j \leq c$ в знаменателе стоит факториал $j!$:

$$\pi_j = \frac{\lambda^j}{1\mu \cdot 2\mu \cdot \dots \cdot j\mu} \pi_0 = \frac{(\lambda/\mu)^j}{j!} \pi_0 = \frac{r^j}{j!} \pi_0.$$

Для $j > c$ в знаменателе первые c множителей дают $c!$, а остальные $j - c$ множителей равны c :

$$\pi_j = \frac{\lambda^j}{c! \mu^c \cdot (c\mu)^{j-c}} \pi_0 = \frac{\lambda^j}{c! c^{j-c} \mu^j} \pi_0 = \frac{r^j}{c! c^{j-c}} \pi_0.$$

Вероятность простоя π_0 находится из условия нормировки $\sum_{j=0}^K \pi_j = 1$:

$$\pi_0 = \left(\sum_{j=0}^c \frac{r^j}{j!} + \frac{r^c}{c!} \sum_{j=c+1}^K \left(\frac{r}{c} \right)^{j-c} \right)^{-1}.$$

3. Характеристики эффективности. Математическое ожидание числа заявок в системе:

$$\bar{n} = \sum_{n=0}^K n \cdot \pi_n.$$

Средняя длина очереди (число заявок, ожидающих обслуживания):

$$L_q = \sum_{n=c+1}^K (n - c) \cdot \pi_n.$$

! Замечание !

В нотации Кендалла описанная выше модель обозначается как $M|M|c|K$. Полученные формулы являются классическими для теории телетрафика (формулы Эрланга для систем с ожиданием и потерями).

3.2 Классификация систем массового обслуживания и нотация Кендалла

Для построения корректной математической модели СМО необходимо формализовать основные параметры, определяющие её функционирование. Выделяют следующие ключевые характеристики:

1. Характеристики входящего потока:

- *Тип распределения интервалов*: детерминированный, экспоненциальный (марковский), общий и др.
- *Свойства потока*: стационарность, ординарность, наличие последствия.
- *Поведение заявок*: возможность ожидания в очереди, наличие ограничений на время ожидания (системы с нетерпеливыми заявками), поведение при переполнении (отказ или ожидание).

2. Механизм обслуживания:

- *Закон распределения времени обслуживания*.
- *Режим работы*: индивидуальная или групповая обработка.
- *Зависимость от состояния*: меняется ли скорость обслуживания в зависимости от длины очереди.

3. Структурная организация:

- *Число каналов обслуживания (c)*: одноканальные и многоканальные системы.
- *Конфигурация очередей*: общая очередь для всех каналов или отдельные очереди к каждому серверу.
- *Емкость системы (K)*: ограничение на суммарное число заявок (на обслуживании + в очереди).

4. Дисциплина обслуживания (Queue Discipline):

- **FCFS** (First Come, First Served) — в порядке поступления (FIFO).
- **LCFS** (Last Come, First Served) — последним пришел, первым обслужен (стек).
- **RSS** (Random Service Selection) — случайный выбор заявки из очереди.
- **PS** (Processor Sharing) — одновременное обслуживание всех заявок с разделением ресурса.
- **Priority** — наличие приоритетных классов (с вытеснением или без).

Нотация Кендалла

Стандартная запись для кодирования параметров СМО имеет вид строки с разделителями:

$$A | B | c | K | N | Z$$

где:

- A — распределение интервалов между поступлениями заявок;
- B — распределение времени обслуживания;

- c — число обслуживающих приборов (серверов);
- K — емкость системы (по умолчанию ∞);
- N — размер популяции источника заявок (по умолчанию ∞);
- Z — дисциплина обслуживания (по умолчанию FCFS).

! Замечание !

Для обозначения вероятностных распределений (A и B) используются следующие сокращения:


- M (Markovian) — экспоненциальное распределение (пуассоновский поток);
- D (Deterministic) — детерминированное (постоянное) время;
- E_k — распределение Эрланга k -го порядка;
- G (General) — произвольное распределение.

Пример: Примеры нотации

1. $M|M|1$ — простейшая система: пуассоновский вход, экспоненциальное обслуживание, один канал, бесконечная очередь.
2. $M|D|10$ — пуассоновский вход, фиксированное время обслуживания, 10 каналов.
3. $M|G|1|\infty|PS$ — одноканальная система с разделением процессора и произвольным временем обслуживания.

3.3 Формула Литтла

Рассмотрим произвольную систему массового обслуживания как «черный ящик», в который поступает поток заявок, и из которого выходят обработанные заявки.



Введем формальные определения основных характеристик функционирования системы. Пусть $A^{(k)}$ — момент поступления k -й заявки в систему ($k \in \mathbb{N}$), причем $0 \leq A^{(1)} \leq A^{(2)} \leq \dots$. Обозначим через $A(t)$ число заявок,

поступивших в систему за интервал $[0, t)$.

Пусть $W^{(k)}$ — время пребывания k -й заявки в системе (время ожидания + время обслуживания). Тогда момент выхода k -й заявки: $D^{(k)} = A^{(k)} + W^{(k)}$.

Случайный процесс $N(t)$, характеризующий число заявок в системе в момент времени t , определяется как количество таких индексов k , для которых заявка уже поступила, но еще не покинула систему:

$$N(t) = \sum_{k=1}^{\infty} \mathbb{I} \left(A^{(k)} \leq t < A^{(k)} + W^{(k)} \right).$$

Предположим, что рассматриваемая система функционирует в установившемся (стационарном) режиме. Определим средние характеристики через пределы по времени и по числу заявок.

1. **Интенсивность входного потока (λ):** предел отношения числа поступивших заявок к длительности интервала наблюдения:

$$\lambda \doteq \lim_{t \rightarrow \infty} \frac{A(t)}{t}.$$

2. **Среднее время пребывания (W):** среднее арифметическое времен пребывания первых k заявок при $k \rightarrow \infty$:

$$W \doteq \lim_{k \rightarrow \infty} \frac{1}{k} \sum_{i=1}^k W^{(i)}.$$

3. **Среднее число заявок (L):** усредненное по времени значение процесса $N(t)$:

$$L \doteq \lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T N(t) dt.$$

Закон Литтла

Если для системы массового обслуживания существуют конечные пределы интенсивности входящего потока λ и среднего времени пребывания заявки W , то существует и предел среднего числа заявок в системе L , причем справедливо равенство:

$$L = \lambda \cdot W.$$

! Замечание !

Фундаментальная ценность закона Литтла заключается в его абсолютной универсальности. В формулировке теоремы не фигурируют ни законы распределения входящего потока и времени обслуживания, ни число каналов, ни дисциплина очереди (FCFS, LCFS, PS и др.). Тожество связывает исключительно асимптотические средние характеристики.

Доказательство. Строгое аналитическое доказательство для систем с произвольной структурой сопряжено с громоздкими техническими деталями. Однако физический смысл закона прозрачно иллюстрируется геометрическим подходом.


1. **Базовые допущения и геометрическая интерпретация.** Для начала предположим, что систе-

ма функционирует по дисциплине FCFS (заявки покидают систему в порядке поступления), а в моменты времени $t = 0$ и $t = T$ система гарантированно пуста.

Вспомним, как мы ввели считающие процессы $A(t)$ и $D(t)$:

- $A(t)$ — суммарное число заявок, поступивших в систему на интервале $[0, t)$;
- $D(t)$ — суммарное число заявок, покинувших систему на интервале $[0, t)$.

Тогда число заявок, находящихся в системе в произвольный момент времени t , определяется разностью $N(t) = A(t) - D(t)$. Пусть за время T через систему прошло ровно N заявок ($A(T) = D(T) = N$).



2. Интегральное тождество. Рассмотрим площадь фигуры, заключенной между графиками $A(t)$ и $D(t)$. С одной стороны, интегрируя по вертикали, эта площадь равна $\int_0^T (A(t) - D(t))dt$. С другой стороны, разбивая фигуру на горизонтальные полосы, длина каждой k -й полосы в точности равна времени пребывания k -й заявки в системе $W^{(k)}$. Следовательно, справедливо тождество суммарного времени:

$$\int_0^T N(t)dt = \sum_{k=1}^N W^{(k)}.$$

3. Асимптотический переход. Поделим обе части полученного тождества на T и умножим правую часть на $\frac{N}{N}$:

$$\underbrace{\frac{1}{T} \int_0^T N(t)dt}_{L(T)} = \underbrace{\frac{N}{T}}_{\lambda(T)} \cdot \underbrace{\left(\frac{1}{N} \sum_{k=1}^N W^{(k)} \right)}_{W(N)}.$$

Устремляя $T \rightarrow \infty$ (а следовательно, и $N \rightarrow \infty$), мы немедленно получаем искомое соотношение:

$$\lim_{T \rightarrow \infty} L(T) = \lim_{T \rightarrow \infty} \lambda(T) \cdot \lim_{N \rightarrow \infty} W(N) \implies L = \lambda \cdot W.$$

4. Обобщение на произвольную дисциплину очереди. Покажем, что предположение о порядке выхода заявок (FCFS) не является существенным. Пусть $A^{(k)}$ — момент поступления, а $D^{(k)}$ — момент выхода k -й заявки (при этом индексы выхода могут не быть монотонными). Факт нахождения k -й заявки в системе в момент времени t описывается индикаторной функцией $\mathbb{I}(A^{(k)} \leq t < D^{(k)})$. Тогда общее число заявок:

$$N(t) = \sum_{k=1}^N \mathbb{I}(A^{(k)} \leq t < D^{(k)}).$$

Интегрируя $N(t)$ по времени на отрезке $[0, T]$ и меняя местами сумму и интеграл, получаем:

$$\int_0^T N(t) dt = \int_0^T \left(\sum_{k=1}^N \mathbb{I}(A^{(k)} \leq t < D^{(k)}) \right) dt = \sum_{k=1}^N \int_0^T \mathbb{I}(A^{(k)} \leq t < D^{(k)}) dt.$$

Поскольку интеграл от индикатора на отрезке $[0, T]$ равен длине интервала пребывания заявки в системе (с учетом того, что система пуста в момент T), он в точности равен $W^{(k)}$. Таким образом, интегральное тождество $\int_0^T N(t) dt = \sum_{k=1}^N W^{(k)}$ инвариантно относительно дисциплины обслуживания.

5. Краевые эффекты. Откажемся от требования пустоты системы в момент T . Если в момент T в системе остаются необработанные заявки, то площадь фигуры даст погрешность $\varepsilon(T)$, равную суммарному времени, которое эти «зависшие» заявки провели в системе до момента T . Однако в стационарном (эргодическом) режиме очередь не растет бесконечно. Следовательно, остаточная площадь $\varepsilon(T)$ ограничена величиной порядка $O(1)$, и при предельном переходе вклад краевых эффектов исчезает:

$$\lim_{T \rightarrow \infty} \frac{\varepsilon(T)}{T} = 0.$$

Теорема полностью доказана. ■

Глава 4

Лекция 4. Свойство PASTA и система M|M|1


4.1 Применение формулы Литтла и соотношения в системах G/G/c

Формула Литтла $L = \lambda W$ является универсальным инструментом, однако её применение требует четкого определения границ рассматриваемой системы («черного ящика»). Рассмотрим канонические примеры, демонстрирующие гибкость этого закона.

Пример: Вариативность границ системы

Рассмотрим стандартную одноканальную СМО. Закон Литтла можно применить к разным подсистемам, получая различные физические характеристики.


1. **Система в целом (Очередь + Сервер).** Пусть «черный ящик» охватывает и буфер ожидания, и прибор обслуживания.



В этом случае L — среднее число заявок в системе (в очереди и на обслуживании), W — среднее время пребывания. Закон Литтла:

$$L = \lambda \cdot W.$$

2. **Только очередь.** Рассмотрим подсистему, включающую только буфер ожидания. Сервер в данном контексте является внешней средой.




Среднее число заявок в очереди L_q связано со средним временем ожидания W_q соотношением:

$$L_q = \lambda \cdot W_q.$$

3. **Только сервер (канал обслуживания).** Рассмотрим систему, состоящую из одного прибора. Емкость такой системы равна 1. Пусть p_0 — вероятность того, что система пуста (сервер свободен). Тогда среднее число заявок в такой системе (обозначим L_s) равно вероятности застать сервер

занятым:

$$L_s = 0 \cdot p_0 + 1 \cdot (1 - p_0) = 1 - p_0.$$



Среднее время пребывания в сервере равно среднему времени обслуживания: $W_s = \mathbb{E}[S] = \frac{1}{\mu}$. Применяя формулу Литтла $L_s = \lambda W_s$, получаем фундаментальную связь для одноканальной системы:

$$1 - p_0 = \lambda \cdot \mathbb{E}[S] = \frac{\lambda}{\mu}.$$

Это означает, что вероятность занятости сервера равна коэффициенту загрузки $\rho = \lambda/\mu$.

! Замечание !

Для систем с ограниченной очередью и потерями формула Литтла применяется к потоку заявок, фактически попавших в систему. Если p_B — вероятность отказа (блокировки), то эффективная интенсивность входного потока равна:

$$\lambda_{\text{eff}} = \lambda(1 - p_B).$$

Тогда среднее число заявок в системе: $L = \lambda(1 - p_B)W$.

4.1.1 Фундаментальные соотношения для систем G/G/c

Рассмотрим систему общего вида $G/G/c$, где G обозначает произвольное распределение интервалов поступления и времени обслуживания, а c — число каналов. Введем базовые обозначения случайных величин и их моментов.

Параметры нагрузки и эффективности

- λ — интенсивность входящего потока.
- S — случайная величина времени обслуживания заявки.
- $\mu \doteq \frac{1}{\mathbb{E}[S]}$ — интенсивность обслуживания одного канала.
- $r \doteq \lambda \mathbb{E}[S] = \frac{\lambda}{\mu}$ — **интенсивность нагрузки** (измеряется в Эрлангах). Характеризует среднее число заявок, поступающих за время обслуживания одной заявки.
- $\rho \doteq \frac{r}{c} = \frac{\lambda}{c\mu}$ — **коэффициент загрузки** (utilization factor). Для стабильности системы необходимо $\rho < 1$.

Определим характеристики пребывания заявки в системе:

- N, N_q — случайное число заявок в системе и в очереди соответственно.
- $L \doteq \mathbb{E}[N]$, $L_q \doteq \mathbb{E}[N_q]$ — средние значения (матожидания).
- T, T_q — случайное время нахождения заявки в системе и в очереди.
- $W \doteq \mathbb{E}[T]$, $W_q \doteq \mathbb{E}[T_q]$ — средние времена.

Очевидно, что полное время пребывания складывается из времени ожидания и времени обслуживания:

$$T = T_q + S.$$

В силу линейности математического ожидания, аналогичное равенство справедливо для средних величин:

$$W = W_q + \mathbb{E}[S] = W_q + \frac{1}{\mu}.$$

Утв. Для любой системы $G/G/c$ в стационарном режиме среднее число заявок в системе L связано со средним числом заявок в очереди L_q и интенсивностью нагрузки r соотношением:

$$L = L_q + r.$$

Доказательство. Воспользуемся формулой Литтла для системы в целом ($L = \lambda W$) и полученным выше разложением для среднего времени пребывания:

$$L = \lambda W = \lambda \left(W_q + \frac{1}{\mu} \right).$$

Раскроем скобки:

$$L = \underbrace{\lambda W_q}_{(*)} + \underbrace{\frac{\lambda}{\mu}}_{(**)}.$$

Проанализируем слагаемые:

1. По формуле Литтла для очереди, слагаемое $(*)$ равно среднему числу заявок в очереди: $\lambda W_q = L_q$.
2. Слагаемое $(**)$ представляет собой интенсивность нагрузки: $\frac{\lambda}{\mu} = r$.

Таким образом, приходим к искомому равенству $L = L_q + r$. ■

Следствие. Величину $r = L - L_q$ можно интерпретировать как среднее число заявок, находящихся на обслуживании в данный момент времени.

В частном случае одноканальной системы ($c = 1$) среднее число обслуживаемых заявок равно вероятности того, что сервер занят:

$$r = 0 \cdot p_0 + 1 \cdot (1 - p_0) = 1 - p_0.$$

Следовательно, для системы $G/G/1$:

$$\rho = r = 1 - p_0.$$

Это подтверждает интуитивный факт: коэффициент загрузки одноканальной системы равен вероятности её занятости.

4.2 Напоминание: Пуассоновский процесс и порядковые статистики

Перед переходом к доказательству свойства PASTA необходимо зафиксировать определения базового стохастического процесса теории массового обслуживания и вспомогательный результат из математической статистики.

Пуассоновский процесс

Пуассоновской случайной величиной $\xi \sim \text{Pois}(\lambda)$ называется величина с распределением:

$$\mathbb{P}(\xi = n) = \frac{\lambda^n}{n!} e^{-\lambda}, \quad \mathbb{E}\xi = \mathbb{D}\xi = \lambda.$$

Пуассоновским процессом (поток событий) $\{N(t), t \geq 0\}$ с интенсивностью λ называется считающий процесс, удовлетворяющий следующим аксиомам:

1. **Начальное условие:** $N(0) = 0$.
2. **Ординарность:** Вероятность появления двух и более событий за малый промежуток времени пренебрежимо мала:

$$\mathbb{P}(N(t + \Delta t) - N(t) \geq 2) = o(\Delta t).$$

Вероятность появления ровно одного события асимптотически линейна:

$$\mathbb{P}(N(t + \Delta t) - N(t) = 1) = \lambda \Delta t + o(\Delta t).$$

3. **Отсутствие последствия:** Процесс имеет независимые приращения. Число событий на непересекающихся интервалах времени суть независимые случайные величины.
4. **Стационарность (однородность):** Распределение числа событий зависит только от длины интервала, а не от его положения на оси времени.

Для дальнейшего анализа нам потребуется лемма о совместном распределении упорядоченных случайных величин.

Совместная плотность порядковых статистик

Пусть $X_1, \dots, X_n$ — независимые одинаково распределённые (i.i.d.) случайные величины с функцией плотности $f(x)$ и функцией распределения $F(x)$. Рассмотрим вариационный ряд (упорядоченные по возрастанию значения):

$$X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}.$$

Тогда совместная плотность вероятности вектора $(X_{(1)}, \dots, X_{(n)})$ имеет вид:

$$f_{X_{(1)}, \dots, X_{(n)}}(y_1, \dots, y_n) = \begin{cases} n! \cdot \prod_{i=1}^n f(y_i), & \text{если } y_1 < y_2 < \dots < y_n, \\ 0, & \text{иначе.} \end{cases}$$

Доказательство. Рассмотрим вероятность попадания упорядоченных величин в непересекающиеся интервалы. Пусть $y_1 < x_1 < y_2 < x_2 < \dots < y_n < x_n$. Обозначим искомое событие как A :

$$A = \{y_1 < X_{(1)} \leq x_1, y_2 < X_{(2)} \leq x_2, \dots, y_n < X_{(n)} \leq x_n\}.$$

Поскольку исходные величины X_i непрерывны, вероятность совпадения значений равна нулю, и мы можем рассматривать строгое неравенство $X_{(1)} < \dots < X_{(n)}$.

Любая реализация, удовлетворяющая условию A , соответствует ровно одной перестановке исходных величин $X_1, \dots, X_n$, так как интервалы $(y_i, x_i]$ не пересекаются. Всего существует $n!$ возможных перестановок индексов $\pi \in \mathfrak{S}_n$. Событие A можно представить как объединение несовместных событий по всем перестановкам:

$$A = \bigsqcup_{\pi \in \mathfrak{S}_n} \{y_1 < X_{\pi(1)} \leq x_1, \dots, y_n < X_{\pi(n)} \leq x_n\}.$$

В силу того, что X_i независимы и одинаково распределены, вероятность каждого слагаемого в объединении одинакова и равна произведению вероятностей попадания в интервалы:

$$\mathbb{P}(y_i < X_i \leq x_i) = F(x_i) - F(y_i).$$

Суммируя по всем $n!$ перестановкам, получаем:

$$\mathbb{P}(A) = n! \cdot \prod_{i=1}^n (F(x_i) - F(y_i)).$$

С другой стороны, эта же вероятность выражается через интеграл от совместной плотности:

$$\mathbb{P}(A) = \int_{y_1}^{x_1} \dots \int_{y_n}^{x_n} f_{X_{(1)}, \dots, X_{(n)}}(u_1, \dots, u_n) du_n \dots du_1.$$

Чтобы найти плотность, необходимо взять смешанную частную производную от вероятности по верхним пределам интегрирования $x_1, \dots, x_n$ (при стремлении $y_i \rightarrow x_i$):

$$f_{X_{(1)}, \dots, X_{(n)}}(x_1, \dots, x_n) = \frac{\partial^n}{\partial x_1 \dots \partial x_n} \left[n! \cdot \prod_{i=1}^n (F(x_i) - F(y_i)) \right].$$

Поскольку каждый множитель $(F(x_i) - F(y_i))$ зависит только от своего x_i , производная произведения равна произведению производных. Учитывая, что $F'(x) = f(x)$, окончательно получаем:

$$f_{X_{(1)}, \dots, X_{(n)}}(x_1, \dots, x_n) = n! \cdot \prod_{i=1}^n f(x_i),$$

при условии упорядоченности аргументов.

4.3 Связь пуассоновского потока и равномерного распределения

Ключевым свойством пуассоновского процесса, лежащим в основе многих методов теории массового обслуживания, является его «абсолютная случайность» на любом конечном интервале. Математически это выражается в том, что при фиксированном числе событий их моменты распределены равномерно.

Об условном распределении моментов наступления событий

Пусть $\{N(t), t \geq 0\}$ — пуассоновский процесс. Зафиксируем интервал $[0, T]$ и предположим, что на нем произошло ровно k событий ($N(T) = k$). Обозначим моменты этих событий через $0 < \tau_1 < \tau_2 < \dots < \tau_k < T$.

Тогда совместное распределение вектора $(\tau_1, \dots, \tau_k)$ совпадает с распределением k **порядковых статистик** независимых случайных величин, равномерно распределенных на отрезке $[0, T]$.

Доказательство. Рассмотрим совместную плотность распределения упорядоченных моментов времени $0 < t_1 < t_2 < \dots < t_k < T$. По определению плотности вероятности:

$$f(t_1, \dots, t_k \mid N(T) = k) dt_1 \dots dt_k \approx \mathbb{P}(t_1 \leq \tau_1 < t_1 + dt_1, \dots, t_k \leq \tau_k < t_k + dt_k \mid N(T) = k).$$

По формуле условной вероятности $\mathbb{P}(A \mid B) = \frac{\mathbb{P}(AB)}{\mathbb{P}(B)}$, вычислим числитель и знаменатель отдельно.

1. Знаменатель (условие): Вероятность того, что на всем интервале $[0, T]$ произошло ровно k событий, подчиняется распределению Пуассона:

$$\mathbb{P}(N(T) = k) = \frac{(\lambda T)^k}{k!} e^{-\lambda T}.$$

2. Числитель (совместное событие): Событие в числителе AB означает, что траектория процесса реализовалась строго определенным образом. Разобьем интервал $[0, T]$ на последовательность непересекающихся промежутков:

- На отрезке $[0, t_1)$ событий не было (0 событий).
- На малом отрезке $[t_1, t_1 + dt_1)$ произошло ровно 1 событие.
- На отрезке $[t_1 + dt_1, t_2)$ событий не было.
- ...
- На отрезке $[t_k, t_k + dt_k)$ произошло ровно 1 событие.
- На оставшемся отрезке $[t_k + dt_k, T]$ событий не было.

В силу свойства **отсутствия последействия** (независимости приращений), вероятность такого сложного события равна произведению вероятностей на каждом участке. Учитывая, что $\mathbb{P}(N(\Delta t) = 0) = e^{-\lambda \Delta t}$ и $\mathbb{P}(N(dt) = 1) \approx \lambda dt \cdot e^{-\lambda dt} \approx \lambda dt$, запишем:

$$\mathbb{P}(AB) \approx \underbrace{e^{-\lambda t_1}}_{[0, t_1)} \cdot \underbrace{\lambda dt_1}_{[t_1, t_1 + dt_1)} \cdot \underbrace{e^{-\lambda(t_2 - t_1)}}_{(t_1, t_2)} \cdot \dots \cdot \underbrace{\lambda dt_k}_{[t_k, t_k + dt_k)} \cdot \underbrace{e^{-\lambda(T - t_k)}}_{(t_k, T)}.$$

(Здесь мы пренебрегли слагаемыми порядка dt в показателях экспонент для интервалов пустоты).

Сгруппируем множители. Произведение λ дает $\lambda^k dt_1 \dots dt_k$. Показатели экспонент складываются, образуя полную длину интервала:

$$t_1 + (t_2 - t_1) + (t_3 - t_2) + \dots + (T - t_k) = T.$$

Таким образом, вероятность совместного события равна:

$$\mathbb{P}(AB) = \lambda^k e^{-\lambda T} dt_1 \dots dt_k.$$

3. Итоговая плотность: Подставим найденные выражения в формулу условной вероятности:

$$f(t_1, \dots, t_k \mid k) dt_1 \dots dt_k = \frac{\lambda^k e^{-\lambda T} dt_1 \dots dt_k}{\frac{(\lambda T)^k}{k!} e^{-\lambda T}}.$$

Сокращая λ^k и $e^{-\lambda T}$, получаем окончательный результат:


$$f(t_1, \dots, t_k \mid k) = \frac{k!}{T^k}, \quad \text{при } 0 < t_1 < \dots < t_k < T.$$

Это выражение в точности совпадает с плотностью k порядковых статистик равномерного распределения $\mathcal{U}[0, T]$, полученной в предыдущей лемме. ■

4.3.1 Интерпретация

Полученный результат позволяет дать наглядную интерпретацию поведения пуассоновского потока. Представим, что мы бросаем k дротиков в временную ось $[0, T]$ абсолютно независимо и «вслепую» (равномерное распределение).

- Пусть координаты попадания дротиков: $U_1, U_2, \dots, U_k$. Это независимые, но **неупорядоченные** величины (U_1 может быть больше U_2).
- Реальные события в потоке всегда происходят последовательно. Согласно доказанной теореме, моменты событий пуассоновского потока $\tau_1, \dots, \tau_k$ соответствуют **отсортированным** координатам дротиков $U_{(1)} \leq U_{(2)} \leq \dots \leq U_{(k)}$.



Вывод: Положение событий пуассоновского потока на оси времени «максимально случайно». У событий нет склонности к группированию или, наоборот, к регулярному следованию друг за другом. Это обеспечивает «непредвзятость» наблюдения системы в моменты поступления заявок.

4.4 Свойство PASTA

Доказанная теорема является фундаментом для одного из самых известных эвристических принципов теории массового обслуживания — свойства PASTA (*Poisson Arrivals See Time Averages*).

PASTA

Пусть $X(t)$ — случайный процесс, описывающий состояние системы (например, число заявок в очереди). Если входящий поток заявок является пуассоновским, то предельное распределение состояния системы, которое «видит» поступающая заявка, совпадает с предельным распределением состояния системы во времени:

$$\lim_{n \rightarrow \infty} \mathbb{P}(X(\tau_n - 0) = j) = \lim_{t \rightarrow \infty} \mathbb{P}(X(t) = j).$$

«Пуассоновские заявки видят временные средние (видят среднее поведение системы)».

Физический смысл: Поскольку пуассоновские события разбросаны по оси времени равномерно (как показано в теореме 6), они сканируют состояние системы в случайные моменты времени. Сам факт связи с равномерным распределением означает, что пуассоновский поток не имеет "предпочтительных" моментов времени или внутренней периодичности. Это означает, что входящий поток не «подгадывает» моменты, когда система пуста или перегружена (как это мог бы делать регулярный поток, синхронизированный с обслуживанием). Поэтому, в частности, средние характеристики системы, наблюдаемые в моменты поступления заявок, совпадают со средними характеристиками системы в целом.

! Замечание !

Это свойство не выполняется для других потоков. Например, если заявки поступают строго периодически (детерминированный поток D) каждые 10 минут, а обслуживание занимает ровно 9 минут, то каждая новая заявка всегда будет видеть систему свободной ($X(\tau_n) = 0$), хотя 90% времени система занята. Пуассоновский поток лишен такой «синхронизации».

4.5 Система M|M|1

Рассмотрим классическую одноканальную систему массового обслуживания с простейшим входным потоком и показательным временем обслуживания. В нотации Кендалла она обозначается как $M|M|1|\infty$.

▽ **Утв.** Пусть $X(t)$ — число заявок в системе в момент времени t . Поскольку входной поток пуассоновский, а обслуживание экспоненциальное, процесс $X(t)$ является **процессом рождения и гибели** со

следующими параметрами:


- Интенсивность рождения (поступления): $\lambda_n = \lambda$ для всех $n \geq 0$.
- Интенсивность гибели (обслуживания): $\mu_n = \mu$ для всех $n \geq 1$ (при $n = 0$ обслуживание невозможно).

! Замечание !

Важно отметить, что свойства конечных систем (например, $M|M|1|K$) нельзя автоматически переносить на бесконечные системы путем предельного перехода $K \rightarrow \infty$ без дополнительного анализа устойчивости. В конечной цепи стационарное распределение существует при любых λ и μ . В бесконечной цепи — только при условии $\lambda < \mu$, как будет показано далее.

Граф состояний и уравнения баланса

Построим диаграмму интенсивностей переходов. Состояния системы соответствуют числу заявок $S = \{0, 1, 2, \dots\}$.



Для нахождения стационарных вероятностей $p_n = \lim_{t \rightarrow \infty} \mathbb{P}(X(t) = n)$ воспользуемся принципом локального баланса («поток через разрез между состояниями должен быть равен нулю»).

Для любого разреза между состояниями n и $n + 1$ поток вероятности слева направо (рождение) должен уравниваться потоком справа налево (гибель):

$$\lambda p_n = \mu p_{n+1}, \quad n \geq 0.$$

Отсюда получаем рекуррентное соотношение:

$$p_{n+1} = \frac{\lambda}{\mu} p_n.$$

Введем коэффициент загрузки системы $\rho \doteq \frac{\lambda}{\mu}$. Тогда:

$$p_{n+1} = \rho p_n \implies p_n = \rho^n p_0.$$

Условие эргодичности и финальное распределение

Для существования стационарного распределения необходимо выполнение условия нормировки $\sum p_n = 1$. Подставим выражение через p_0 :

$$\sum_{n=0}^{\infty} p_n = \sum_{n=0}^{\infty} p_0 \rho^n = p_0 \sum_{n=0}^{\infty} \rho^n = 1.$$

Данный ряд является геометрической прогрессией. Он сходится тогда и только тогда, когда знаменатель прогрессии по модулю меньше единицы:

$$\rho < 1 \iff \lambda < \mu.$$

Если условие выполнено, сумма ряда равна $\frac{1}{1-\rho}$, откуда находим вероятность простоя системы:

$$p_0 \cdot \frac{1}{1-\rho} = 1 \implies p_0 = 1 - \rho.$$

Заметим, что этот результат совпадает с формулой $p_0 = 1 - \rho$, выведенной ранее для системы общего вида $G|G|1$ с использованием закона Литтла.

Распределение числа заявок в M|M|1

Если интенсивность поступления заявок меньше интенсивности обслуживания ($\lambda < \mu$), то число заявок в системе $M|M|1$ в стационарном режиме имеет **геометрическое распределение** с параметром $1 - \rho$:

$$p_n = (1 - \rho)\rho^n, \quad n = 0, 1, 2, \dots$$

Следствие. Если $\rho \geq 1$, очередь растет неограниченно, стационарного режима не существует, и $p_n \rightarrow 0$ для любого фиксированного n (вероятность застать конечное число заявок стремится к нулю).

Глава 5

Лекция 5. Системы M|M|1 и M|M|с

5.1 Характеристики эффективности системы M|M|1

Ранее было установлено, что стационарное распределение вероятностей состояний классической одноканальной системы M|M|1 существует при условии $\rho = \frac{\lambda}{\mu} < 1$ и задается геометрическим законом: $p_n = (1 - \rho)\rho^n$. Опираясь на этот результат, определим ключевые макроскопические метрики эффективности функционирования системы.

▽ **Утв. [Стационарные характеристики системы M|M|1]** Для одноканальной системы массового обслуживания с пуассоновским входным потоком интенсивности λ и экспоненциальным временем обслуживания интенсивности μ при $\lambda < \mu$ справедливы следующие соотношения:

- Среднее число заявок в системе: $L = \frac{\rho}{1-\rho}$.
- Среднее число заявок в очереди: $L_q = \frac{\rho^2}{1-\rho}$.
- Среднее время пребывания заявки в системе: $W = \frac{1}{\mu-\lambda}$.
- Среднее время ожидания заявки в очереди: $W_q = \frac{\rho}{\mu-\lambda}$.

Доказательство. 1. Среднее число заявок в системе (L). По определению математического ожидания дискретной случайной величины N имеем:

$$L = \mathbb{E}[N] = \sum_{n=0}^{\infty} n \cdot p_n = (1 - \rho) \sum_{n=0}^{\infty} n \rho^n.$$

Для вычисления суммы ряда воспользуемся методом дифференцирования по параметру ρ . Вынесем ρ за знак суммы:

$$\sum_{n=0}^{\infty} n \rho^n = \rho \sum_{n=1}^{\infty} n \rho^{n-1} = \rho \frac{\partial}{\partial \rho} \left(\sum_{n=1}^{\infty} \rho^n \right).$$

Поскольку сумма бесконечной геометрической прогрессии равна $\frac{\rho}{1-\rho}$, находим производную:

$$\frac{\partial}{\partial \rho} \left(\frac{\rho}{1-\rho} \right) = \frac{1 \cdot (1-\rho) - \rho \cdot (-1)}{(1-\rho)^2} = \frac{1}{(1-\rho)^2}.$$

Подставляя полученный результат в исходное выражение для L , получаем:

$$L = (1 - \rho) \cdot \rho \cdot \frac{1}{(1-\rho)^2} = \frac{\rho}{1-\rho} = \frac{\lambda}{\mu - \lambda}.$$

2. Среднее число заявок в очереди (L_q). Длина очереди N_q связана с общим числом заявок соотношением $N_q = \max(0, N - 1)$. Используя линейность математического ожидания:

$$L_q = \mathbb{E}[N_q] = \sum_{n=1}^{\infty} (n-1)p_n = \sum_{n=1}^{\infty} n p_n - \sum_{n=1}^{\infty} p_n = \mathbb{E}[N] - (1 - p_0).$$

Так как вероятность простоя системы $p_0 = 1 - \rho$, то $1 - p_0 = \rho$. Отсюда:

$$L_q = L - \rho = \frac{\rho}{1 - \rho} - \rho = \frac{\rho - \rho(1 - \rho)}{1 - \rho} = \frac{\rho^2}{1 - \rho} = \frac{\lambda^2}{\mu(\mu - \lambda)}.$$

3. Временные характеристики (W и W_q). Применим формулу Литтла ($L = \lambda W$):

$$W = \frac{L}{\lambda} = \frac{\lambda}{\lambda(\mu - \lambda)} = \frac{1}{\mu - \lambda}.$$

Аналогично для очереди ($L_q = \lambda W_q$):

$$W_q = \frac{L_q}{\lambda} = \frac{\lambda^2}{\lambda\mu(\mu - \lambda)} = \frac{\lambda}{\mu(\mu - \lambda)}.$$



Отдельный интерес представляет исследование длины очереди при условии, что она физически существует (поступающая заявка застает прибор занятым).

Следствие. Среднее число заявок в очереди при условии, что очередь не пуста, равно:

$$L'_q = \frac{1}{1 - \rho}.$$

Доказательство. Введем условное математическое ожидание $L'_q = \mathbb{E}[N_q \mid N_q > 0]$. Очередь не пуста, когда в системе находится $n \geq 2$ заявок. Вероятность этого события:

$$\mathbb{P}(N \geq 2) = 1 - p_0 - p_1 = 1 - (1 - \rho) - (1 - \rho)\rho = \rho^2.$$

По определению условного математического ожидания:

$$L'_q = \sum_{n=2}^{\infty} (n-1) \frac{p_n}{\mathbb{P}(N \geq 2)} = \frac{1}{\rho^2} \sum_{n=2}^{\infty} (n-1)p_n.$$


Ряд в числителе совпадает с безусловным ожиданием L_q (так как при $n = 1$ слагаемое зануляется):

$$L'_q = \frac{L_q}{\rho^2} = \frac{1}{\rho^2} \cdot \frac{\rho^2}{1 - \rho} = \frac{1}{1 - \rho}.$$




! Замечание !

Зависимость метрик L, L_q, W, W_q от коэффициента загрузки ρ имеет гиперболический характер с вертикальной асимптотой при $\rho = 1$. Это означает неограниченный рост очередей и задержек при приближении загрузки к 100%.



Число заявок в системе и очереди



Временные характеристики

Распределение времени ожидания и пребывания в системе M|M|1

До сих пор макроскопические характеристики системы вычислялись без учета дисциплины обслуживания. Однако для анализа распределения времени ожидания конкретной заявки необходимо зафиксировать дисциплину очереди. Предположим, что заявки обслуживаются в порядке поступления (FCFS — First-Come, First-Served).

Обозначим через T_q случайную величину времени ожидания заявки в очереди, а через T — полное время ее пребывания в системе. Соответствующие функции распределения задаются как $W_q(t) = \mathbb{P}(T_q \leq t)$ и $W(t) = \mathbb{P}(T \leq t)$.

▽ **Утв. [Функции распределения времени задержки M|M|1]** Для системы M|M|1 с дисциплиной обслуживания FCFS функции распределения времени ожидания и времени пребывания имеют вид:

$$W_q(t) = \begin{cases} 0, & t < 0, \\ 1 - \rho, & t = 0, \\ 1 - \rho e^{-(\mu - \lambda)t}, & t > 0; \end{cases}$$

$$W(t) = \begin{cases} 0, & t \leq 0, \\ 1 - e^{-(\mu - \lambda)t}, & t > 0. \end{cases}$$

Доказательство. Случайная величина T_q имеет смешанное распределение. Пусть N — число заявок в системе в момент поступления новой заявки. Применим формулу полной вероятности:

$$W_q(t) = \mathbb{P}(T_q \leq t) = \sum_{n=0}^{\infty} \mathbb{P}(T_q \leq t \mid N = n) \mathbb{P}(N = n).$$

В силу свойства PASTA вероятности состояний в момент прибытия совпадают со стационарными: $\mathbb{P}(N = n) = p_n$.

С вероятностью $p_0 = 1 - \rho$ поступающая заявка застаёт систему пустой ($N = 0$) и немедленно прини-

мается к обслуживанию. В этом случае время ожидания равно нулю, и $\mathbb{P}(T_q \leq t \mid N = 0) = 1$ для любого $t \geq 0$. Отсюда возникает дискретный скачок функции распределения в нуле:

$$W_q(0) = \mathbb{P}(T_q = 0) = p_0 = 1 - \rho.$$

Пусть $t > 0$ и $n \geq 1$. Поскольку рассматривается FCFS, заявка перейдет к обслуживанию за время $\leq t$, если суммарное время обслуживания всех n заявок, находящихся перед ней, не превзойдет t . Так как времена обслуживания независимы и экспоненциально распределены, время суммарного обслуживания n заявок подчиняется распределению Эрланга порядка n с плотностью $f_n(x) = \frac{\mu^n}{(n-1)!} x^{n-1} e^{-\mu x}$. Таким образом:

$$\mathbb{P}(T_q \leq t \mid N = n) = \int_0^t f_n(x) dx.$$

Подставляя полученные выражения в формулу полной вероятности, имеем:

$$W_q(t) = 1 - \rho + \sum_{n=1}^{\infty} p_n \int_0^t f_n(x) dx = 1 - \rho + \sum_{n=1}^{\infty} (1 - \rho) \rho^n \int_0^t \frac{\mu^n x^{n-1}}{(n-1)!} e^{-\mu x} dx.$$

Поменяем порядок суммирования и интегрирования, вынеся независимые от n множители за знак суммы:

$$W_q(t) = 1 - \rho + \int_0^t \mu (1 - \rho) \rho e^{-\mu x} \left(\sum_{n=1}^{\infty} \frac{(\mu \rho x)^{n-1}}{(n-1)!} \right) dx.$$

Сделав замену индекса суммирования $k = n - 1$, замечаем, что ряд в скобках сводится к разложению экспоненты:

$$\sum_{n=1}^{\infty} \frac{(\mu \rho x)^{n-1}}{(n-1)!} = \sum_{k=0}^{\infty} \frac{(\mu \rho x)^k}{k!} = e^{\mu \rho x} = e^{\lambda x}.$$

Подставив свернутый ряд в интеграл, находим:

$$W_q(t) = 1 - \rho + \rho \int_0^t \mu (1 - \rho) e^{-(\mu - \lambda)x} dx = 1 - \rho + \rho \left(1 - e^{-(\mu - \lambda)t} \right) = 1 - \rho e^{-(\mu - \lambda)t}.$$


Проверим согласованность результата, вычислив математическое ожидание времени ожидания через интеграл от функции надежности:

$$W_q = \mathbb{E}[T_q] = \int_0^{\infty} (1 - W_q(t)) dt = \int_0^{\infty} \rho e^{-(\mu - \lambda)t} dt = \frac{\rho}{\mu - \lambda}.$$

Полученное значение совпадает с формулой, выведенной ранее из закона Литтла.

Для функции распределения полного времени пребывания в системе $W(t)$ логика аналогична. Отличие состоит в том, что для ухода заявки из системы к моменту времени t должно завершиться обслуживание $n + 1$ заявок (включая саму прибывшую). Учитывая отсутствие дискретной компоненты в нуле ($W(0) = 0$), суммирование плотности Эрланга порядка $n + 1$ с весами p_n дает строго непрерывное экспоненциальное распределение:

$$W(t) = 1 - e^{-(\mu - \lambda)t}.$$



Сравнение функций распределения времени ожидания и пребывания.

5.2 Многоканальная система обслуживания M|M|c

Обобщим результаты на случай многоканальной системы, состоящей из c идентичных параллельных серверов. На вход поступает пуассоновский поток заявок с интенсивностью λ . Времена обслуживания на серверах независимы и распределены экспоненциально с параметром μ .

Напомним ключевые характеристики нагрузки:

- $r = \frac{\lambda}{\mu}$ — приведенная интенсивность потока (нагрузка в Эрлангах);
- $\rho = \frac{r}{c} = \frac{\lambda}{c\mu}$ — коэффициент загрузки системы.

▽ **Утв. [Стационарное распределение системы M|M|c]** Необходимым и достаточным условием существования стационарного режима является $\rho < 1$. Вероятности состояний p_n задаются формулами:

$$p_n = \begin{cases} \frac{r^n}{n!} p_0, & 0 \leq n < c, \\ \frac{r^n}{c! c^{n-c}} p_0, & n \geq c, \end{cases}$$

где вероятность простоя системы:

$$p_0 = \left(\sum_{n=0}^{c-1} \frac{r^n}{n!} + \frac{r^c}{c!(1-\rho)} \right)^{-1}.$$

Доказательство. Используется общее решение для процессов рождения и гибели. Для $n < c$ интенсивность обслуживания равна $n\mu$, для $n \geq c$ она стабилизируется на уровне $c\mu$. Вывод формул проводится прямой подстановкой интенсивностей в произведение $\prod \frac{\lambda_{i-1}}{\mu_i}$ и суммированием геометрической прогрессии для нахождения константы нормировки p_0 , аналогично тому, как это было сделано ранее для M|M|1. ■

▽ **Утв. [Стационарные характеристики системы M|M|c]** Для многоканальной системы массового обслуживания, состоящей из c приборов, с пуассоновским входным потоком интенсивности λ и экспоненциальным временем обслуживания интенсивности μ при коэффициенте загрузки $\rho = \frac{\lambda}{c\mu} < 1$ справедливы следующие соотношения:

- Среднее число заявок в очереди: $L_q = \frac{p_0 r^c \rho}{c!(1-\rho)^2}$.
- Среднее число заявок в системе: $L = L_q + r = \frac{p_0 r^c \rho}{c!(1-\rho)^2} + r$.
- Среднее время ожидания заявки в очереди: $W_q = \frac{L_q}{\lambda} = \frac{p_0 r^c}{c \cdot c! \mu (1-\rho)^2}$.
- Среднее время пребывания заявки в системе: $W = W_q + \frac{1}{\mu} = \frac{p_0 r^c}{c \cdot c! \mu (1-\rho)^2} + \frac{1}{\mu}$.

где $r = \frac{\lambda}{\mu}$ — приведенная интенсивность потока, а p_0 — вероятность простоя системы.

Доказательство. 1. Среднее число заявок в очереди (L_q). По определению математического ожидания дискретной случайной величины длины очереди $N_q = \max(0, N - c)$ имеем:

$$L_q = \mathbb{E}[N_q] = \sum_{n=c}^{\infty} (n - c) p_n = \sum_{n=c+1}^{\infty} (n - c) p_n.$$

Подставим выражение для вероятностей состояний p_n при $n \geq c$, заданное формулой $p_n = \frac{r^n}{c! c^{n-c}} p_0$, и введем новый индекс суммирования $m = n - c$:

$$L_q = \sum_{m=1}^{\infty} m p_{c+m} = \sum_{m=1}^{\infty} m \frac{r^{c+m}}{c! c^m} p_0.$$

Вынесем независимые от m множители за знак суммы и сгруппируем члены, зависящие от m , используя соотношение $\rho = \frac{r}{c}$:

$$L_q = \frac{p_0 r^c}{c!} \sum_{m=1}^{\infty} m \left(\frac{r}{c}\right)^m = \frac{p_0 r^c}{c!} \sum_{m=1}^{\infty} m \rho^m.$$

Ряд $\sum_{m=1}^{\infty} m \rho^m$ равен $\frac{\rho}{(1-\rho)^2}$. Подставляя это значение, получаем окончательное выражение для длины очереди:

$$L_q = \frac{p_0 r^c \rho}{c!(1-\rho)^2}.$$

2. Временные характеристики (W и W_q). По закону Литтла, примененному непосредственно к подсистеме очереди, среднее время ожидания равно:

$$W_q = \frac{L_q}{\lambda} = \frac{p_0 r^c \rho}{\lambda c!(1-\rho)^2}.$$

Используя определение коэффициента загрузки $\rho = \frac{\lambda}{c\mu}$, заменяем отношение $\frac{\rho}{\lambda}$ на $\frac{1}{c\mu}$:

$$W_q = \frac{p_0 r^c}{c \cdot c! \mu (1-\rho)^2}.$$

Полное время пребывания заявки в системе T складывается из времени ожидания в очереди T_q и времени непосредственного обслуживания. Поскольку время обслуживания экспоненциально с параметром μ , его математическое ожидание равно $\frac{1}{\mu}$. Из линейности математического ожидания следует:

$$W = \mathbb{E}[T] = \mathbb{E}[T_q] + \mathbb{E}[\text{время обслуживания}] = W_q + \frac{1}{\mu} = \frac{p_0 r^c}{c \cdot c! \mu (1 - \rho)^2} + \frac{1}{\mu}.$$

3. Среднее число заявок в системе (L). Применим универсальный закон Литтла к системе в целом ($L = \lambda W$) и подставим найденное выражение для W :

$$L = \lambda W = \lambda \left(W_q + \frac{1}{\mu} \right) = \lambda W_q + \frac{\lambda}{\mu}.$$

Учитывая, что по закону Литтла для очереди $\lambda W_q = L_q$, а по определению $\frac{\lambda}{\mu} = r$, приходим к искомому результату:

$$L = L_q + r = \frac{p_0 r^c \rho}{c! (1 - \rho)^2} + r.$$

Пример: Аналитический расчет характеристик для малого числа каналов

Продemonстрируем зависимость макроскопических метрик от c в явном виде, выразив вероятность простоя p_0 и длину очереди L_q исключительно через коэффициент загрузки ρ . Напомним, что приведенная нагрузка связана с загрузкой соотношением $r = c\rho$.

Случай $c = 1$ (одноканальная СМО): Вероятность простоя вычисляется сворачиванием геометрической прогрессии:

$$p_0 = \left(1 + \frac{\rho}{1 - \rho} \right)^{-1} = (1 - \rho).$$

Подставляя p_0 в общую формулу длины очереди, получаем классический результат:

$$L_q^{(1)} = \frac{(1 - \rho)\rho \cdot \rho}{1!(1 - \rho)^2} = \frac{\rho^2}{1 - \rho}.$$

Случай $c = 2$ (двухканальная СМО): Ряд для нормировочной константы p_0 обрывается на втором слагаемом перед переходом к бесконечной сумме. Подставим $r = 2\rho$:

$$p_0 = \left(1 + \frac{2\rho}{1!} + \frac{(2\rho)^2}{2!(1 - \rho)} \right)^{-1} = \left(1 + 2\rho + \frac{2\rho^2}{1 - \rho} \right)^{-1}.$$

Приведем выражение в скобках к общему знаменателю:

$$1 + 2\rho + \frac{2\rho^2}{1 - \rho} = \frac{1 - \rho + 2\rho - 2\rho^2 + 2\rho^2}{1 - \rho} = \frac{1 + \rho}{1 - \rho} \implies p_0 = \frac{1 - \rho}{1 + \rho}.$$

Подставляя найденное p_0 в формулу для очереди, находим:

$$L_q^{(2)} = \frac{\frac{1 - \rho}{1 + \rho} (2\rho)^2 \rho}{2!(1 - \rho)^2} = \frac{4\rho^3(1 - \rho)}{2(1 + \rho)(1 - \rho)^2} = \frac{2\rho^3}{1 - \rho^2}.$$

Случай $c = 4$ (четырёхканальная СМО): Аналогичные алгебраические преобразования (сумми-


рование четырех членов ряда и прогрессии для остатка) приводят к появлению полиномиальной дроби:

$$p_0 = \frac{1 - \rho}{1 + 3\rho + 4\rho^2 + \frac{8}{3}\rho^3}.$$


Отсюда длина очереди выражается как:

$$L_q^{(4)} = \frac{32\rho^5}{3(1 - \rho) \left(1 + 3\rho + 4\rho^2 + \frac{8}{3}\rho^3\right)}.$$

Именно эти нелинейные полиномиальные соотношения определяют поведение кривых на графиках эффективности. Можно заметить, что при фиксированной загрузке $\rho \rightarrow 1$ наличие дополнительных каналов не меняет порядка асимптоты $O((1 - \rho)^{-1})$, но существенно уменьшает константу перед ней.



Число заявок в системе и очереди



Время пребывания и ожидания

Вероятность задержки

Вероятность того, что поступающая заявка застанет все серверы занятыми и будет вынужден ожидать в очереди, обозначается $C(c, r)$.

▽ Утв. [Формула Эрланга-С] Вероятность задержки заявки вычисляется по формуле:

$$C(c, r) \doteq \mathbb{P}(T_q > 0) = \frac{p_0 r^c}{c!(1 - \rho)}.$$


Доказательство. Заявка вынуждена ждать, если в момент ее прибытия в системе находится $n \geq c$ других заявок. Суммируя вероятности стационарного распределения:

$$\mathbb{P}(T_q > 0) = \sum_{n=c}^{\infty} p_n = \sum_{n=c}^{\infty} \frac{r^n}{c!c^{n-c}} p_0 = \frac{p_0 r^c}{c!} \sum_{m=0}^{\infty} \rho^m = \frac{p_0 r^c}{c!(1 - \rho)}.$$



Это соотношение характеризует эффект масштаба: при фиксированном коэффициенте загрузки ρ система

с большим числом серверов обеспечивает меньшую вероятность задержки, то есть обладает более высокой стабильностью под нагрузкой. Визуализация этого феномена представлена на графике ниже.



Зависимость вероятности ожидания от коэффициента загрузки ρ при различном числе каналов. Все кривые асимптотически стремятся к 1 при $\rho \rightarrow 1$.

Распределение времени ожидания и пребывания в системе M|M|c

Аналогично системе с одним каналом, знание стационарного распределения и вероятности задержки позволяет получить функции распределения времени ожидания $W_q(t)$ и полного времени пребывания в системе $W(t)$ при условии использования дисциплины обслуживания FCFS.

Утв. [Распределение времени ожидания и пребывания в M|M|c] Для многоканальной системы M|M|c с дисциплиной обслуживания FCFS функции распределения времени ожидания $W_q(t) = \mathbb{P}(T_q \leq t)$ и времени пребывания $W(t) = \mathbb{P}(T \leq t)$ задаются выражениями (для $t \geq 0$):

- $W_q(t) = 1 - C(c, \rho)e^{-c\mu(1-\rho)t}$;
- $W(t) = 1 - e^{-\mu t} - \frac{C(c, \rho)}{c(1-\rho) - 1} (e^{-\mu t} - e^{-c\mu(1-\rho)t})$, если $c(1-\rho) \neq 1$.

В сингулярном случае, когда $c(1-\rho) = 1$, распределение полного времени имеет вид:

$$W(t) = 1 - e^{-\mu t} - C(c, \rho)\mu t e^{-\mu t}.$$

Доказательство. Пусть N — число заявок в системе в момент прибытия новой заявки. Применим формулу полной вероятности:

$$W_q(t) = \sum_{n=0}^{\infty} \mathbb{P}(T_q \leq t \mid N = n) p_n.$$

Если $n < c$, заявка немедленно поступает на свободный прибор, следовательно, $T_q = 0$. Сумма стационарных вероятностей для всех состояний до образования очереди равна $1 - \mathbb{P}(T_q > 0) = 1 - C(c, r)$.

Если $n \geq c$, заявка становится в очередь. Пусть $k = n - c \geq 0$ — число заявок, находящихся перед ней в очереди. Для того чтобы наша заявка перешла к обслуживанию, система должна завершить обработку $k + 1$ заявок. Поскольку все c каналов заняты, поток обслуживания является пуассоновским с интенсивностью $c\mu$. Время обработки $k + 1$ заявок распределено по закону Эрланга порядка $k + 1$ с параметром $c\mu$. Плотность этого распределения:

$$f_{k+1}(x) = \frac{(c\mu)^{k+1}}{k!} x^k e^{-c\mu x}.$$

Тогда функция распределения $W_q(t)$ принимает вид:

$$W_q(t) = 1 - C(c, r) + \sum_{k=0}^{\infty} p_{c+k} \int_0^t \frac{(c\mu)^{k+1}}{k!} x^k e^{-c\mu x} dx.$$

Используя свойство стационарных вероятностей $p_{c+k} = p_c \rho^k = C(c, r)(1 - \rho)\rho^k$, поменяем порядок интегрирования и суммирования:

$$W_q(t) = 1 - C(c, r) + \int_0^t C(c, r)(1 - \rho)c\mu e^{-c\mu x} \left(\sum_{k=0}^{\infty} \frac{(c\mu \rho x)^k}{k!} \right) dx.$$

Ряд сходится к экспоненте $e^{c\mu \rho x} = e^{\lambda x}$. Сводя показатели степеней, получаем интеграл:

$$W_q(t) = 1 - C(c, r) + C(c, r) \int_0^t c\mu(1 - \rho)e^{-c\mu(1-\rho)x} dx.$$

Вычисляя интеграл, приходим к требуемому выражению:

$$W_q(t) = 1 - C(c, r) + C(c, r) \left(1 - e^{-c\mu(1-\rho)t} \right) = 1 - C(c, r)e^{-c\mu(1-\rho)t}.$$

Для нахождения $W(t)$ воспользуемся тем, что полное время пребывания $T = T_q + T_{serv}$ есть сумма независимых случайных величин. Покажем, что плотность суммы независимых непрерывных величин X и Y вычисляется как свертка их плотностей. Вероятность попадания суммы в интервал определяется интегралом от совместной плотности по полуплоскости $x + y \leq t$:

$$F_{X+Y}(t) = \mathbb{P}(X + Y \leq t) = \iint_{x+y \leq t} f_{X,Y}(x, y) dx dy.$$

В силу независимости $f_{X,Y}(x, y) = f_X(x)f_Y(y)$. Зафиксируем x и проинтегрируем по y от $-\infty$ до $t - x$:

$$F_{X+Y}(t) = \int_{-\infty}^{\infty} f_X(x) \left(\int_{-\infty}^{t-x} f_Y(y) dy \right) dx = \int_{-\infty}^{\infty} f_X(x) F_Y(t - x) dx.$$

Дифференцируя данное выражение по параметру t , получаем формулу свертки плотностей:

$$f_{X+Y}(t) = \int_{-\infty}^{\infty} f_X(x) f_Y(t - x) dx = (f_X * f_Y)(t).$$

Применим этот результат. Плотность времени обслуживания $f_{serv}(y) = \mu e^{-\mu y}$. Случайная величина T_q принимает значение 0 с вероятностью $1 - C(c, r)$, поэтому ее плотность содержит дискретную компоненту. С использованием функции Дирака плотность времени ожидания записывается как:

$$f_{T_q}(x) = (1 - C(c, r))\delta(x + 0) + C(c, r)c\mu(1 - \rho)e^{-c\mu(1-\rho)x}, \quad x \geq 0.$$

Сдвиг аргумента дельта-функции $x + 0$ означает, что центр распределения смещен бесконечно мало влево от нуля. Это необходимо для обеспечения непрерывности $W(t)$ в нуле справа. Для краткости обозначим $\gamma = c\mu(1 - \rho)$. Подставим плотности в формулу свертки, интегрируя от 0− до t :

$$f_T(t) = \int_{0-}^t [(1 - C(c, r))\delta(x + 0) + C(c, r)\gamma e^{-\gamma x}] \mu e^{-\mu(t-x)} dx.$$

Интеграл распадается на два слагаемых. Первое вычисляется благодаря фильтрующему свойству функции Дирака, второе преобразуется путем вынесения экспоненты от t :

$$f_T(t) = (1 - C(c, r))\mu e^{-\mu t} + C(c, r)\gamma \mu e^{-\mu t} \int_0^t e^{-(\gamma-\mu)x} dx.$$

Рассмотрим общий случай $\gamma \neq \mu$ (то есть $c(1 - \rho) \neq 1$). Вычисляя интеграл, получаем плотность:

$$f_T(t) = (1 - C(c, r))\mu e^{-\mu t} + C(c, r)\frac{\gamma\mu}{\gamma - \mu} (e^{-\mu t} - e^{-\gamma t}).$$

Интегрируя плотность $f_T(\tau)$ по отрезку $[0, t]$, находим функцию распределения полного времени $W(t)$:

$$W(t) = \int_0^t f_T(\tau) d\tau = (1 - C(c, r))(1 - e^{-\mu t}) + C(c, r)\frac{\gamma\mu}{\gamma - \mu} \int_0^t (e^{-\mu\tau} - e^{-\gamma\tau}) d\tau.$$

Беря первообразные, находим:

$$W(t) = (1 - C(c, r))(1 - e^{-\mu t}) + C(c, r)\frac{\gamma}{\gamma - \mu}(1 - e^{-\mu t}) - C(c, r)\frac{\mu}{\gamma - \mu}(1 - e^{-\gamma t}).$$

Сгруппируем слагаемые, содержащие множитель $(1 - e^{-\mu t})$:

$$1 - C(c, r) + C(c, r)\frac{\gamma}{\gamma - \mu} = 1 + C(c, r)\left(\frac{\gamma}{\gamma - \mu} - 1\right) = 1 + C(c, r)\frac{\mu}{\gamma - \mu}.$$

Подставляя это обратно в выражение для $W(t)$ и раскрывая скобки:

$$\begin{aligned} W(t) &= \left(1 + C(c, r)\frac{\mu}{\gamma - \mu}\right)(1 - e^{-\mu t}) - C(c, r)\frac{\mu}{\gamma - \mu}(1 - e^{-\gamma t}) \\ &= 1 - e^{-\mu t} + C(c, r)\frac{\mu}{\gamma - \mu} - C(c, r)\frac{\mu}{\gamma - \mu}e^{-\mu t} - C(c, r)\frac{\mu}{\gamma - \mu} + C(c, r)\frac{\mu}{\gamma - \mu}e^{-\gamma t} \\ &= 1 - e^{-\mu t} - C(c, r)\frac{\mu}{\gamma - \mu}(e^{-\mu t} - e^{-\gamma t}). \end{aligned}$$

Подставляя обратно определение множителя $\frac{\mu}{\gamma - \mu} = \frac{\mu}{c\mu(1-\rho) - \mu} = \frac{1}{c(1-\rho) - 1}$, приходим к итоговой формуле для $W(t)$.


В сингулярном случае вырождения корней $\gamma = \mu$ интеграл в выражении для плотности вырождается в $\int_0^t 1 dx = t$. Плотность принимает вид распределения Эрланга:

$$f_T(t) = (1 - C(c, r))\mu e^{-\mu t} + C(c, r)\mu^2 t e^{-\mu t}.$$

Функция распределения находится интегрированием по частям ($\int \mu^2 \tau e^{-\mu \tau} d\tau = 1 - e^{-\mu t} - \mu t e^{-\mu t}$):

$$\begin{aligned} W(t) &= (1 - C(c, r))(1 - e^{-\mu t}) + C(c, r)(1 - e^{-\mu t} - \mu t e^{-\mu t}) \\ &= (1 - e^{-\mu t}) - C(c, r)\mu t e^{-\mu t}. \end{aligned}$$

CDF времени ожидания (W_q) и пребывания (W) в M/M/c ($\rho = 0.75, \mu = 1$)



5.3 Оптимальный выбор числа каналов и режимы масштабирования

Одной из ключевых задач при проектировании систем массового обслуживания является выбор числа обслуживающих приборов c для заданной нагрузки $r = \lambda/\mu$. Этот выбор определяется компромиссом между качеством обслуживания (минимизацией вероятности ожидания $C(c, r)$) и эффективностью использования ресурсов (максимизацией коэффициента загрузки ρ).

Условие стационарности $c > r$ позволяет представить число каналов в виде $c = r + \Delta$, где $\Delta > 0$ — избыточный ресурс (резерв) производительности.

Пример: Задача масштабирования

Рассмотрим систему M/M/c с нагрузкой $r_0 = 9$ Эрланг и числом каналов $c_0 = 12$. В исходном состоянии коэффициент загрузки $\rho_0 = 0.75$, а вероятность задержки $C(12, 9) \approx 0.266$.

Пусть нагрузка возрастает в 4 раза: $r_{new} = 36$. Необходимо определить новое число каналов c_{new} исходя из различных стратегий управления ресурсами.

Решение. Рассмотрим три асимптотических режима масштабирования при $r \rightarrow \infty$:

1. **Режим качества (Quality Domain, QD).** Фиксируется коэффициент загрузки: $\rho = \text{const} < 1$. Тогда $c_{QD} = r/\rho$. Для $r = 36$ и $\rho = 0.75$ получаем $c = 48$. При $r \rightarrow \infty$ вероятность задержки экспоненциально убывает $C(c, r) \rightarrow 0$. Система обладает избыточной надежностью, что экономически неэффективно из-за низкого использования ресурсов.
2. **Режим эффективности (Efficiency Domain, ED).** Фиксируется абсолютный резерв каналов: $\Delta = c - r = \text{const}$. Тогда $c_{ED} = r + \Delta$. Для $r = 36$ и $\Delta = 3$ получаем $c = 39$. При $r \rightarrow \infty$ загрузка $\rho \rightarrow 1$, однако вероятность задержки $C(c, r) \rightarrow 1$, что ведет к деградации качества обслуживания.
3. **Сбалансированный режим (Quality-and-Efficiency Domain, QED).** Фиксируется вероятность обслуживания без задержек $C(c, r) = \text{const}$. Применение режима QED позволяет сохранить вероятность обслуживания без задержек на заданном уровне при одновременном повышении эффективности использования каналов. Известный как режим Халфина-Уитта, данный подход предполагает, что резерв каналов растет пропорционально квадратному корню из нагрузки:

$$c_{QED} \approx r + \beta\sqrt{r}, \quad \beta > 0.$$

Для исходной системы ($r_0 = 9, c_0 = 12$) параметр $\beta = (12 - 9)/\sqrt{9} = 1$. Тогда для новой нагрузки $r_{new} = 36$ получаем:

$$c_{new} \approx 36 + 1 \cdot \sqrt{36} = 42.$$

При таком выборе вероятность задержки остается практически неизменной ($C(42, 36) \approx 0.27$), а коэффициент загрузки возрастает до $\rho = 36/42 \approx 0.857$.

Математическое обоснование режима QED дает следующая предельная теорема.

Теорема Халфина-Уитта (Halfin-Whitt)

Рассмотрим последовательность систем $M|M|n$ с интенсивностью нагрузки r_n , где $n \rightarrow \infty$ и $r_n \rightarrow \infty$ так, что существует конечный предел:

$$\lim_{n \rightarrow \infty} \frac{n - r_n}{\sqrt{r_n}} = \beta, \quad \beta > 0.$$

Тогда предельная вероятность ожидания заявки в очереди существует и определяется соотношением:

$$\lim_{n \rightarrow \infty} C(n, r_n) = \alpha(\beta) = \left[1 + \frac{\beta \Phi(\beta)}{\phi(\beta)} \right]^{-1},$$

где $\phi(x)$ и $\Phi(x)$ — плотность и функция распределения стандартного нормального закона $\mathcal{N}(0, 1)$ соответственно:

$$\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad \Phi(x) = \int_{-\infty}^x \phi(t) dt.$$

! Замечание !

С практической точки зрения сбалансированный подход (QED) реализуется через решение задачи дискретной оптимизации. Если задан максимально допустимый уровень вероятности задержки в очереди (Quality of Service) $\alpha \in (0, 1)$, оптимальное число каналов определяется как:

$$c^* = \min\{c \in \mathbb{N} : C(c, r) \leq \alpha\}.$$

В режиме масштабирования Халфина-Уитта эта задача сводится к поиску соответствующего параметра β , который определяет необходимый избыток производительности (safety staffing).

Глава 6

Лекция 6. Системы M|M|c|K и M|G|1

6.1 Система массового обслуживания M|M|c|K


Система с ограниченной емкостью (M|M|c|K)

Многоканальная система массового обслуживания, состоящая из c идентичных приборов и буфера ограниченной емкости. Максимально допустимое число заявок в системе равно K (из них c могут находиться на обслуживании, а $K - c$ — в очереди). Если в момент поступления новой заявки в системе уже находится $N = K$ заявок, вновь прибывшая заявка получает отказ и покидает систему необслуженной.

Интенсивность входного потока зависит от текущего состояния системы и задается следующим образом:

$$\lambda_n = \begin{cases} \lambda, & 0 \leq n < K, \\ 0, & n \geq K. \end{cases}$$

Поскольку пространство состояний марковской цепи конечно ($N \in \{0, 1, \dots, K\}$), стационарное распределение вероятностей существует при любых значениях интенсивностей λ и μ . В отличие от систем с бесконечной очередью, ограничение $\rho < 1$ здесь не является обязательным: система сохраняет стабильность даже при сверхвысоких нагрузках за счет отбрасывания избыточных заявок.



Фрагмент графа состояний системы M|M|c|K. Переходы в состояния $n > K$ заблокированы.

▽ **Утв. [Стационарное распределение системы M|M|c|K]** Для многоканальной системы с ограничением емкости K вероятности состояний задаются формулами:

$$p_n = \begin{cases} \frac{r^n}{n!} p_0, & 0 \leq n < c, \\ \frac{r^n}{c^{n-c} c!} p_0, & c \leq n \leq K, \end{cases}$$

где $r = \frac{\lambda}{\mu}$ — приведенная нагрузка, $\rho = \frac{r}{c}$ — коэффициент загрузки. Вероятность простоя системы вычисляется как:

$$p_0 = \left(\sum_{n=0}^{c-1} \frac{r^n}{n!} + \frac{r^c}{c!} S_K(\rho) \right)^{-1}, \quad \text{где} \quad S_K(\rho) = \begin{cases} \frac{1 - \rho^{K-c+1}}{1 - \rho}, & \rho \neq 1, \\ K - c + 1, & \rho = 1. \end{cases}$$

Доказательство. Решение уравнений глобального баланса для процессов рождения и гибели дает стандартное выражение вероятностей через p_0 . Нормировочная константа p_0 находится из условия $\sum_{n=0}^K p_n = 1$. Сумма геометрической прогрессии $S_K(\rho) = \sum_{n=c}^K \rho^{n-c}$ вычисляется по стандартной формуле суммы конечной геометрической прогрессии при $\rho \neq 1$, а при $\rho = 1$ сводится к сумме $(K - c + 1)$ единиц. ■

! Замечание !

Ключевым отличием систем с отказами от классических систем является понятие **эффективной интенсивности входного потока** λ_{eff} . Поскольку заявки, поступающие в момент, когда система находится в состоянии K (с вероятностью p_K), отбрасываются, фактический поток заявок, принимаемых к обслуживанию, меньше номинального λ . Следовательно:

$$\lambda_{\text{eff}} = \lambda(1 - p_K).$$

Все глобальные макроскопические характеристики системы (в частности, закон Литтла) обязаны строиться исключительно с использованием λ_{eff} , так как отброшенные заявки не задерживаются в системе.

▽ **Утв. [Макроскопические характеристики системы М|М|с|К]** Для макроскопических метрик эффективности справедливы следующие соотношения:

- Среднее число заявок в очереди:

$$L_q = \begin{cases} \frac{p_0 r^c \rho}{c!(1-\rho)^2} \left[1 - \rho^{K-c+1} - (1-\rho)(K-c+1)\rho^{K-c} \right], & \rho \neq 1, \\ \frac{p_0 r^c}{c!} \cdot \frac{(K-c)(K-c+1)}{2}, & \rho = 1. \end{cases}$$

- Среднее число заявок в системе: $L = L_q + \frac{\lambda_{\text{eff}}}{\mu}$.
- Среднее время пребывания в системе: $W = \frac{L}{\lambda_{\text{eff}}} = \frac{L}{\lambda(1-p_K)}$.
- Среднее время ожидания в очереди: $W_q = \frac{L_q}{\lambda_{\text{eff}}} = W - \frac{1}{\mu}$.

Доказательство. 1. Среднее число заявок в очереди (L_q). По определению математического ожидания имеем:

$$L_q = \sum_{n=c+1}^K (n-c)p_n = \frac{p_0 r^c}{c!} \sum_{n=c+1}^K (n-c)\rho^{n-c}.$$

Введем новый индекс суммирования $j = n - c$. Тогда граница суммирования изменится от $j = 1$ до $N = K - c$:

$$L_q = \frac{p_0 r^c}{c!} \sum_{j=1}^N j \rho^j.$$

Рассмотрим случай $\rho \neq 1$. Применим метод дифференцирования по параметру ρ :

$$\sum_{j=1}^N j\rho^j = \rho \sum_{j=1}^N j\rho^{j-1} = \rho \frac{d}{d\rho} \left(\sum_{j=1}^N \rho^j \right) = \rho \frac{d}{d\rho} \left(\frac{\rho - \rho^{N+1}}{1 - \rho} \right).$$

Вычислим производную дроби:

$$\frac{d}{d\rho} \left(\frac{\rho - \rho^{N+1}}{1 - \rho} \right) = \frac{(1 - (N+1)\rho^N)(1 - \rho) - (\rho - \rho^{N+1})(-1)}{(1 - \rho)^2} = \frac{1 - (N+1)\rho^N + N\rho^{N+1}}{(1 - \rho)^2}.$$

Умножая на ρ и возвращаясь к исходным обозначениям ($N = K - c$), преобразуем числитель:

$$1 - (K - c + 1)\rho^{K-c} + (K - c)\rho^{K-c+1} = 1 - \rho^{K-c+1} - (1 - \rho)(K - c + 1)\rho^{K-c}.$$

Подставляя это в выражение для L_q , получаем требуемую формулу для $\rho \neq 1$.

Для случая $\rho = 1$ ряд представляет собой сумму арифметической прогрессии:

$$\sum_{j=1}^{K-c} j \cdot 1^j = \frac{(K - c)(K - c + 1)}{2}, \quad \text{откуда} \quad L_q = \frac{p_0 r^c}{c!} \frac{(K - c)(K - c + 1)}{2}.$$

2. Временные характеристики. Формулы для L, W и W_q прямо следуют из применения универсального закона Литтла к системе с отбрасыванием заявок. В качестве интенсивности потока выступает величина λ_{eff} . ■

Следствие. В частном случае одноканальной системы с ограничением ($c = 1$, система М|М|1|К) уравнение глобального баланса интенсивностей принимает наглядный вид. Среднее число заявок $L = L_q + (1 - p_0)$, где $(1 - p_0)$ — вероятность того, что прибор занят. Из соотношения $L = L_q + \lambda_{\text{eff}}/\mu$ немедленно следует:

$$\underbrace{\mu(1 - p_0)}_{\text{эффективная интенсивность обслуживания}} = \underbrace{\lambda(1 - p_K)}_{\text{эффективная интенсивность входящего потока}}.$$

Система достигает равновесия, при котором средняя скорость обработки находящихся в приборе заявок строго равна скорости поступления новых (принятых) заявок. ◆

Пример: Аналитический расчет вероятности отказа для системы М|М|1|К

Рассмотрим одноканальную систему с ограниченным буфером (общая емкость системы равна K , число приборов $c = 1$). Продемонстрируем вывод явной аналитической зависимости вероятности потери заявки p_K от коэффициента загрузки ρ и исследуем ее поведение при высоких нагрузках ($\rho \geq 1$).

Решение. Для одноканальной системы $c = 1$, следовательно, множители $c! = 1$ и $c^{n-c} = 1$. Общая формула для стационарных вероятностей p_n существенно упрощается на всем диапазоне состояний $0 \leq n \leq K$:

$$p_n = \rho^n p_0.$$

Используя условие нормировки $\sum_{n=0}^K p_n = 1$, находим константу p_0 через сумму конечной геометрической прогрессии. Для $\rho \neq 1$ получаем:

$$p_0 \sum_{n=0}^K \rho^n = p_0 \frac{1 - \rho^{K+1}}{1 - \rho} = 1 \quad \Rightarrow \quad p_0 = \frac{1 - \rho}{1 - \rho^{K+1}}.$$

Вероятность того, что система полностью заполнена (и поступающая заявка получит отказ), вычисляется подстановкой $n = K$:

$$p_K = \rho^K p_0 = \frac{\rho^K (1 - \rho)}{1 - \rho^{K+1}} = \frac{\rho^K (\rho - 1)}{\rho^{K+1} - 1}.$$

В отличие от систем с бесконечной очередью, где при $\rho \rightarrow 1$ длина очереди стремится к бесконечности (асимптота), система М/М/1/К сохраняет стабильность при любых нагрузках. Рассмотрим два критических режима:

- **Пограничная нагрузка ($\rho = 1$):** Возникает неопределенность вида $\left[\frac{0}{0}\right]$. Раскрывая ее по правилу Лопиталя (или подставляя $\rho = 1$ напрямую в исходную сумму $\sum_{n=0}^K 1^n = K + 1$), получаем строго конечную вероятность отказа:

$$p_K \Big|_{\rho=1} = \frac{1}{K + 1}.$$

- **Режим перегрузки ($\rho > 1$):** При интенсивностях входного потока, превышающих скорость обслуживания, очередь не возрастает бесконечно, а стабилизируется за счет отбрасывания лишних заявок. Разделив числитель и знаменатель дроби на ρ^K , получим:

$$p_K = \frac{\rho - 1}{\rho - \rho^{-K}}.$$


При сильной перегрузке ($\rho \gg 1$) экспоненциально убывающим слагаемым ρ^{-K} можно пренебречь. Это дает следующую асимптотику вероятности отказа:

$$p_K \approx \frac{\rho - 1}{\rho} = 1 - \frac{1}{\rho}.$$

Данный математический результат имеет строгий физический смысл. Вычислим эффективную интенсивность потока, проходящего через систему в режиме перегрузки:

$$\lambda_{\text{eff}} = \lambda(1 - p_K) \approx \lambda \left(1 - \left(1 - \frac{1}{\rho} \right) \right) = \lambda \cdot \frac{1}{\rho} = \lambda \cdot \frac{\mu}{\lambda} = \mu.$$

Система автоматически адаптируется к любой перегрузке: она работает на абсолютном пределе своей производительности (обслуживая μ заявок в единицу времени), а весь избыточный трафик отбрасывается на входе.



Зависимость вероятности потери заявки p_K от загрузки ρ для различной емкости буфера. Черной штрихпунктирной линией показана предельная асимптота при $K \rightarrow \infty$ в режиме перегрузки ($\rho > 1$).

6.1.1 Распределение состояний в моменты поступления заявок

В системах с ограничением емкости буфера необходимо строго различать три типа распределений:

1. p_n — стационарное распределение (доля времени, которую система проводит в состоянии n).
2. q_n — распределение вероятностей состояний, которые застает *произвольная* поступающая заявка.
3. q_n^* — распределение вероятностей состояний, которые застает *успешно принятая* в систему заявка.

Согласно свойству PASTA (Poisson Arrivals See Time Averages), пуассоновский поток заявок «видит» систему в стационарном состоянии, поэтому $q_n = p_n$. Однако для систем $M|M|c|K$ факт приема заявки зависит от ее состояния: если $n = K$, заявка будет отброшена. Следовательно, распределение успешно принятых заявок q_n^* является **условным** распределением и не совпадает с q_n .

! Замечание !

Напомним **формулу Байеса** для условной вероятности гипотез. Если H_i задает полную группу несовместных гипотез, а A является некоторым событием, то апостериорная вероятность гипотезы H_n вычисляется как:

$$\mathbb{P}(H_n | A) = \frac{\mathbb{P}(A | H_n) \mathbb{P}(H_n)}{\sum_i \mathbb{P}(A | H_i) \mathbb{P}(H_i)}.$$

▽ Утв. [**Связь вероятностей p_n и q_n^***] Вероятность того, что успешно принятая в систему $M|M|c|K$

заявка застанет в ней ровно n заявок, определяется выражением:

$$q_n^* = \begin{cases} \frac{p_n}{1 - p_K}, & 0 \leq n \leq K - 1, \\ 0, & n = K. \end{cases}$$

Доказательство. Зафиксируем произвольный момент времени t в стационарном режиме. Рассмотрим малый интервал $(t, t + \Delta t)$. Пусть гипотеза H_n заключается в том, что в момент t система находится в состоянии n . Вероятности этих гипотез по определению суть стационарные вероятности: $\mathbb{P}(H_n) = p_n$.

Определим событие A как «на интервале $(t, t + \Delta t)$ в систему пришла и была **успешно принята** новая заявка». Согласно определению условной вероятности:

$$\mathbb{P}(A | H_n) = \frac{\mathbb{P}(A \cap H_n)}{\mathbb{P}(H_n)}.$$

Рассмотрим числитель для случаев $n \in \{0, \dots, K - 1\}$. В этих состояниях система имеет хотя бы одно свободное место, поэтому любая пришедшая заявка принимается с вероятностью 1. Следовательно, при $n < K$ пересечение $A \cap H_n$ совпадает с пересечением $\{\text{на интервале } \Delta t \text{ пришла 1 заявка}\} \cap H_n$. Используя свойства пуассоновского потока, получаем:

$$\mathbb{P}(A | H_n) = \frac{\mathbb{P}(\{\text{пришла 1 заявка}\} \cap H_n)}{\mathbb{P}(H_n)} = \frac{(\lambda \Delta t + o(\Delta t)) \cdot p_n}{p_n} = \lambda \Delta t + o(\Delta t).$$

Для состояния $n = K$ система полностью заполнена. Любая пришедшая заявка получает отказ, то есть событие A в состоянии K невозможно: $A \cap H_K = \emptyset$, откуда $\mathbb{P}(A | H_K) = 0$.

Запишем условные вероятности в виде системы:

$$\mathbb{P}(A | H_n) = \begin{cases} \lambda \Delta t + o(\Delta t), & 0 \leq n \leq K - 1, \\ 0, & n = K. \end{cases}$$

Воспользуемся формулой Байеса для нахождения искомой вероятности q_n^* :

$$q_n^* \doteq \lim_{\Delta t \rightarrow 0} \mathbb{P}(H_n | A) = \lim_{\Delta t \rightarrow 0} \frac{\mathbb{P}(A | H_n) \mathbb{P}(H_n)}{\sum_{i=0}^K \mathbb{P}(A | H_i) \mathbb{P}(H_i)} = \lim_{\Delta t \rightarrow 0} \frac{\mathbb{P}(A | H_n) \cdot p_n}{\sum_{i=0}^{K-1} (\lambda \Delta t + o(\Delta t)) p_i + 0 \cdot p_K}.$$

Для любого $n \leq K - 1$ подставим значение $\mathbb{P}(A | H_n)$:

$$q_n^* = \lim_{\Delta t \rightarrow 0} \frac{(\lambda \Delta t + o(\Delta t)) p_n}{(\lambda \Delta t + o(\Delta t)) \sum_{i=0}^{K-1} p_i} = \lim_{\Delta t \rightarrow 0} \frac{\left(\lambda + \frac{o(\Delta t)}{\Delta t}\right) p_n}{\left(\lambda + \frac{o(\Delta t)}{\Delta t}\right) \sum_{i=0}^{K-1} p_i}.$$

Переходя к пределу при $\Delta t \rightarrow 0$, находим:

$$q_n^* = \frac{\lambda p_n}{\lambda \sum_{i=0}^{K-1} p_i} = \frac{p_n}{\sum_{i=0}^{K-1} p_i}.$$

В силу нормировочного условия $\sum_{i=0}^K p_i = 1$, сумма в знаменателе равна $1 - p_K$. Следовательно:

$$q_n^* = \frac{p_n}{1 - p_K}, \quad n \in \{0, \dots, K-1\}.$$

Для состояния $n = K$ числитель под знаком предела тождественно равен нулю в силу $\mathbb{P}(A \mid H_K) = 0$, откуда $q_K^* = 0$. ■

Следствие. Из полученной формулы следует соотношение $q_n^*(1 - p_K) = p_n$. При устремлении емкости системы к бесконечности ($K \rightarrow \infty$) мы переходим к классической системе $M|M|c|\infty$. В этом случае вероятность отказа стремится к нулю ($p_K \rightarrow 0$), и знаменатель дроби стремится к единице. Следовательно, $q_n^* \rightarrow p_n$. Аналитически это означает, что в системах с бесконечной очередью все заявки принимаются, и условное распределение совпадает с безусловным стационарным распределением.

! Замечание !

Поскольку для процессов с непрерывным временем вероятность поступления заявки в строго зафиксированный момент t равна нулю, прямое вычисление условной вероятности $\mathbb{P}(H_n \mid \{\text{поступление заявки в момент } t\})$ невозможно. Введение предельного перехода при $\Delta t \rightarrow 0$ позволяет корректно определить условную вероятность относительно события нулевой меры и формализовать понятие состояния системы непосредственно перед моментом прибытия заявки.

6.1.2 Системы с отказами (M|M|c|c) и формула Эрланга

Особый теоретический и практический интерес (в частности, в телефонии и инфокоммуникационных сетях) представляет вырожденный случай системы с ограниченной емкостью, в которой места для ожидания полностью отсутствуют.

Система с явными потерями (M|M|c|c)

Многоканальная система массового обслуживания, состоящая из c приборов, в которой емкость буфера равна нулю. Максимально допустимое число заявок в системе в точности совпадает с числом приборов ($K = c$). Любая заявка, заставшая все c каналов занятыми, мгновенно получает отказ и покидает систему.

Утв. [Первая формула Эрланга] Для системы $M|M|c|c$ стационарное распределение вероятностей состояний задается формулой:

$$p_n = \frac{r^n}{c!} \cdot \frac{c!}{\sum_{i=0}^c r^i}, \quad n \in \{0, 1, \dots, c\},$$

где $r = \frac{\lambda}{\mu}$ — приведенная нагрузка. Вероятность того, что все каналы заняты (вероятность блокировки или потери заявки), обозначается как $B(c, r)$ и называется **формулой потерь Эрланга** (Erlang-B

formula):

$$B(c, r) \equiv p_c = \frac{\frac{r^c}{c!}}{\sum_{i=0}^c \frac{r^i}{i!}}.$$

Доказательство. Поскольку $K = c$, состояния с наличием очереди ($n > c$) не существуют. Воспользуемся общим решением для системы $M|M|c|K$. При $n \leq c$ интенсивность обслуживания линейна и равна $n\mu$. Уравнения глобального баланса дают $p_n = \frac{r^n}{n!} p_0$.

Применяя условие нормировки $\sum_{n=0}^c p_n = 1$, вычисляем вероятность простоя системы:

$$p_0 = \left[\sum_{i=0}^c \frac{r^i}{i!} \right]^{-1}.$$

Подстановка p_0 в выражение для p_n напрямую приводит к искомой формуле. Полагая $n = c$, получаем выражение для $B(c, r)$. ■

! Замечание 1 !

Стационарное распределение p_n обладает свойством инвариантности по отношению к форме распределения времени обслуживания. Согласно теореме Севастьянова, формулы Эрланга остаются справедливыми для системы общего вида $M|G|c|c$. Вероятности состояний зависят от распределения времени обслуживания исключительно через его математическое ожидание $\mathbb{E}[S]$ (посредством параметра нагрузки $r = \lambda \mathbb{E}[S]$).

! Замечание 2 !

Вероятность блокировки заявки тождественно совпадает со стационарной вероятностью p_c в силу свойства PASTA. Данное свойство применимо к исходному пуассоновскому потоку всех поступающих заявок (как успешно принимаемых системой, так и получающих отказ), в отличие от условного потока только принятых заявок.

! Замечание 3 !

Прямое вычисление вероятности отказа по формуле Эрланга $B(c, r) = p_c$ при больших значениях c приводит к вычислительным трудностям из-за наличия факториалов. Для численного нахождения стационарных вероятностей применяют рекуррентное соотношение:

$$B(c, r) = \frac{rB(c-1, r)}{c + rB(c-1, r)}, \quad B(0, r) = 1.$$

6.2 Система массового обслуживания M|G|1 и формула Полячека — Хинчина

Рассмотрим одноканальную систему массового обслуживания с пуассоновским входным потоком заявок и произвольным (General) распределением времени обслуживания. Дисциплина обслуживания — FCFS (First Come, First Served).

Система с произвольным обслуживанием (M|G|1)

Система, в которой интенсивность входного пуассоновского потока равна λ , а времена обслуживания отдельных заявок $\{S_1, S_2, \dots, S_n, \dots\}$ образуют последовательность независимых одинаково распределенных случайных величин с функцией распределения $B(t) = \mathbb{P}(S_n \leq t)$. Среднее время обслуживания и коэффициент загрузки системы определяются как:

$$\mu \doteq \frac{1}{\mathbb{E}[S]}, \quad \rho \doteq \frac{\lambda}{\mu} < 1.$$

! Замечание 1 !

Поскольку время обслуживания может иметь как непрерывный, так и дискретный характер (или их комбинацию), математическое ожидание $\mathbb{E}[S]$ строго определяется через **интеграл Лебега — Стильеса**:

$$\mathbb{E}[S] = \int_0^{+\infty} t dB(t).$$

Данный интеграл обобщает классический интеграл Римана и сумму для дискретных величин, выполняя интегрирование по вероятностной мере, порожденной функцией распределения $B(t)$. В случае абсолютно непрерывного распределения с плотностью $b(t)$ он сводится к $\int tb(t)dt$.

! Замечание 2 !

Требование независимости и одинаковости распределенности величин S_n является критически важным. Если в реальной системе присутствует физический износ оборудования (время обработки растет с номером заявки n) или адаптивность (скорость обслуживания зависит от текущей длины очереди X_n), распределение S_{n+1} начинает зависеть от предыстории, делая приведенные ниже выкладки непригодными.

Для анализа классической системы M|G|1 применение стандартного аппарата уравнений Колмогорова напрямую невозможно. Случайный процесс $X(t)$, описывающий число заявок в системе в момент времени t , не обладает марковским свойством: вероятность перехода в новое состояние зависит не только от текущего числа заявок, но и от того, *сколько времени* уже обслуживается текущая заявка (поскольку произвольное распределение времени обслуживания не обладает свойством отсутствия памяти, в отличие от экспоненциального).

Для преодоления этой проблемы Дэвид Кендалл предложил метод дискретизации времени, при котором эволюция системы рассматривается исключительно в строго определенные, «регенеративные» моменты.

Вложенная цепь Маркова (метод Кендалла)

Пусть t_n — моменты окончания обслуживания n -й заявки. Рассмотрим дискретный процесс $X_n \doteq X(t_n + 0)$, описывающий число заявок в системе *непосредственно после* ухода n -й заявки. Последовательность случайных величин $\{X_n\}_{n=1}^{\infty}$ образует дискретную однородную цепь Маркова, называемую **вложенной**.

! Замечание 1 !

В классических марковских цепях с дискретным временем индекс n обычно соответствует детерминированным шагам (например, фиксированным интервалам Δt). В методе Кендалла физическое время $t_n(\omega)$ окончания обслуживания n -й заявки является случайной величиной, зависящей от конкретной реализации ω .


Корректность построения цепи обеспечивается сменой индексного множества. Параметр $n \in \mathbb{N}$ здесь выступает не как физическое время, а как **порядковый номер ухода n -й заявки**. Переход от непрерывного процесса $X(t)$ к дискретной последовательности $\{X_n\}_{n=1}^{\infty}$ абстрагируется от того, *когда именно* произошли переходы. Поскольку индексы n пробегают фиксированное детерминированное множество $\mathbb{N}$, $\{X_n\}$ представляет собой корректно определенный случайный процесс с дискретным временем.

! Замечание 2 !

Строгое доказательство марковости вложенной цепи опирается на алгебраическое уравнение эволюции:

$$X_{n+1} = \max(0, X_n - 1) + A_{n+1},$$

где A_{n+1} — число заявок, поступивших в систему за время S_{n+1} (обслуживание $(n+1)$ -й заявки).



Временная диаграмма процесса обслуживания. Марковская цепь формируется путем фиксации состояний X_n строго в моменты ухода заявок.

Поскольку моменты наблюдения t_n строго привязаны к окончанию обслуживания, в момент начала обработки следующей заявки ее «таймер» стартует с нуля. Количество прибывших заявок A_{n+1} зависит исключительно от длительности интервала S_{n+1} и интенсивности пуассоновского потока λ . В силу фундаментальной аксиомы о том, что времена $\{S_n\}$ независимы от предыстории системы, величина A_{n+1} также стохастически независима от прошлых состояний $X_{n-1}, X_{n-2}, \dots$.

Таким образом, распределение случайной величины X_{n+1} полностью и однозначно определяется текущим состоянием X_n :

$$\mathbb{P}(X_{n+1} = j \mid X_n, X_{n-1}, \dots, X_0) = \mathbb{P}(X_{n+1} = j \mid X_n).$$

Однородность данной цепи (независимость переходных вероятностей от шага n) вытекает из стационарности пуассоновского потока и идентичности распределений $B(t)$ для всех заявок.

Формула Полячека — Хинчина

Для системы M/G/1 стационарное распределение вероятностей состояний существует тогда и только тогда, когда коэффициент загрузки $\rho < 1$. В стационарном режиме среднее число заявок в системе определяется формулой:

$$L = \rho + \frac{\rho^2 + \lambda^2 \sigma_B^2}{2(1 - \rho)},$$

где $\sigma_B^2 = \mathbb{D}[S]$ — дисперсия времени обслуживания.

Доказательство. Пусть A_{n+1} — число заявок, поступивших в систему за время обслуживания $(n + 1)$ -й заявки. Эволюция состояний вложенной цепи Маркова описывается разностным стохастическим уравнением:

$$X_{n+1} = \begin{cases} X_n - 1 + A_{n+1}, & X_n \geq 1, \\ A_{n+1}, & X_n = 0. \end{cases}$$

Введем индикаторную функцию события $\{X_n > 0\}$, обозначаемую $\mathbb{I}_{\{X_n > 0\}}$, равную 1 при $X_n > 0$ и 0 при $X_n = 0$. Уравнение эволюции принимает единый алгебраический вид:

$$X_{n+1} = X_n - \mathbb{I}_{\{X_n > 0\}} + A_{n+1} \quad (*)$$

Предположим, что марковская цепь эргодична. В стационарном режиме распределения X_{n+1} и X_n совпадают, следовательно, их начальные моменты равны. Обозначим искомое математическое ожидание числа заявок в момент ухода как $\mathbb{E}[X_{n+1}] = \mathbb{E}[X_n] \doteq L^{(D)}$. Верхний индекс (D) (от англ. *Departure* — уход) подчеркивает, что данная величина есть среднее число заявок в системе, наблюдаемое исключительно в моменты завершения обслуживания. В общем случае она может не совпадать со средним числом заявок в произвольный момент времени L .

1. Первый начальный момент и вероятность непустой системы. Применим оператор математического ожидания к обеим частям уравнения (*):

$$L^{(D)} = L^{(D)} - \mathbb{E}[\mathbb{I}_{\{X_n > 0\}}] + \mathbb{E}[A_{n+1}] \implies \mathbb{E}[\mathbb{I}_{\{X_n > 0\}}] = \mathbb{E}[A_{n+1}].$$

По свойствам индикаторной функции ее математическое ожидание равно вероятности соответствующего события: $\mathbb{E}[\mathbb{I}_{\{X_n > 0\}}] = \mathbb{P}(X_n > 0) = 1 - \pi_0$, где π_0 — стационарная вероятность того, что система пуста в моменты ухода. Иными словами, это вероятность того, что уходящая заявка оставляет после себя непустую систему.

Вычислим $\mathbb{E}[A_{n+1}]$, применяя формулу полного математического ожидания по длительности обслуживания S_{n+1} . В силу свойств пуассоновского потока условное распределение $\{A_{n+1} \mid S_{n+1} = t\} \sim \text{Poiss}(\lambda t)$:

$$\mathbb{E}[A_{n+1}] = \int_0^{+\infty} \mathbb{E}[A_{n+1} \mid S_{n+1} = t] dB(t) = \int_0^{+\infty} \lambda t dB(t) = \lambda \mathbb{E}[S_{n+1}] = \rho.$$

Отсюда немедленно следует важный результат: $1 - \pi_0 = \rho$. Поскольку для существования стационарного режима вероятность пустого состояния должна быть строго положительной ($\pi_0 > 0$), из этого тождества аналитически вытекает **необходимое условие стационарности**: $\rho < 1$. (В пункте 4 мы строго докажем равенство распределений по временам ухода и в произвольный момент времени $\pi_0 = p_0$. Это придаст величине ρ классический физический смысл — доли времени занятости прибора в непрерывном времени).

2. Второй начальный момент и длина очереди. Возведем уравнение (*) в квадрат. Учитывая идемпотентность индикатора $\mathbb{I}_{\{X_n > 0\}}^2 = \mathbb{I}_{\{X_n > 0\}}$ и свойство $X_n \mathbb{I}_{\{X_n > 0\}} = X_n$, получаем:

$$\begin{aligned} X_{n+1}^2 &= (X_n - \mathbb{I}_{\{X_n > 0\}} + A_{n+1})^2 \\ &= X_n^2 + \mathbb{I}_{\{X_n > 0\}}^2 + A_{n+1}^2 - 2X_n \mathbb{I}_{\{X_n > 0\}} - 2A_{n+1} \mathbb{I}_{\{X_n > 0\}} + 2A_{n+1} X_n \\ &= X_n^2 + \mathbb{I}_{\{X_n > 0\}} + A_{n+1}^2 - 2X_n - 2A_{n+1} \mathbb{I}_{\{X_n > 0\}} + 2A_{n+1} X_n. \end{aligned}$$

Перейдем к математическим ожиданиям. В силу стационарности $\mathbb{E}[X_{n+1}^2] = \mathbb{E}[X_n^2]$. Приращение пуассоновского потока A_{n+1} зависит только от длительности S_{n+1} и строго не зависит от предыстории процесса (состояния X_n и индикатора $\mathbb{I}_{\{X_n > 0\}}$). Следовательно, математическое ожидание произведений распадается на произведение математических ожиданий:

$$0 = \mathbb{E}[\mathbb{I}_{\{X_n > 0\}}] + \mathbb{E}[A_{n+1}^2] - 2\mathbb{E}[X_n] - 2\mathbb{E}[A_{n+1}]\mathbb{E}[\mathbb{I}_{\{X_n > 0\}}] + 2\mathbb{E}[A_{n+1}]\mathbb{E}[X_n].$$

Подставляя найденные ранее значения ($\mathbb{E}[\mathbb{I}_{\{X_n > 0\}}] = \rho$, $\mathbb{E}[A_{n+1}] = \rho$, $\mathbb{E}[X_n] = L^{(D)}$), приводим уравнение к виду:

$$0 = \rho + \mathbb{E}[A_{n+1}^2] - 2L^{(D)} - 2\rho^2 + 2\rho L^{(D)}.$$

Группируя слагаемые с $L^{(D)}$, находим:

$$2L^{(D)}(1 - \rho) = \rho - 2\rho^2 + \mathbb{E}[A_{n+1}^2].$$

Поскольку доказанное ранее условие стационарности $\rho < 1$ выполнено, разделим обе части на $2(1 - \rho)$ и выразим длину очереди:

$$L^{(D)} = \frac{\rho - 2\rho^2 + \mathbb{E}[A_{n+1}^2]}{2(1 - \rho)}.$$

3. Вычисление дисперсии приращений. Определим $\mathbb{E}[A_{n+1}^2]$ через формулу полной дисперсии:

$$\mathbb{D}[A_{n+1}] = \mathbb{E}[\mathbb{D}[A_{n+1} \mid S_{n+1}]] + \mathbb{D}[\mathbb{E}[A_{n+1} \mid S_{n+1}]].$$

Для пуассоновского закона условное математическое ожидание и дисперсия равны λS_{n+1} :

$$\mathbb{D}[A_{n+1}] = \mathbb{E}[\lambda S_{n+1}] + \mathbb{D}[\lambda S_{n+1}] = \lambda \mathbb{E}[S_{n+1}] + \lambda^2 \mathbb{D}[S_{n+1}] = \rho + \lambda^2 \sigma_S^2.$$

Переходя ко второму начальному моменту:

$$\mathbb{E}[A_{n+1}^2] = \mathbb{D}[A_{n+1}] + (\mathbb{E}[A_{n+1}])^2 = \rho + \lambda^2 \sigma_B^2 + \rho^2.$$

Подстановка данного выражения в формулу для $L^{(D)}$ дает искомый результат:

$$L^{(D)} = \frac{\rho - 2\rho^2 + (\rho + \lambda^2 \sigma_B^2 + \rho^2)}{2(1 - \rho)} = \frac{2\rho - \rho^2 + \lambda^2 \sigma_B^2}{2(1 - \rho)} = \rho + \frac{\rho^2 + \lambda^2 \sigma_B^2}{2(1 - \rho)}.$$

4. Совпадение распределений и эквивалентность средних.

Для завершения доказательства необходимо обосновать равенство $L = L^{(D)}$. Введем три распределения вероятностей состояний системы:


- p_n — стационарная вероятность того, что в произвольный момент времени в системе находится n заявок;
- q_n — вероятность того, что *прибывающая* заявка застает в системе n заявок;
- π_n — вероятность того, что *уходящая* после обслуживания заявка оставляет в системе n заявок.

Рассмотрим некоторую реализацию процесса $X(t)$ на достаточно большом интервале времени $[0, T]$. В силу того, что приходы и уходы заявок в системе $M|G|1$ являются одиночными событиями, изменения состояния системы происходят только в виде скачков ± 1 .

Зафиксируем уровень n и введем счетчики переходов:

- $A_n(T)$ — число переходов вида $n \rightarrow n + 1$ (приход заявки в систему, находящуюся в состоянии n);
- $D_n(T)$ — число переходов вида $n + 1 \rightarrow n$ (уход заявки, оставляющей после себя n заявок).

Поскольку для повторного совершения скачка «вверх» система обязана предварительно совершить скачок «вниз» (и наоборот), значения этих счетчиков для любой реализации процесса могут отличаться не более чем на единицу: $|A_n(T) - D_n(T)| \leq 1$.



Пусть $A(T)$ — общее число прибывших заявок, а $D(T)$ — общее число обслуженных заявок за время T . Очевидно, что баланс числа заявок в системе задается соотношением:

$$D(T) = A(T) + X(0) - X(T). \quad (6.1)$$

Вычислим вероятность π_n как предел отношения частот при $T \rightarrow \infty$:

$$\pi_n = \lim_{T \rightarrow \infty} \frac{D_n(T)}{D(T)} = \lim_{T \rightarrow \infty} \frac{A_n(T) + \overbrace{[D_n(T) - A_n(T)]}^{=0, \pm 1}}{\underbrace{A(T) + X(0) - X(T)}_{\in O(1)}}. \quad (6.2)$$

В стационарном состоянии случайная величина $X(T)$ ограничена (состояние системы не уходит в бесконечность почти наверняка при $\rho < 1$). Следовательно, разность $X(0) - X(T)$ остается ограниченной константой. При $T \rightarrow \infty$ общее число поступивших заявок $A(T) \rightarrow \infty$. Разделив числитель и знаменатель на $A(T)$, получаем:

$$\pi_n = \lim_{T \rightarrow \infty} \frac{\frac{A_n(T)}{A(T)} + \frac{0, \pm 1}{A(T)}}{1 + \frac{O(1)}{A(T)}} = \lim_{T \rightarrow \infty} \frac{A_n(T)}{A(T)} = q_n.$$

Таким образом, вероятность найти систему в состоянии n в моменты ухода (π_n) тождественно равна вероятности застать систему в этом же состоянии в моменты прихода (q_n).

Согласно **свойству PASTA** (Poisson Arrivals See Time Averages), пуассоновский входной поток «видит» систему в стационарном состоянии, что означает $q_n = p_n$. Объединяя результаты, получаем:

$$p_n = q_n = \pi_n \quad \implies \quad L = L^{(D)}.$$

Окончательно подставляем выведенное ранее значение $L^{(D)}$ и получаем **формулу Полячека — Хинчина**:

$$L = \rho + \frac{\rho^2 + \lambda^2 \sigma_B^2}{2(1 - \rho)}$$

Следствие. Применение универсального закона Литтла ($L = \lambda W$) к полученному результату позволяет определить все остальные макроскопические метрики системы M/G/1:

- Среднее время пребывания в системе: $W = \frac{L}{\lambda} = \frac{1}{\mu} + \frac{\rho^2 + \lambda^2 \sigma_B^2}{2\lambda(1 - \rho)}.$
- Средняя длина очереди: $L_q = L - \rho = \frac{\rho^2 + \lambda^2 \sigma_B^2}{2(1 - \rho)}.$
- Среднее время ожидания в очереди: $W_q = W - \frac{1}{\mu} = \frac{L_q}{\lambda}.$

Пример: Сравнение систем M|M|1 и M|D|1

Формула Полячека — Хинчина позволяет аналитически оценить влияние разброса времени обслуживания на длину очереди. Рассмотрим два случая: систему с показательным временем обслуживания ($M|M|1$) и систему с детерминированным временем обслуживания постоянной длительности ($M|D|1$).

Решение.**Случай 1 (система $M|M|1$).**

Время обслуживания имеет экспоненциальное распределение с параметром μ . Дисперсия экспоненциального распределения равна квадрату математического ожидания: $\sigma_B^2 = \frac{1}{\mu^2}$. Подставляя это в формулу Полячека — Хинчина, выделим слагаемое, отвечающее за очередь:

$$L_{M|M|1} = \rho + \frac{\rho^2 + \lambda^2 \frac{1}{\mu^2}}{2(1 - \rho)} = \rho + \frac{2\rho^2}{2(1 - \rho)} = \rho + \underbrace{\frac{\rho^2}{1 - \rho}}_{L_q}.$$


Случай 2 (система $M|D|1$).

Время обслуживания строго фиксировано: $S = a = \text{const.}$ Дисперсия константы равна нулю ($\sigma_B^2 = 0$). При подстановке получаем:

$$L_{M|D|1} = \rho + \frac{\rho^2 + 0}{2(1 - \rho)} = \rho + \underbrace{\frac{1}{2} \cdot \frac{\rho^2}{1 - \rho}}_{L_q}.$$

Сравнивая вторые слагаемые в обоих случаях, видим, что среднее число заявок в очереди для системы с детерминированным обслуживанием ровно в два раза меньше, чем в простейшей системе с тем же коэффициентом загрузки ρ .

Таким образом, устранение стохастичности (вариативности) времени обслуживания позволяет сократить длину очереди вдвое при неизменной интенсивности потока и прибора. ■



Зависимость среднего числа заявок в системе от коэффициента загрузки. График демонстрирует, что очереди формируются не только из-за высокой загрузки, но и из-за дисперсии временных параметров.

Глава 7

Лекция 7. Система $M^{[X]}|M|1$

Система $M^{[X]}|M|1$

Система массового обслуживания, на вход которой поступает пуассоновский поток событий с интенсивностью λ . В данной модели каждое событие инициирует поступление не одиночной заявки, а группы (пакета).

Размер группы является дискретной случайной величиной X . Предполагается, что размеры последовательно поступающих групп представляют собой независимые в совокупности и одинаково распределенные случайные величины. Закон распределения размера группы задается вероятностями:

$$\mathbb{P}(X = n) = c_n, \quad n \in \mathbb{N},$$

где $\sum_{n=1}^{\infty} c_n = 1$. Интенсивность поступления групп, состоящих строго из n заявок, составляет $\lambda_n = \lambda c_n$.

Время обслуживания отдельной заявки распределено по экспоненциальному закону с параметром μ .

Вследствие группового поступления заявок граф переходов марковской цепи содержит дуги, соответствующие скачкам процесса на произвольное число состояний вправо.




Рис. 7.1: Граф интенсивностей переходов для системы с групповым поступлением заявок. Проиллюстрированы приходы групп размера 1 и 2.

УТВ. Производящая функция стационарного распределения вероятностей состояний системы $P(z) = \sum_{n=0}^{\infty} p_n z^n$ имеет вид:

$$P(z) = \frac{p_0}{1 - \frac{\lambda}{\mu} z \bar{C}(z)},$$

где $\bar{C}(z) = \frac{1-C(z)}{1-z}$, $C(z)$ — производящая функция распределения размера группы X . Вероятность проста системы равна $p_0 = 1 - \rho$, где коэффициент загрузки $\rho = \frac{\lambda}{\mu} \mathbb{E}[X] < 1$.

Стационарное распределение полностью определяется данной функцией: вероятности состояний $\{p_n\}_{n=0}^{\infty}$ вычисляются как коэффициенты разложения $P(z)$ в ряд Тейлора:

$$p_n = \frac{1}{n!} \left. \frac{d^n P(z)}{dz^n} \right|_{z=0}.$$

Доказательство. Составим систему уравнений глобального баланса, приравнявая интенсивности выхода из состояния n и входа в него:

- Для состояния $n = 0$:

$$\lambda p_0 = \mu p_1.$$

- Для состояний $n \geq 1$:

$$(\lambda + \mu)p_n = \mu p_{n+1} + \sum_{k=1}^n p_{n-k} \lambda_k.$$

Подставляя $\lambda_k = \lambda c_k$, перепишем второе уравнение:

$$(\lambda + \mu)p_n = \mu p_{n+1} + \lambda \sum_{k=1}^n p_{n-k} c_k.$$


Введем производящие функции для распределения размера группы $C(z) = \sum_{n=1}^{\infty} c_n z^n$ и вероятностей состояний $P(z) = \sum_{n=0}^{\infty} p_n z^n$. Умножим уравнение для $n \geq 1$ на z^n и просуммируем по n от 1 до ∞ :

$$(\lambda + \mu) \sum_{n=1}^{\infty} p_n z^n = \mu \sum_{n=1}^{\infty} p_{n+1} z^n + \lambda \sum_{n=1}^{\infty} \sum_{k=1}^n p_{n-k} c_k z^n.$$

Выразим одинарные суммы через $P(z)$:

$$\sum_{n=1}^{\infty} p_n z^n = P(z) - p_0, \quad \sum_{n=1}^{\infty} p_{n+1} z^n = \frac{1}{z} \sum_{n=2}^{\infty} p_n z^n = \frac{1}{z} (P(z) - p_0 - p_1 z).$$

Для преобразования двойной суммы изменим порядок суммирования. Исходная область индексов представляет собой дискретный клин $1 \leq k \leq n < \infty$.



Меняя пределы, получаем произведение двух рядов:

$$\sum_{n=1}^{\infty} \sum_{k=1}^n p_{n-k} c_k z^n = \sum_{k=1}^{\infty} \sum_{n=k}^{\infty} c_k p_{n-k} z^n = \sum_{k=1}^{\infty} c_k z^k \sum_{n=k}^{\infty} p_{n-k} z^{n-k} = C(z)P(z).$$

Подставим полученные выражения в основное уравнение:

$$(\lambda + \mu)(P(z) - p_0) = \frac{\mu}{z}(P(z) - p_0 - p_1 z) + \lambda C(z)P(z).$$

Так как $\frac{\mu}{z}p_1 z = \mu p_1$, и из уравнения для $n = 0$ известно соотношение $\mu p_1 = \lambda p_0$, получаем:

$$\lambda P(z) - \lambda p_0 + \mu(P(z) - p_0) = \frac{\mu}{z}(P(z) - p_0) - \lambda p_0 + \lambda C(z)P(z).$$

После сокращения слагаемых $-\lambda p_0$ группируем члены, содержащие $P(z)$, в левой части, а p_0 — в правой:

$$\lambda P(z) - \lambda C(z)P(z) = \frac{\mu}{z}(P(z) - p_0) - \mu(P(z) - p_0).$$

Вынося общие множители, находим:

$$\lambda P(z)(1 - C(z)) = \mu(P(z) - p_0) \left(\frac{1 - z}{z} \right).$$

Умножая обе части на z , выражаем $P(z)$:

$$\lambda z P(z)(1 - C(z)) = \mu(1 - z)P(z) - \mu(1 - z)p_0,$$

$$P(z) [\mu(1 - z) - \lambda z(1 - C(z))] = \mu(1 - z)p_0,$$

$$P(z) = \frac{\mu(1 - z)p_0}{\mu(1 - z) - \lambda z(1 - C(z))}.$$

Разделив числитель и знаменатель на $\mu(1 - z)$ и введя функцию $\bar{C}(z) = \frac{1 - C(z)}{1 - z}$, приходим к требуемому соотношению для производящей функции.

Найдем вероятность простоя p_0 , используя условие нормировки $P(1) = 1$. Перейдем к пределу при $z \rightarrow 1$. Значение $\bar{C}(1)$ вычисляется по правилу Лопиталя:

$$\lim_{z \rightarrow 1} \bar{C}(z) = \lim_{z \rightarrow 1} \frac{1 - C(z)}{1 - z} = \lim_{z \rightarrow 1} \frac{-C'(z)}{-1} = C'(1).$$

Поскольку $C'(1) = \sum_{n=1}^{\infty} n c_n = \mathbb{E}[X]$, знаменатель функции $P(z)$ в точке $z = 1$ принимает вид $1 - \frac{\lambda}{\mu} \mathbb{E}[X]$.

Из условия нормировки следует:

$$1 = \frac{p_0}{1 - \frac{\lambda}{\mu} \mathbb{E}[X]} \implies p_0 = 1 - \rho,$$

где $\rho = \frac{\lambda}{\mu} \mathbb{E}[X]$. Для существования стационарного режима необходимо выполнение условия $p_0 > 0$, что эквивалентно $\rho < 1$. ■

Макроскопические характеристики $M^{[X]}|M|1$

При условии $\rho < 1$ стационарный режим существует. Основные метрики эффективности системы определяются соотношениями:

- Среднее число заявок в системе: $L = \frac{\rho + \frac{\lambda}{\mu} \mathbb{E}[X^2]}{2(1 - \rho)}.$

- Среднее время пребывания заявки: $W = \frac{L}{\lambda \mathbb{E}[X]}$.
- Среднее время ожидания: $W_q = W - \frac{1}{\mu}$.
- Среднее число заявок в очереди: $L_q = L - \rho$.

Доказательство. Среднее число заявок L вычисляется как значение первой производной производящей функции в точке 1: $L = P'(1)$. Представим $P(z)$ в виде $P(z) = p_0 \left(1 - \frac{\lambda}{\mu} z \bar{C}(z)\right)^{-1}$ и продифференцируем:

$$P'(z) = p_0 \left(1 - \frac{\lambda}{\mu} z \bar{C}(z)\right)^{-2} \cdot \frac{\lambda}{\mu} (\bar{C}(z) + z \bar{C}'(z)).$$

Для нахождения предела $\bar{C}'(1)$ продифференцируем дробь $\bar{C}(z)$ по правилу дифференцирования частного:

$$\bar{C}'(z) = \frac{-C'(z)(1-z) - (1-C(z))(-1)}{(1-z)^2} = \frac{-C'(z)(1-z) + 1 - C(z)}{(1-z)^2}.$$

При $z \rightarrow 1$ возникает неопределенность $\left[\frac{0}{0}\right]$. Применяем правило Лопиталя:

$$\lim_{z \rightarrow 1} \bar{C}'(z) = \lim_{z \rightarrow 1} \frac{-C''(z)(1-z) - C'(z)(-1) - C'(z)}{-2(1-z)} = \lim_{z \rightarrow 1} \frac{-C''(z)(1-z)}{-2(1-z)} = \frac{1}{2} C''(1).$$

По определению второй факториальный момент равен $C''(1) = \mathbb{E}[X(X-1)] = \mathbb{E}[X^2] - \mathbb{E}[X]$. Подставляя найденные пределы в выражение для $P'(1)$, получаем:

$$L = P'(1) = \frac{p_0}{p_0^2} \cdot \frac{\lambda}{\mu} \left(\mathbb{E}[X] + \frac{1}{2} (\mathbb{E}[X^2] - \mathbb{E}[X]) \right) = \frac{1}{1-\rho} \cdot \frac{\lambda}{2\mu} (\mathbb{E}[X] + \mathbb{E}[X^2]).$$

Учитывая, что $\frac{\lambda}{2\mu} \mathbb{E}[X] = \frac{\rho}{2}$, итоговая формула длины очереди принимает вид:

$$L = \frac{\rho + \frac{\lambda}{\mu} \mathbb{E}[X^2]}{2(1-\rho)}.$$

Остальные метрики выводятся на основе закона Литтла. Поскольку группы заявок поступают с интенсивностью λ , а средний размер одной группы равен $\mathbb{E}[X]$, эффективная интенсивность поступления индивидуальных заявок (общее число единичных заявок, приходящих в систему за единицу времени) определяется произведением:

$$\lambda_{\text{eff}} = \lambda \mathbb{E}[X].$$

Отсюда среднее время пребывания $W = \frac{L}{\lambda_{\text{eff}}}$. Средняя длина очереди $L_q = \lambda_{\text{eff}} W_q = \lambda_{\text{eff}} \left(W - \frac{1}{\mu}\right) = L - \frac{\lambda_{\text{eff}}}{\mu} = L - \rho$.

Пример: Фиксированный размер группы

Рассмотрим систему $M^{[X]}|M|1$, в которой заявки поступают строго пакетами фиксированной длины k ($X = k = \text{const}$). Необходимо вычислить среднее число заявок в системе L .

Решение. Для детерминированной величины $X = k$ начальные моменты равны $\mathbb{E}[X] = k$ и $\mathbb{E}[X^2] = k^2$. Коэффициент загрузки составляет $\rho = \frac{\lambda k}{\mu}$. Подставляя моменты в полученную формулу для макроскопических характеристик, находим:

$$L = \frac{\rho + \frac{\lambda}{\mu} k^2}{2(1 - \rho)} = \frac{\rho + \rho k}{2(1 - \rho)} = \frac{k + 1}{2} \cdot \frac{\rho}{1 - \rho}.$$

Пример: Геометрическое распределение размера группы

Пусть размер группы имеет геометрическое распределение с параметром $\alpha \in (0, 1)$: $\mathbb{P}(X = n) = (1 - \alpha)\alpha^{n-1}$ для $n \in \mathbb{N}$. Требуется определить среднее число заявок в системе L .

Решение. Составим производящую функцию $C(z)$:

$$C(z) = \sum_{n=1}^{\infty} (1 - \alpha)\alpha^{n-1} z^n = \frac{z(1 - \alpha)}{1 - \alpha z}.$$

Вычислим первый момент $\mathbb{E}[X]$:

$$\mathbb{E}[X] = \lim_{z \rightarrow 1} \frac{1 - C(z)}{1 - z} = \lim_{z \rightarrow 1} \frac{1 - \frac{z(1 - \alpha)}{1 - \alpha z}}{1 - z} = \lim_{z \rightarrow 1} \frac{1 - \alpha z - z + \alpha z}{(1 - \alpha z)(1 - z)} = \lim_{z \rightarrow 1} \frac{1 - z}{(1 - \alpha z)(1 - z)} = \frac{1}{1 - \alpha}.$$

Второй начальный момент для смещенного геометрического распределения равен $\mathbb{E}[X^2] = \frac{1 + \alpha}{(1 - \alpha)^2}$. Загрузка системы составит $\rho = \frac{\lambda}{\mu(1 - \alpha)}$. Подставим моменты в общую формулу:

$$L = \frac{\rho + \frac{\lambda}{\mu} \frac{1 + \alpha}{(1 - \alpha)^2}}{2(1 - \rho)}.$$

Так как $\frac{\lambda}{\mu} = \rho(1 - \alpha)$, преобразуем числитель:

$$L = \frac{\rho + \rho(1 - \alpha) \frac{1 + \alpha}{(1 - \alpha)^2}}{2(1 - \rho)} = \frac{\rho \left(1 + \frac{1 + \alpha}{1 - \alpha}\right)}{2(1 - \rho)}.$$

После приведения скобки к общему знаменателю $\left(\frac{1 - \alpha + 1 + \alpha}{1 - \alpha} = \frac{2}{1 - \alpha}\right)$, получаем итоговый результат:

$$L = \frac{\rho \cdot \frac{2}{1 - \alpha}}{2(1 - \rho)} = \frac{1}{1 - \alpha} \cdot \frac{\rho}{1 - \rho}.$$

! Замечание !

В обоих рассмотренных примерах среднее число заявок в системе L принимает вид произведения средней длины очереди классической системы $M|M|1$ (равной $\frac{\rho}{1 - \rho}$) на константный множитель. Общую формулу для L можно переписать в виде:

$$L = \frac{\rho}{1 - \rho} \cdot \frac{\mathbb{E}[X^2] + \mathbb{E}[X]}{2\mathbb{E}[X]}.$$

Данный мультипликативный фактор зависит исключительно от первых двух моментов распределения

размера группы. Это отражает следующее свойство (аналогичное формуле Поллачека-Хинчина): при фиксированной общей загрузке ρ дисперсия размера пакета напрямую увеличивает среднюю длину очереди. Чем больше разброс размера группы по сравнению с одиночным поступлением, тем на большую величину масштабируется базовая метрика системы $M|M|1$.

Глава 8

Лекция 8. Система $M|Er_k|1$. Протоколы множественного доступа

8.1 Системы с фазовым обслуживанием. Модель $M|Er_k|1$

Система $M|Er_k|1$

Одноканальная система массового обслуживания, на вход которой поступает пуассоновский поток заявок с интенсивностью λ . Процесс обслуживания каждой заявки состоит из k последовательных независимых этапов (фаз). Время прохождения каждой фазы распределено по экспоненциальному закону. Суммарное время обслуживания заявки S подчиняется распределению Эрланга k -го порядка ($S \sim Er_k$).

Для обеспечения математического ожидания полного времени обслуживания $\mathbb{E}[S] = \frac{1}{\mu}$, среднее время выполнения одной обособленной фазы должно составлять $\frac{1}{k\mu}$. Следовательно, интенсивность переходов процесса обслуживания между смежными фазами равна $k\mu$.




Рис. 8.1: Структура фазового обслуживания системы $M|Er_k|1$. Состояния марковской цепи сгруппированы в макро-состояния (соответствующие числу заявок в системе), внутри которых протекает последовательное выполнение независимых фаз. Нумерация микро-состояний ведется по суммарному числу оставшихся этапов обслуживания.

Состояние системы в произвольный момент времени описывается двумерным вектором (n, i) , где n — общее число заявок в системе, а $i \in \{1, 2, \dots, k\}$ — номер текущей фазы обслуживаемой заявки.

Для снижения размерности задачи сведем двумерное пространство состояний к одномерному. Введем случайную величину J , равную суммарному числу невыполненных фаз обслуживания для всех заявок, находящихся в системе. При наличии n заявок и обслуживании первой из них на стадии i , искомое значение J задается соотношением:

$$J = (n - 1)k + i, \quad \text{при } n > 0,$$

и $J = 0$ при отсутствии заявок в системе ($n = 0$).

▽ **Утв.** Марковская цепь, описывающая изменение суммарного числа невыполненных фаз J в системе $M|Er_k|1$, стохастически эквивалентна марковской цепи системы с групповым поступлением заявок $M^{[X]}|M|1$, в которой размер группы строго фиксирован и равен k ($X = k = \text{const}$).

Доказательство. Рассмотрим динамику изменения состояния системы, выраженного через переменную $J(t)$. Поступление новой заявки образует пуассоновский поток с интенсивностью λ и мгновенно увеличивает суммарное число невыполненных фаз на k . Данное событие соответствует скачкообразному переходу марковской цепи из состояния j в $j + k$.

В свою очередь, обслуживание заявок представляет собой последовательное выполнение фаз. Завершение обработки каждой отдельной фазы происходит с интенсивностью $k\mu$ и строго уменьшает текущее число оставшихся фаз на единицу (переход $j \rightarrow j - 1$). Таким образом, процесс изменения числа фаз стохастически идентичен процессу изменения числа элементов в системе $M^{[X=k]}|M|1$, где пакеты фиксированного размера k поступают с интенсивностью λ , а элементы пакета обслуживаются поодиночке с интенсивностью $k\mu$. ■




Рис. 8.2: Граф интенсивностей переходов для суммарного числа невыполненных фаз J в системе $M|Er_k|1$. Граф полностью эквивалентен модели $M^{[X=k]}|M|1$ с индивидуальной интенсивностью обслуживания $k\mu$.

Ключевое отличие $M|Er_k|1$ от классической системы с групповым поступлением заключается в физической интерпретации состояний: в $M^{[X=k]}|M|1$ окончание одной стадии обслуживания означает уход заявки из системы, тогда как в $M|Er_k|1$ заявка покидает прибор только после завершения всех k стадий. Данная связь позволяет напрямую вывести временные характеристики системы.

Макроскопические характеристики $M|Er_k|1$

При выполнении условия стационарности $\rho = \frac{\lambda}{\mu} < 1$, метрики эффективности системы определяются следующими соотношениями:

- Среднее время ожидания заявки в очереди: $W_q = \frac{k+1}{2k} \cdot \frac{\rho}{\mu(1-\rho)}$.
- Среднее число заявок в очереди: $L_q = \frac{k+1}{2k} \cdot \frac{\rho^2}{1-\rho}$.

- Среднее время пребывания заявки в системе: $W = W_q + \frac{1}{\mu}$.
- Среднее число заявок в системе: $L = L_q + \rho$.

Доказательство. Вычислим среднее время ожидания заявки в очереди W_q . При использовании дисциплины обслуживания FCFS (First-Come, First-Served) время ожидания вновь прибывшей заявки строго равно суммарному времени, необходимому для завершения всех фаз обслуживания, уже находящихся в системе к моменту ее поступления.

В силу свойства PASTA (Poisson Arrivals See Time Averages), пуассоновский поток заявок заставит систему в стационарном состоянии. Следовательно, математическое ожидание числа невыполненных фаз, наблюдаемое прибывающей заявкой, совпадает со средним числом фаз в произвольный момент времени $\mathbb{E}[J]$.

Для вычисления $\mathbb{E}[J]$ воспользуемся установленной стохастической эквивалентностью с системой $M^{[X]}|M|1$. Подставим параметры эквивалентной модели в формулу для средней длины очереди системы с групповым поступлением:

- Интенсивность входного потока групп: λ .
- Размер группы: $X = k$ (детерминированная величина, $\mathbb{E}[X] = k$, $\mathbb{E}[X^2] = k^2$).
- Интенсивность обслуживания одного элемента (одной фазы): $\mu_{\text{phase}} = k\mu$.
- Коэффициент загрузки по фазам: $\rho_{\text{phase}} = \frac{\lambda \mathbb{E}[X]}{\mu_{\text{phase}}} = \frac{\lambda k}{k\mu} = \rho$.

Среднее число фаз в системе равно:

$$\mathbb{E}[J] = \frac{\rho_{\text{phase}} + \frac{\lambda}{\mu_{\text{phase}}} \mathbb{E}[X^2]}{2(1 - \rho_{\text{phase}})} = \frac{\rho + \frac{\lambda}{k\mu} k^2}{2(1 - \rho)} = \frac{\rho + \rho k}{2(1 - \rho)} = \frac{k + 1}{2} \cdot \frac{\rho}{1 - \rho}.$$

Поскольку среднее время выполнения одной фазы составляет $\frac{1}{k\mu}$, полное время ожидания вычисляется как произведение среднего числа фаз на длительность одной фазы:

$$W_q = \mathbb{E}[J] \cdot \frac{1}{k\mu} = \frac{k + 1}{2} \cdot \frac{\rho}{1 - \rho} \cdot \frac{1}{k\mu} = \frac{k + 1}{2k} \cdot \frac{\rho}{\mu(1 - \rho)}.$$

Дальнейший вывод метрик базируется на фундаментальных законах теории массового обслуживания. Применяя закон Литтла для подсистемы очереди ($L_q = \lambda W_q$), получаем:

$$L_q = \lambda \cdot \frac{k + 1}{2k} \cdot \frac{\rho}{\mu(1 - \rho)} = \frac{k + 1}{2k} \cdot \frac{\rho^2}{1 - \rho}.$$

Среднее время пребывания заявки в системе складывается из времени ожидания и среднего времени обслуживания:

$$W = W_q + \mathbb{E}[S] = W_q + \frac{1}{\mu}.$$

Среднее число заявок в системе в целом определяется по закону Литтла ($L = \lambda W$):

$$L = \lambda \left(W_q + \frac{1}{\mu} \right) = L_q + \rho.$$

! Замечание !

Коэффициент $\frac{k+1}{2k}$ в полученных формулах можно представить в виде $\frac{1}{2} \left(1 + \frac{1}{k} \right)$. Рассмотрим асимптотическое поведение системы:

- При $k = 1$ модель вырождается в классическую $M|M|1$, а множитель обращается в 1.
- При $k \rightarrow \infty$ распределение Эрланга стремится к детерминированной величине (распределение Дирака). Модель переходит в $M|D|1$, а множитель асимптотически стремится к $\frac{1}{2}$.

Данный предел аналитически согласуется со следствиями из формулы Полячека-Хинчина, согласно которым полное устранение стохастичности времени обслуживания приводит к двукратному сокращению длины очереди при фиксированном коэффициенте загрузки.

8.2 Протоколы множественного доступа. Алгоритмы ALOHA

Рассмотрим сетевую архитектуру, использующую два независимых частотных канала: прямую линию связи (Downlink) и обратную линию связи (Uplink). В канале Downlink центральный узел осуществляет широковещательную передачу пакетов. В канале Uplink множество из n независимых терминалов конкурируют за доступ к разделяемой среде передачи.

В классическом протоколе ALOHA терминал инициирует передачу в канал немедленно после генерации пакета, без предварительного контроля состояния среды.

! Замечание !

Отсутствие механизма прослушивания несущей (Carrier Sense) в классической архитектуре ALOHA обусловлено требованием максимальной аппаратной простоты терминалов. На этапе разработки протокола генерируемый трафик имел низкую общую интенсивность, и вероятностью коллизий пренебрегали. Механизмы предварительного контроля состояния канала (семейство CSMA) были формализованы позднее как ответ на рост нагрузки в сетях.

Поскольку передачи узлов независимы, пакеты могут пересекаться во времени. Наложение сигналов называется коллизией, в результате которой информация искажается и не может быть демодулирована. Для обеспечения гарантированной доставки применяется механизм автоматического запроса повторения (ARQ): при успешном приеме центральный узел отправляет кадр подтверждения (ACK). Отсутствие подтверждения диагностируется как коллизия и инициирует повторную передачу пакета через случайный интервал времени.

8.2.1 Асинхронная ALOHA

Определим абсолютную пропускную способность канала S_{abs} как среднее число успешно переданных пакетов в единицу времени. Зафиксируем параметры модели:

- В зоне радиовидимости базовой станции находятся n передатчиков. Мощности принимаемых сигналов идентичны (эффект захвата отсутствует).
- Все генерируемые пакеты имеют строго фиксированную длину. Время передачи одного пакета составляет Δt .
- Суммарный поток пакетов (включая первичные и повторные передачи), генерируемый всеми узлами, является пуассоновским с абсолютной интенсивностью λ [пакетов/с].
- Емкость буфера каждого терминала равна 1. При наличии пакета в буфере новые заявки отбрасываются.
- Канал является идеальным: единственной причиной потери пакета выступает коллизия.

Введем безразмерную величину $G \doteq \lambda \Delta t$, определяющую предложенную нагрузку на канал (среднее число пакетов, поступающих за время Δt). При симметричной нагрузке интенсивность трафика отдельного узла равна $\frac{\lambda}{n}$. Рассмотрим асимптотический режим, при котором $n \rightarrow \infty$, а суммарная интенсивность λ конечна и фиксирована.


▽ **Утв. [Пропускная способность чистой ALOHA при бесконечном числе устройств]** В асимптотическом режиме $n \rightarrow \infty$ нормированная пропускная способность $S = S_{\text{abs}} \Delta t$ асинхронной сети ALOHA определяется выражением:

$$S = G e^{-2G}$$

Глобальный максимум достигается при $G = \frac{1}{2}$ и составляет $S_{\text{max}} = \frac{1}{2e} \approx 0.184$.

Доказательство. Абсолютная пропускная способность выражается через интенсивность входного потока и вероятность отсутствия коллизии: $S_{\text{abs}} = \lambda \cdot \mathbb{P}(\text{успех})$.

Для вычисления вероятности успешной передачи зафиксируем некоторый целевой пакет, инициированный в произвольный момент времени t_0 . Поскольку длительность передачи равна Δt , она завершится в момент $t_0 + \Delta t$. Передача окажется успешной тогда и только тогда, когда ни один другой узел не начнет передачу в интервале $[t_0 - \Delta t, t_0 + \Delta t]$. Длина этого «уязвимого интервала» (vulnerable period) строго равна $\tau = 2\Delta t$.



В силу независимости терминалов, процесс генерации пакетов *остальными* $n - 1$ узлами формирует фоновый пуассоновский поток. При $n \rightarrow \infty$ интенсивность этого фонового потока совпадает с суммарной интенсивностью λ . Фиксированный целевой пакет выступает заданным условием наблюдения, поэтому он исключается из множества случайных событий фонового процесса.

Вероятность успешной передачи совпадает с вероятностью того, что на уязвимом интервале $\tau = 2\Delta t$ наступит ровно ноль событий фонового потока. Применяя формулу Пуассона для $k = 0$ и среднего числа событий $\lambda\tau = \lambda(2\Delta t) = 2G$:

$$\mathbb{P}(\text{успех}) = \mathbb{P}(k = 0) = \frac{(2G)^0}{0!} e^{-2G} = e^{-2G}.$$

Абсолютная пропускная способность составляет $S_{\text{abs}} = \lambda e^{-2G}$. Переходя к нормированной величине $S = S_{\text{abs}}\Delta t$ (числу успешных пакетов за время Δt), получаем итоговую формулу:

$$S = (\lambda\Delta t)e^{-2G} = Ge^{-2G}.$$

Вычислим производную функции $S(G)$ для нахождения точки оптимума:

$$\frac{dS}{dG} = e^{-2G} - 2Ge^{-2G} = e^{-2G}(1 - 2G) = 0 \implies G = \frac{1}{2}.$$

! Замечание !

В дальнейших выкладках стандартной практикой является нормировка оси времени, при которой $\Delta t \equiv 1$. В этом случае понятия абсолютной и приведенной интенсивностей совпадают ($\lambda = G$, $S_{\text{abs}} = S$), а единицей измерения времени становится длительность одного пакета.

8.2.2 Синхронная (слотированная) АЛОНА при бесконечном числе устройств

Основным фактором снижения эффективности чистой АЛОНА является избыточная длина уязвимого интервала ($2\Delta t$). Алгоритм синхронной АЛОНА устраняет частичные наложения пакетов за счет квантования времени.


Ось времени разбивается на равные слоты длительностью Δt . Терминалам разрешается инициировать передачу исключительно на границах слотов. Для координации узлов применяется глобальный синхронизирующий сигнал.

▽ **Утв. [Пропускная способность слотированной АЛОНА]** В асимптотическом режиме $n \rightarrow \infty$ нормированная пропускная способность синхронной сети АЛОНА задается выражением:

$$S = Ge^{-G}$$

Глобальный максимум достигается при $G = 1$ и составляет $S_{\max} = \frac{1}{e} \approx 0.368$.

Доказательство. Пусть передача целевого пакета запланирована в слоте, ограниченном моментами $k\Delta t$ и $(k+1)\Delta t$. Заявки, инициирующие эту передачу, формируются терминалом на предшествующем интервале. Поскольку любые передачи стартуют строго по границам слотов, частичное наложение пакетов невозможно: пакеты либо полностью совпадают во времени, либо не пересекаются вовсе.



Уязвимый интервал для целевой передачи сужается до одного предыдущего слота $[(k-1)\Delta t, k\Delta t]$. Если на этом интервале длительностью $\tau = \Delta t$ ни один конкурирующий узел не сгенерирует заявку, в следующем слоте целевой пакет будет передан успешно.

Математическое ожидание числа событий фонового потока на интервале Δt равно $\lambda\Delta t = G$. Вероят-

ность того, что фоновых событий не произойдет, составляет $\mathbb{P}(k = 0) = e^{-G}$. Следовательно, нормированная пропускная способность равна $S = Ge^{-G}$.

Точка экстремума определяется из уравнения:


$$\frac{dS}{dG} = e^{-G} - Ge^{-G} = e^{-G}(1 - G) = 0 \implies G = 1.$$

! Замечание !

При оптимальной нагрузке ($G = 1$) вероятностное распределение состояний произвольного слота имеет вид:

- Слот пуст (простой канала): $\mathbb{P}(0) = \frac{1^0}{0!}e^{-1} = e^{-1} \approx 0.368$.
- Успешная передача (ровно 1 пакет): $\mathbb{P}(1) = \frac{1^1}{1!}e^{-1} = e^{-1} \approx 0.368$.
- Коллизия ($k \geq 2$ пакетов): $\mathbb{P}(k \geq 2) = 1 - \mathbb{P}(0) - \mathbb{P}(1) = 1 - 2e^{-1} \approx 0.264$.

Данное распределение описывает безусловную статистику состояний канала и вычислено безотносительно к попытке передачи какого-либо выделенного пакета.



8.2.3 Синхронная ALOHA при конечном числе устройств

В предыдущем разделе пропускная способность сети вычислялась в асимптотическом предположении о бесконечном числе терминалов ($n \rightarrow \infty$), генерирующих суммарный пуассоновский поток. Рассмотрим более реалистичную модель слотированной ALOHA с конечным числом узлов.

Утв. [Пропускная способность системы с конечным числом терминалов] Рассмотрим сеть, состоящую из n независимых терминалов. Пусть $G_i \in (0, 1)$ — вероятность начала передачи пакета i -м терминалом в произвольном слоте. Суммарная нагрузка на канал G (математическое ожидание числа попыток передачи в одном слоте) равна $G = \sum_{i=1}^n G_i$.

Индивидуальная пропускная способность S_i (вероятность успешной передачи i -го терминала) и суммарная пропускная способность системы S задаются соотношениями:

$$S_i = \frac{G_i}{1 - G_i} \prod_{\substack{j=1 \\ j \neq i}}^n (1 - G_j), \quad S = \sum_{i=1}^n S_i.$$

Доказательство. Успешная передача пакета i -м терминалом в выделенном слоте происходит тогда и только тогда, когда i -й терминал осуществляет передачу, а все остальные $n - 1$ терминалов «молчат» (не инициируют передачу). В силу независимости работы терминалов вероятность совместного наступления этих событий равна произведению их вероятностей:

$$S_i = G_i \prod_{\substack{j=1 \\ j \neq i}}^n (1 - G_j).$$

Для приведения выражения к симметричному виду относительно произведения по всем j , умножим и разделим правую часть на вероятность отсутствия передачи i -го терминала $(1 - G_i)$:

$$S_i = \frac{G_i}{1 - G_i} \prod_{j=1}^n (1 - G_j).$$

События, заключающиеся в успешной передаче пакета i -м или k -м терминалом в одном и том же слоте, являются несовместными (в противном случае возникает коллизия). Следовательно, суммарная пропускная способность сети вычисляется как сумма индивидуальных пропускных способностей:

$$S = \sum_{i=1}^n S_i = \left(\sum_{i=1}^n \frac{G_i}{1 - G_i} \right) \prod_{j=1}^n (1 - G_j).$$

Следствие. Предположим, что нагрузка распределена между терминалами равномерно. Тогда для любого $i \in \{1, \dots, n\}$ вероятность передачи составляет $G_i = \frac{G}{n}$. Подставим данное значение в формулу суммарной пропускной способности:

$$S = n \cdot S_i = n \frac{\frac{G}{n}}{1 - \frac{G}{n}} \left(1 - \frac{G}{n} \right)^n = \frac{G}{1 - \frac{G}{n}} \left(1 - \frac{G}{n} \right)^n.$$

Устремим число узлов к бесконечности ($n \rightarrow \infty$) при строго фиксированной суммарной нагрузке G . Используя классический предел $\lim_{n \rightarrow \infty} \left(1 - \frac{x}{n} \right)^n = e^{-x}$ и учитывая, что знаменатель $(1 - \frac{G}{n}) \rightarrow 1$, вычисляем предел пропускной способности:

$$\lim_{n \rightarrow \infty} S = G \lim_{n \rightarrow \infty} \left(1 - \frac{G}{n} \right)^n = G e^{-G}.$$

Данный результат совпадает с формулой пропускной способности слотированной АЛОНА с бесконечным числом устройств, полученной ранее на основе гипотезы о пуассоновском характере фонового трафика.

Глава 9

Лекция 9. Древовидные стек-алгоритмы и введение в CSMA

9.1 Стек-алгоритмы

Рассмотрим синхронную систему множественного доступа. Время дискретно и разбито на слоты равной длительности. В конце каждого слота станции получают безошибочную тернарную обратную связь (возможны три исхода: *пусто*, *успех*, *коллизия*).

Стек-алгоритм (алгоритм расщепления дерева)

Пусть в некотором слоте произошла коллизия. Станции, участвующие в ней, образуют корневую вершину дерева коллизий. Цель алгоритма — обойти это дерево и успешно передать все вступившие в коллизию пакеты. Время, затраченное на обход дерева, назовем интервалом разрешения коллизии (англ.: Collision Resolution Interval, CRI).

Каждая станция поддерживает внутренний счетчик задержки r . Работа алгоритма подчиняется следующим правилам:

- Блокировка.** Станции, сгенерировавшие пакеты после начала CRI, устанавливают $r = \infty$ и переходят в режим ожидания. Они получают право на передачу только после полного завершения текущего CRI.
- Передача.** В текущем слоте передают пакет только те станции, у которых $r = 0$. Станции с $r > 0$ ожидают.
- Обновление счетчиков.** По итогам слота станции пересчитывают значения r на основе сигнала обратной связи:
 - Коллизия:* Каждая станция с $r = 0$ равновероятно (с $p = 1/2$) выбирает новое значение $r \in \{0, 1\}$. Ожидающие станции с $r > 0$ увеличивают счетчик: $r \rightarrow r + 1$.
 - Успех или Пусто:* Все станции уменьшают счетчики: $r \rightarrow r - 1$.
- Завершение.** CRI заканчивается, когда система обходит все ветви текущего дерева. После этого заблокированные новые станции сбрасывают $r \rightarrow 0$ и начинают новый цикл передач.

! Замечание 1 !

Возникает вопрос: почему при наличии обратной связи алгоритм не строит прямое расписание передач для устройств? Это невозможно, так как тернарная обратная связь анонимна. Система узнает лишь сам факт конфликта, но не располагает информацией о точном количестве активных станций и их идентификаторах.

! Замечание 2 !

В классической математической модели предполагается, что станция непрерывно слушает канал с момента запуска системы ($t = 0$), независимо от наличия пакетов для передачи. Следовательно, к моменту генерации заявки она обладает полной предысторией эфира. Для отслеживания границ CRI каждая станция локально поддерживает глобальный счетчик открытых ветвей дерева коллизий.

Так, при первой коллизии (в корне дерева) счетчик устанавливается равным двум. Каждая последующая коллизия расщепляет одну ветвь на две, увеличивая счетчик на единицу. Успешная передача или пустой слот закрывают одну ветвь, уменьшая счетчик на единицу. Как только глобальный счетчик достигает нуля, CRI завершается.

! Замечание 3 !


Если в сети появляется абсолютно новая (только что включенная) станция, она сталкивается с проблемой рассинхронизации. Без предыстории она не знает текущего значения счетчика ветвей и в рамках данной модели не способна определить границу CRI по одной лишь анонимной обратной связи. На практике в протоколах множественного доступа этот недостаток можно устранить следующим образом. Головной узел сети должен централизованно отслеживать ход разрешения конфликтов и транслировать в нисходящий канал служебный маркер. Он открыто может сообщать станциям факт завершения CRI, позволяя новым участникам мгновенно синхронизироваться.

! Замечание 4 !

Название «стек-алгоритм» обусловлено тем, что переменная r выполняет роль указателя вершины стека. Станции с $r = 0$ находятся на вершине и имеют право доступа к каналу. При коллизии инкремент $r \rightarrow r + 1$ эквивалентен операции проталкивания в стек (push), а при пустом слоте или успехе декремент $r \rightarrow r - 1$ соответствует выталкиванию из стека (pop).

Пример: Работа алгоритма


Пусть передачу начинают станции $\{1, 2, 3, 4\}$. Построим дерево коллизий, отображающее динамику счетчиков r .



В слоте 1 возникает коллизия. Станции $\{1, 2, 4\}$ выбирают $r = 0$, а станция $\{3\}$ выбирает $r = 1$ (переход в правое поддерево). В слоте 2 станции $\{1, 2, 4\}$ снова сталкиваются, и в результате жеребьевки все они синхронно выбирают $r = 1$.

Следовательно, в слоте 3 станций с $r = 0$ нет, канал пуст. По правилам алгоритма пустой слот вызывает декремент: все станции $\{1, 2, 4\}$ сбрасывают счетчик до $r = 0$. Значит, в слоте 4 они вновь выходят в эфир, образуя детерминированную повторную коллизия.

Выявленная избыточность (пустой слот влечет за собой неизбежную коллизия) позволяет модифицировать алгоритм. Пусть за слотом с коллизией следует пустой слот. Это гарантирует, что все участники предыдущей коллизии перешли в правую ветвь ($r = 1$) и в следующем слоте неминуемо столкнутся вновь. В этом случае алгоритм принудительно эмулирует коллизия: станции с $r = 0$ немедленно осуществляют жеребьевку, а станции с $r > 0$ увеличивают счетчики без фактической потери таймслота на заведомо конфликтную передачу. Сравним временные диаграммы работы базового и оптимизированного алгоритмов для рассмотренного примера.



Стек-алгоритмы обеспечивают разрешение конфликтов за конечное время, однако их применение на практике ограничено жестким требованием к наличию канала безошибочной обратной связи.

! Замечание !

В 1981 году Б.С. Цыбаков и В.А. Михайлов показали, что пропускная способность класса систем синхронного случайного множественного доступа (бесконечное число станций, пуассоновский поток заявок, тернарная обратная связь без прослушивания несущей) строго ограничена сверху значением 0,587. Позднее эта верхняя граница неоднократно уточнялась в сторону уменьшения (вплоть до 0,568). При этом лучшие из известных конструктивных алгоритмов расщепления (например, оптимальный алгоритм Галлагера — Цыбакова — Михайлова) достигают пропускной способности лишь около 0,488.

9.2 Протоколы с прослушиванием несущей (CSMA)

В базовых протоколах случайного доступа (ALOHA, стек-алгоритмы) длительность коллизии или пустого слота равна времени передачи пакета T . Для повышения пропускной способности необходимо сократить это время. С этой целью станции предварительно слушают канал. Этот механизм называют множественным доступом с прослушиванием несущей (англ.: Carrier Sense Multiple Access, CSMA).

Пусть l — максимальное расстояние между узлами сети, а $c \approx 3 \cdot 10^8$ м/с — скорость распространения электромагнитного сигнала. Тогда время распространения сигнала между наиболее удаленными станциями составляет $\tau = l/c$. Для типичной локальной сети протяженностью $l = 100$ м задержка распространения равна $\tau \approx 0.33$ мкс. Время передачи пакета T составляет десятки или сотни микросекунд. Следовательно, выполняется строгое неравенство $\tau \ll T$. Отсюда получаем, что длительность пустых слотов можно существенно сократить, выбрав ее сопоставимой с τ .

! Замечание !


В протоколах семейства CSMA ось времени разбивается на слоты длины a . Величина a ограничена снизу задержкой распространения сигнала.

Пусть станция 1 начинает передачу в момент t_0 . Тогда фронт сигнала достигает наиболее удаленной станции 2 в момент $t_0 + \tau$. Если станция 2 заканчивает прослушивание канала в момент $t_0 + \tau - \varepsilon$ (где $\varepsilon > 0, \varepsilon \ll \tau$), она фиксирует свободную среду и начинает собственную передачу. В результате возникает коллизия. Значит, для надежного обнаружения занятости канала слот должен длиться не менее 2τ .

На практике также учитывают задержку переключения состояний приемопередатчика $t_{hw} \approx 2$ мкс и время оценки состояния канала $t_{sense} \approx 4$ мкс. Заметим, что эти аппаратные величины превышают 2τ на порядок.

Согласно требованию рассматриваемого протокола, две станции могут вступить в коллизию тогда и только тогда, когда они начнут передачу в течение одного слота. Отсюда получаем ограничение на длительность слота a :

$$a > 2\tau + t_{hw} + t_{sense}.$$



Математическая модель системы CSMA

Для аналитического исследования протоколов семейства CSMA вводятся следующие предположения:

- **Бесконечное число станций.** В сети находится бесконечное количество терминалов ($n \rightarrow \infty$), генерирующих суммарный пуассоновский поток новых заявок с интенсивностью λ_0 . Каждый терминал отправляет пакеты редко и имеет в буфере не более одной заявки.
- **Случайная задержка.** При возникновении коллизии станции узнают об этом по отсутствию подтверждения (англ.: acknowledgement, ACK). Мгновенная повторная передача привела бы к новой коллизии, поэтому станции откладывают попытку на случайное время X (например, экспоненциально с некоторым средним $\bar{X}$).
- **Параметры времени.** Длина пакета строго фиксирована и равна T . Среднее время задержки перед повторной передачей $\bar{X}$ многократно превышает длину пакета ($\bar{X} \gg T$), а длина слота мала ($a \ll T$).
- **Суммарный поток.** Трафик в канале состоит из новых и повторно передаваемых пакетов. В силу условия $\bar{X} \gg T$ и того, что повторные передачи откладываются на экспоненциальное время, суммарный поток попыток передачи можно считать пуассоновским процессом с интенсивностью $\lambda \geq \lambda_0$.


Отличие между конкретными методами CSMA заключается в алгоритме действий станции после прослушивания канала.

Ненастойчивый CSMA (Non-persistent CSMA)

Алгоритм минимизирует наложение пакетов за счет безусловного отказа от передачи при занятом канале:

1. Перед передачей станция слушает канал.
2. Если канал свободен, станция передает пакет.
3. Если канал занят, станция откладывает передачу на случайное время (эмулирует коллизию), после чего переходит к шагу 1.
4. Если передача завершается коллизией (отсутствует подтверждение), станция откладывает повтор-


ную передачу на случайное время и возвращается к шагу 1.



1-настойчивый CSMA (1-persistent CSMA)

Алгоритм минимизирует время простоя канала, обеспечивая немедленную передачу после его освобождения:


1. Перед передачей станция слушает канал.
2. Если канал свободен, станция передает пакет с вероятностью 1.
3. Если канал занят, станция непрерывно слушает его до момента освобождения, после чего немедленно передает пакет.
4. Если передача завершается коллизией, станция откладывает повторную передачу на случайное время и возвращается к шагу 1.



p -настойчивый CSMA (p -persistent CSMA)

Алгоритм снижает вероятность коллизии, возникающей в 1-настойчивом CSMA, когда несколько станций одновременно ждут освобождения канала:

1. Перед передачей станция слушает канал.
2. Если канал свободен, станция передает пакет с вероятностью p , а с вероятностью $1 - p$ откладывает передачу на один слот a .
3. Если в следующем слоте канал остается свободным, процесс вероятностного выбора повторяется (возврат к шагу 2).
4. Если в следующем слоте канал оказался занятым (то есть другая станция начала передачу в предыдущем слоте), станция откладывает передачу на случайное время (эмулирует коллизию) и возвращается к шагу 1.
5. Если канал изначально занят, станция ждет его освобождения, после чего переходит к шагу 2.
6. Если отправленный пакет испытывает коллизию в процессе передачи, станция откладывает повторную передачу на случайное время и возвращается к шагу 1.




! Замечание !

Во всех рассмотренных протоколах действует общее правило обработки реальных коллизий: если передача завершилась неудачно (произошло наложение сигналов), станция обязана выждать случайное время перед новой попыткой доступа к среде.

9.2.1 Ненастойчивый протокол CSMA (Non-persistent CSMA)

Эволюция системы представляет собой чередование периодов занятости (англ.: busy period, B) и периодов простоя (англ.: idle period, I). Пара смежных интервалов образует цикл. Внутри периода B между двумя последовательными передачами всегда присутствует минимум один свободный слот длины a . В самом деле, для инициации новой передачи терминал обязан зафиксировать свободное состояние среды.



▽ **Утв. [Пропускная способность ненастойчивого CSMA]** Для сети, использующей протокол ненастойчивого CSMA, зависимость нормированной пропускной способности S от абсолютной интенсивности предложенной нагрузки λ имеет вид:

$$S = \frac{\lambda a T e^{-\lambda a}}{a + T(1 - e^{-\lambda a})},$$

где T — время передачи пакета, a — длительность слота прослушивания.

Доказательство. Пропускная способность равна отношению среднего времени успешной передачи к средней длине цикла:

$$S = \frac{\mathbb{E}[U]}{\mathbb{E}[B] + \mathbb{E}[I]},$$

где $\mathbb{E}[B]$ и $\mathbb{E}[I]$ — математические ожидания длительностей периодов занятости и простоя соответственно, а $\mathbb{E}[U]$ — среднее суммарное время успешных передач за один цикл.

Вычислим математическое ожидание периода простоя $\mathbb{E}[I]$. Период простоя состоит из дискретного числа слотов длины a . Он включает ровно k слотов, если в течение первых $k - 1$ слотов заявки не поступали, а в k -м слоте появилась хотя бы одна заявка. Так как входящий поток пуассоновский с интенсивностью λ , вероятность отсутствия заявок на интервале a равна $e^{-\lambda a}$. Следовательно, число слотов подчиняется геометрическому распределению:

$$\mathbb{P}(I = ka) = (e^{-\lambda a})^{k-1} (1 - e^{-\lambda a}), \quad k \geq 1.$$

Отсюда математическое ожидание длины периода простоя составляет:

$$\mathbb{E}[I] = \frac{a}{1 - e^{-\lambda a}}.$$

Рассмотрим период занятости B . Он представляет собой последовательность тактов передачи (англ.: transmission period, TP). Каждый такт включает непосредственную передачу пакета (длительность T) и обязательный слот прослушивания (длительность a), откуда полная длина такта равна $T + a$. Новый такт иницируется, если в течение слота a в систему поступает пакет. В противном случае начинается период простоя I . Вероятность того, что период занятости состоит из k тактов, равна:

$$\mathbb{P}(B = k(T + a)) = (1 - e^{-\lambda a})^{k-1} e^{-\lambda a}, \quad k \geq 1.$$

Значит, математическое ожидание периода занятости равно:

$$\mathbb{E}[B] = \frac{T + a}{e^{-\lambda a}}.$$

Вычислим $\mathbb{E}[U]$. Среднее число тактов передачи в одном периоде B составляет $\mathbb{E}[B]/(T+a) = 1/e^{-\lambda a}$. Передача завершается успехом тогда и только тогда, когда в предшествующем слоте a поступила ровно одна заявка. Поскольку такт передачи уже состоялся, достоверно известно, что число заявок не равно нулю. Следовательно, вероятность успеха P_{suc} вычисляется как условная вероятность:

$$P_{suc} = \mathbb{P}(\text{поступила 1 заявка} \mid \text{поступило} \geq 1 \text{ заявок}) = \frac{\lambda a e^{-\lambda a}}{1 - e^{-\lambda a}}.$$

Умножая среднее число тактов на вероятность успеха и длительность полезной передачи T , получаем:

$$\mathbb{E}[U] = \frac{1}{e^{-\lambda a}} \cdot \frac{\lambda a e^{-\lambda a}}{1 - e^{-\lambda a}} \cdot T = \frac{\lambda a T}{1 - e^{-\lambda a}}.$$

Подставим найденные величины $\mathbb{E}[I]$, $\mathbb{E}[B]$ и $\mathbb{E}[U]$ в исходную формулу для пропускной способности:

$$S = \frac{\frac{\lambda a T}{1 - e^{-\lambda a}}}{\frac{T+a}{e^{-\lambda a}} + \frac{a}{1 - e^{-\lambda a}}}.$$

Домножим числитель и знаменатель дроби на величину $e^{-\lambda a}(1 - e^{-\lambda a})$. Тогда числитель преобразуется к виду $\lambda a T e^{-\lambda a}$, а знаменатель принимает вид:

$$(T+a)(1 - e^{-\lambda a}) + a e^{-\lambda a} = T + a - T e^{-\lambda a} - a e^{-\lambda a} + a e^{-\lambda a} = T + a - T e^{-\lambda a}.$$

Окончательно получаем требуемое соотношение для S . ■

Следствие. Перейдем к пределу при устремлении длины слота прослушивания к нулю ($a \rightarrow 0$). Разделим числитель и знаменатель полученной дроби на a :


$$S = \frac{\lambda T e^{-\lambda a}}{\frac{T}{a}(1 - e^{-\lambda a}) + 1}.$$

Используя первый замечательный предел для экспоненты $\lim_{a \rightarrow 0} \frac{1 - e^{-\lambda a}}{a} = \lambda$, находим асимптотическую пропускную способность идеализированной системы:

$$\lim_{a \rightarrow 0} S = \frac{\lambda T}{\lambda T + 1} = \frac{G}{G + 1},$$


где $G = \lambda T$ — среднее число заявок, генерируемых за время передачи одного пакета. При неограниченном росте предложенной нагрузки ($G \rightarrow \infty$) предел функции равен 1. Это показывает, что теоретически ненастойчивый CSMA способен обеспечить абсолютную утилизацию канала без потерь на коллизии.

Зависимость пропускной способности от нагрузки (при $T = 1$)



9.2.2 1-настойчивый протокол CSMA (1-persistent CSMA)

Временная диаграмма процесса идентична случаю ненастойчивого CSMA: эволюция системы представляет собой чередование периодов занятости B и периодов простоя I .



▽ **Утв. [Пропускная способность 1-настойчивого CSMA]** Для сети, использующей 1-настойчивый протокол CSMA, зависимость нормированной пропускной способности S от абсолютной интенсивности предложенной нагрузки λ имеет вид:

$$S = \frac{\lambda T e^{-\lambda(T+a)} [T + a - T e^{-\lambda a}]}{(T + a)(1 - e^{-\lambda a}) + a e^{-\lambda(T+a)}},$$

где T — время передачи пакета, a — длительность слота прослушивания.

Доказательство. Аналогично доказательству для ненастойчивого CSMA, пропускная способность вычисляется как отношение среднего времени успешной передачи к средней длине цикла:

$$S = \frac{\mathbb{E}[U]}{\mathbb{E}[B] + \mathbb{E}[I]}.$$

Распределение длины периода простоя I совпадает со случаем ненастойчивого CSMA. Математическое

ожидание равно:

$$\mathbb{E}[I] = \frac{a}{1 - e^{-\lambda a}}.$$

Рассмотрим период занятости B . В 1-настойчивом CSMA заявки, поступившие во время текущей передачи, не откладываются, а ожидают освобождения канала. Следовательно, интервал накопления заявок для инициации следующего такта передачи составляет $T + a$. Вероятность того, что период занятости состоит из k тактов, равна:

$$\mathbb{P}(B = k(T + a)) = \left(1 - e^{-\lambda(T+a)}\right)^{k-1} e^{-\lambda(T+a)}, \quad k \geq 1.$$

Отсюда математическое ожидание периода занятости составляет:

$$\mathbb{E}[B] = \frac{T + a}{e^{-\lambda(T+a)}}.$$

Вычисление математического ожидания времени успешной передачи $\mathbb{E}[U]$ требует разделения первого и последующих тактов внутри периода B . Среднее число тактов равно $N = \mathbb{E}[B]/(T + a) = e^{\lambda(T+a)}$.

Первый такт следует за периодом простоя. Он завершается успехом, если в последнем слоте a поступила ровно одна заявка при условии, что поступила хотя бы одна:

$$P_1 = \frac{\lambda a e^{-\lambda a}}{1 - e^{-\lambda a}}.$$

Последующие такты успешны, если на предшествующем интервале $T + a$ (включающем саму передачу и слот прослушивания) поступила ровно одна заявка при условии, что поступила хотя бы одна:

$$P_{\geq 2} = \frac{\lambda(T + a)e^{-\lambda(T+a)}}{1 - e^{-\lambda(T+a)}}.$$

Суммируя вероятности по всем тактам и умножая на длительность полезной передачи T , получаем:

$$\mathbb{E}[U] = T[P_1 + (N - 1)P_{\geq 2}] = T \left[\frac{\lambda a e^{-\lambda a}}{1 - e^{-\lambda a}} + \left(e^{\lambda(T+a)} - 1\right) \frac{\lambda(T + a)e^{-\lambda(T+a)}}{1 - e^{-\lambda(T+a)}} \right].$$

Так как $(e^{\lambda(T+a)} - 1)e^{-\lambda(T+a)} = 1 - e^{-\lambda(T+a)}$, второе слагаемое в скобках упрощается до $\lambda(T + a)$. Приводя выражение к общему знаменателю, находим:

$$\mathbb{E}[U] = \frac{T\lambda [ae^{-\lambda a} + (T + a)(1 - e^{-\lambda a})]}{1 - e^{-\lambda a}} = \frac{\lambda T [T + a - Te^{-\lambda a}]}{1 - e^{-\lambda a}}.$$

Подставим найденные величины $\mathbb{E}[I]$, $\mathbb{E}[B]$ и $\mathbb{E}[U]$ в исходную формулу для S :

$$S = \frac{\frac{\lambda T [T + a - Te^{-\lambda a}]}{1 - e^{-\lambda a}}}{\frac{T + a}{e^{-\lambda(T+a)}} + \frac{a}{1 - e^{-\lambda a}}}.$$

Домножим числитель и знаменатель дроби на произведение $e^{-\lambda(T+a)}(1 - e^{-\lambda a})$. Тогда числитель принимает вид $\lambda T e^{-\lambda(T+a)}[T + a - Te^{-\lambda a}]$, а знаменатель преобразуется к виду:

$$(T + a)(1 - e^{-\lambda a}) + a e^{-\lambda(T+a)}.$$

Окончательно получаем требуемое соотношение для пропускной способности.

Следствие. Перейдем к пределу при устремлении длины слота прослушивания к нулю ($a \rightarrow 0$). Разделим числитель и знаменатель дроби на a :

$$S = \frac{\lambda T e^{-\lambda(T+a)} \left[\frac{T}{a} (1 - e^{-\lambda a}) + 1 \right]}{\frac{T+a}{a} (1 - e^{-\lambda a}) + e^{-\lambda(T+a)}}.$$

Воспользуемся первым замечательным пределом $\lim_{a \rightarrow 0} \frac{1 - e^{-\lambda a}}{a} = \lambda$. Подставляя этот предел, находим асимптотическую пропускную способность:

$$\lim_{a \rightarrow 0} S = \frac{\lambda T e^{-\lambda T} (\lambda T + 1)}{T \lambda + e^{-\lambda T}}.$$

В терминах безразмерной предложенной нагрузки $G = \lambda T$ предельная формула принимает классический вид:


$$\lim_{a \rightarrow 0} S = \frac{G e^{-G} (1 + G)}{G + e^{-G}}.$$

Для нахождения теоретического максимума продифференцируем полученную функцию по G и приравняем производную к нулю. Это приводит к трансцендентному уравнению:

$$G^3 e^G - 2G - 1 = 0.$$

Численное решение данного уравнения дает точку экстремума $G \approx 1.019$. Подстановка этого значения показывает, что абсолютный теоретический максимум пропускной способности 1-настойчивого CSMA составляет $S_{\max} \approx 0.538$. В отличие от ненастойчивого протокола, система не способна достичь полной утилизации канала из-за неизбежных коллизий: если во время текущей передачи заявки генерируют сразу несколько станций, по ее окончании они гарантированно выйдут в эфир одновременно.

Зависимость пропускной способности от нагрузки (при $T = 1$)



9.3 Анализ протоколов CSMA при разной топологии сети

Рассмотрим несколько сценариев множественного доступа с различными топологическими особенностями сети. Пусть система состоит из четырех узлов, где узлы 2 и 3 выступают активными передатчиками, а узлы 1 и 4 — получателями. Передача данных осуществляется строго по направлениям $2 \rightarrow 1$ и $3 \rightarrow 4$.

Узлы 1 и 4 находятся на краях сети: узел 1 слышит только узел 2, узел 4 слышит только узел 3. Взаимодействие центральных узлов 2 и 3 порождает два класса топологий:

- **Симметричная топология:** Узлы 2 и 3 находятся в зоне радиовидимости друг друга.
- **Асимметричная топология:** Узел 2 слышит передачу узла 3, однако узел 3 не слышит передачу узла 2.


Успешный прием пакета данных (длительности T) требует отправки кадра подтверждения (англ.: acknowledgement, АСК) длительности T_{ack} . Время распространения сигнала мало и включено в длительность базового слота прослушивания a . Длительность кадра подтверждения будем считать кратной длительности слота: $T_{ack} = k \cdot a$.

Пример: Анализ протоколов CSMA при различных топологиях сети


В зависимости от применяемого алгоритма доступа и топологии выделяют шесть базовых конфигураций:

1. Ненастойчивый CSMA, асимметричный случай.
2. Ненастойчивый CSMA, симметричный случай.
3. 1-настойчивый CSMA, асимметричный случай.
4. 1-настойчивый CSMA, симметричный случай.
5. p -настойчивый CSMA, асимметричный случай.
6. p -настойчивый CSMA, симметричный случай.

Симметричный случай



Асимметричный случай



Проанализируем детально **Случай 5** (p -настойчивый CSMA, асимметричный случай) с учетом передачи кадров АСК. Требуется определить пропускные способности $S_{2 \rightarrow 1}$ и $S_{3 \rightarrow 4}$, а также условия возникновения коллизий.

Решение. Проведем последовательный анализ каждой конфигурации.

1. **Случай 1:** Ненастойчивый CSMA, асимметричный случай.

[Оставлено для заполнения].

2. **Случай 2:** Ненастойчивый CSMA, симметричный случай.

[Оставлено для заполнения].

3. **Случай 3:** 1-настойчивый CSMA, асимметричный случай.

[Оставлено для заполнения].

4. **Случай 4:** 1-настойчивый CSMA, симметричный случай. [Оставлено для заполнения].


5. **Случай 5:** p -настойчивый CSMA, асимметричный случай.

Рассмотрим узел 3. Он не слышит передачи узла 2. Следовательно, состояние канала для него полностью определяется собственными передачами и сигналами от узла 4. Передачи узла 2 не создают интерференции на узле 4. Значит, передача $3 \rightarrow 4$ протекает в условиях отсутствия конкуренции. Узел 3 функционирует как единственная станция в системе с p -настойчивым CSMA. Отсюда получаем, что пропускная способность канала $3 \rightarrow 4$ достигает теоретического максимума при высокой нагрузке и $p = 1$: $S_{3 \rightarrow 4} \rightarrow 1$.

Рассмотрим передачу $2 \rightarrow 1$. Узел 2 слышит передачу узла 3. Согласно алгоритму CSMA, если узел 3 передает пакет, узел 2 фиксирует занятость несущей и переходит в режим ожидания. Как только узел 3 завершает передачу данных, наступает интервал a . После этого узел 4 начинает передачу АСК. Поскольку узел 2 не слышит узел 4, эфир для узла 2 становится свободным ровно в момент окончания данных от узла 3.

Момент завершения ожидания слота для узла 2 определяется моментом завершения передачи узла 3 (с точностью до аппаратной погрешности $\varepsilon \ll a$). Узел 2 с вероятностью p начинает передачу пакета данных в освободившийся канал.

Проанализируем условия успешной доставки пакета $2 \rightarrow 1$. Пакет данных от узла 2 доходит до узла 1 без искажений. Далее узел 1 формирует кадр АСК. Коллизия возникает исключительно на приемной стороне узла 2, если в момент приема кадра АСК от узла 1 узел 3 возобновляет передачу собственных данных.



Пусть t_0 — момент завершения передачи данных узлом 3. Узел 2 начинает передачу в момент $t_0 + j \cdot a$, где $j \geq 0$ — число слотов отсрочки. Передача данных узла 2 завершается в момент $t_0 + j \cdot a + T$. Ожидаемый кадр АСК от узла 1 занимает интервал $[t_0 + j \cdot a + T + a, t_0 + j \cdot a + T + a + T_{ack}]$.

Узел 3 освобождает канал и готов к новой передаче в момент $t_0 + a + T_{ack}$. Так как $T \gg T_{ack}$, узел 3 завершает обработку цикла значительно раньше, чем узел 2 закончит передачу. Следовательно, при высокой интенсивности λ_3 узел 3 начнет новую передачу на интервале, перекрывающемся с ожиданием кадра АСК узлом 2. Для успешной передачи $2 \rightarrow 1$ необходимо, чтобы узел 3 сохранял молчание на интервале длиной T плюс время на получение АСК. Вероятность такого события

стремится к нулю при $\lambda_3 \rightarrow \infty$. Значит, $S_{2 \rightarrow 1} \rightarrow 0$. Это классическая проблема скрытой станции (англ.: hidden terminal problem).

Рассмотрим специфический случай удачной синхронизации. Допустим, узлы 2 и 3 начинают передачу одновременно в одном слоте. Поскольку длины пакетов равны (T), передачи завершаются синхронно. Спустя интервал a узлы 1 и 4 одновременно отправляют кадры АСК. В этот момент узлы 2 и 3 переходят в режим приема. Так как узел 2 слышит узлы 1 и 3 (узел 3 молчит), а узел 3 слышит узлы 2 и 4 (узел 2 молчит), взаимная интерференция отсутствует. Оба кадра АСК успешно достигают адресатов. Таким образом, полная деградация пропускной способности зависимого канала наступает только при рассинхронизации стартов передач.

6. Случай 6: p -настойчивый CSMA, симметричный случай.

[Оставлено для заполнения].

9.4 Анализ средней задержки передачи

Для оценки производительности протоколов множественного доступа, помимо пропускной способности, критически важной характеристикой является средняя задержка передачи D — интервал времени от момента генерации пакета терминалом до его успешной доставки адресату.

Для построения аналитической модели введем следующие предположения. Успешный прием пакета сопровождается отправкой подтверждения (англ.: acknowledgement, АСК). Время обработки данных на приемной и передающей сторонах пренебрежимо мало. При отсутствии подтверждения (вследствие коллизии) терминал планирует повторную передачу через случайное время X . В соответствии с ранее принятым допущением о том, что суммарный трафик первичных и повторных пакетов образует пуассоновский поток, вероятность успеха любой попытки передачи одинакова и равна:

$$P_{suc} = \frac{S}{G},$$

где S — пропускная способность, G — предложенная нагрузка.

Утв. [Средняя задержка в системах АЛОНА] В сетях, использующих протоколы семейства АЛОНА без предварительного прослушивания несущей, среднее время доставки пакета вычисляется по формуле:

$$D = \left(\frac{G}{S} - 1 \right) R + T + \tau,$$

где $R = T + 2\tau + T_{ack} + \mathbb{E}[X]$ — среднее время, затрачиваемое на одну неудачную попытку передачи, T — длительность передачи пакета, T_{ack} — длительность передачи подтверждения, τ — максимальное время распространения сигнала в среде.

Доказательство. Вероятность того, что пакет будет успешно доставлен ровно с k -й попытки, подчиняется геометрическому распределению:

$$\mathbb{P}(k) = (1 - P_{suc})^{k-1} P_{suc}.$$

Математическое ожидание общего числа попыток передачи для одного пакета составляет:

$$\mathbb{E}[K] = \sum_{k=1}^{\infty} k(1 - P_{suc})^{k-1} P_{suc} = \frac{1}{P_{suc}} = \frac{G}{S}.$$

Значит, среднее число неудачных попыток (коллизий), предшествующих успешной передаче, равно $\frac{G}{S} - 1$.

Каждая неудачная попытка занимает интервал времени R , который складывается из следующих компонент:

- T — время непосредственной передачи пакета в канал;
- τ — задержка распространения сигнала от источника до приемника;
- T_{ack} — время передачи служебного пакета подтверждения;
- τ — задержка распространения подтверждения обратно к источнику.

Следовательно, таймер ожидания передачи подтверждения установлен на величину $T + 2\tau + T_{ack}$. Если по истечении этого времени источник не получает подтверждение, он фиксирует факт коллизии и ожидает в среднем время $\mathbb{E}[X]$ до инициации следующей попытки. Отсюда полная длительность цикла неудачной передачи равна $R = T + 2\tau + T_{ack} + \mathbb{E}[X]$.

Для последней (успешной) попытки пакет считается доставленным в момент завершения его полного приема адресатом, то есть через время $T + \tau$ после начала передачи. Суммируя временные затраты на все неудачные и одну успешную попытки, получаем итоговое выражение для D . ■

! Замечание !

В протоколах с прослушиванием несущей (CSMA) приведенный расчет задержки требует существенной модификации. Поскольку терминалы не осуществляют передачу немедленно, а предварительно анализируют состояние среды, к интервалу R добавляется время вынужденного ожидания освобождения канала. Структура этого ожидания нетривиальна и жестко детерминирована конкретной дисциплиной доступа (например, ненастойчивый или p -настойчивый алгоритмы), а также текущей загрузкой сети.

Глава 10

Лекция 10. Новый взгляд на цепи Маркова: полугруппы и генераторы

10.1 Полугруппы операторов и инфинитезимальные генераторы

Ранее мы установили, что стационарное распределение π эргодической цепи Маркова удовлетворяет векторному уравнению $Q^T \pi = 0$, что эквивалентно инвариантности $\pi^T P(t) = \pi^T$ для любого $t \geq 0$. При этом матрица переходных вероятностей удовлетворяет полугрупповому свойству: $P(s+t) = P(s)P(t)$. Для дальнейшего анализа формализуем это наблюдение в терминах функционального анализа.

Полугруппа операторов

Пусть X — банахово (линейное нормированное полное) пространство. Семейство ограниченных линейных операторов $\{P_t\}_{t \geq 0}$, действующих из X в X , называется **полугруппой**, если выполнены следующие условия:

1. $P_{t+s} = P_t P_s$ для любых $s, t \geq 0$;
2. $P_0 = I$, где I — тождественный оператор.

Обратимость операторов P_t при этом не требуется.

Непрерывность полугруппы

Полугруппа $\{P_t\}_{t \geq 0}$ называется **сильно непрерывной**, если для любого элемента $\varphi \in X$ выполнено условие:

$$\lim_{h \rightarrow +0} \|P_h \varphi - \varphi\|_X = 0.$$

Если сходимость выполняется по операторной норме в пространстве ограниченных операторов $\mathcal{B}(X)$, то есть $\lim_{h \rightarrow +0} \|P_h - I\|_{\mathcal{B}(X)} = 0$, то полугруппа называется **равномерно непрерывной**.

Инфинитезимальный генератор

Линейный оператор G , определяемый пределом

$$G\varphi = \lim_{h \rightarrow +0} \frac{P_h \varphi - \varphi}{h},$$

называется **генератором** полугруппы $\{P_t\}_{t \geq 0}$. Его областью определения является множество всех $\varphi \in X$, для которых указанный предел существует по норме пространства X .

▽ **Утв.** Для равномерно непрерывной полугруппы генератор G является ограниченным оператором, а сама полугруппа однозначно восстанавливается в виде экспоненциального ряда:

$$P_t = e^{Gt}.$$

! Замечание !

Инфинитезимальный генератор тесно связан с абстрактной задачей Коши. Для дифференциального уравнения

$$\begin{cases} \frac{d}{dt}u(t) = Gu(t), \\ u(0) = \varphi, \end{cases}$$

где $u: [0, +\infty) \rightarrow X$, решение задается прямым действием полугруппы на начальное условие: $u(t) = P_t\varphi$.

Применим изложенный аппарат к марковским цепям. Пусть S — не более чем счетное множество состояний марковской цепи $X(t)$, а $f: S \rightarrow \mathbb{R}$ — ограниченная функция состояний. Вычислим математическое ожидание $\mathbb{E}_{\vec{\alpha}}f(X(t))$ при заданном начальном распределении $\vec{\alpha} = (\alpha^{(1)}, \alpha^{(2)}, \dots)^T$:

$$\begin{aligned} \mathbb{E}_{\vec{\alpha}}f(X(t)) &= \sum_{j \in S} \mathbb{P}(X(t) = j)f(j) \\ &= \sum_{j \in S} \left(\sum_{i \in S} \mathbb{P}(X(t) = j \mid X(0) = i) \mathbb{P}(X(0) = i) \right) f(j) \\ &= \sum_{i \in S} \alpha^{(i)} \left(\sum_{j \in S} p_{ij}(t) f(j) \right). \end{aligned}$$

Вводя вектор-столбец $\vec{f} = (f^{(1)}, f^{(2)}, \dots)^T \doteq (f(1), f(2), \dots)^T$ и вектор-столбец начального распределения $\vec{\alpha}$, перепишем результат через скалярное произведение:

$$\mathbb{E}_{\vec{\alpha}}f(X(t)) = \langle \vec{\alpha}, P(t)\vec{f} \rangle.$$

Из прямого уравнения Колмогорова известно, что $\frac{d}{dt}P(t) = P(t)Q$. Интегрируя это матричное уравнение на отрезке $[0, t]$, получаем:

$$P(t) = I + \int_0^t P(s)Q \, ds.$$

Подставим полученное интегральное представление в выражение для математического ожидания:

$$\begin{aligned} \langle \vec{\alpha}, P(t)\vec{f} \rangle &= \left\langle \vec{\alpha}, \left(I + \int_0^t P(s)Q \, ds \right) \vec{f} \right\rangle \\ &= \langle \vec{\alpha}, \vec{f} \rangle + \int_0^t \langle \vec{\alpha}, P(s)(Q\vec{f}) \rangle \, ds. \end{aligned}$$

Заметим, что скалярное произведение $\langle \vec{\alpha}, \vec{f} \rangle$ совпадает с $\mathbb{E}_{\vec{\alpha}}f(X(0))$. Для интерпретации подынтегрального слагаемого рассмотрим вектор-столбец $Q\vec{f}$ как дискретное представление некоторой новой функции $Qf: S \rightarrow \mathbb{R}$,

действующей на пространстве состояний:

$$(Qf)(i) = \sum_{j \in S} Q_{ij} f(j).$$

При такой записи выражение $\langle \vec{\alpha}, P(s)(Q\vec{f}) \rangle$ приобретает смысл математического ожидания функции Qf в момент времени s , то есть равно $\mathbb{E}_{\vec{\alpha}}[(Qf)(X(s))]$. Объединяя эти соотношения, приходим к следующему результату.

Формула Дынкина

Для любой ограниченной функции f и начального распределения $\vec{\alpha}$ справедливо соотношение:

$$\mathbb{E}_{\vec{\alpha}} f(X(t)) = \mathbb{E}_{\vec{\alpha}} f(X(0)) + \int_0^t \mathbb{E}_{\vec{\alpha}} [(Qf)(X(s))] ds,$$

где Qf — скалярная функция на пространстве состояний, полученная действием генератора Q на исходную функцию f .

Пример: Выражение для матрицы Q

Покажем, что инфинитезимальная матрица Q действительно выступает в роли генератора полугруппы.

Решение. Пусть $\vec{\alpha} = \vec{e}_i$, где $\vec{e}_i$ — i -й базисный вектор. Это соответствует детерминированному начальному состоянию $X(0) = i$, откуда $\mathbb{E}_{\vec{e}_i} f(X(t)) = \vec{e}_i^T P(t) \vec{f}$. Вычислим действие оператора Q на функцию f в точке i :

$$\begin{aligned} (Qf)(i) &= \vec{e}_i^T (Q\vec{f}) = \vec{e}_i^T (P'(0)\vec{f}) \\ &= \vec{e}_i^T \lim_{h \rightarrow +0} \frac{P(h)\vec{f} - P(0)\vec{f}}{h} \\ &= \lim_{h \rightarrow +0} \frac{\vec{e}_i^T P(h)\vec{f} - \vec{e}_i^T P(0)\vec{f}}{h} \\ &= \lim_{h \rightarrow +0} \frac{\mathbb{E}_{\vec{e}_i} f(X(h)) - f(i)}{h}. \end{aligned}$$

В качестве частного случая подставим в полученный предел индикаторную функцию фиксированного состояния $j \in S$: $f(s) = I_{\{s=j\}}$. Тогда $f(i) = \delta_{ij}$ (символ Кронекера), $\vec{f} = \vec{e}_j$, а $\mathbb{E}_{\vec{e}_i} f(X(h)) = \vec{e}_i^T P(t) \vec{f} = \vec{e}_i^T P(t) \vec{e}_j = p_{ij} = \mathbb{P}(X(h) = j \mid X(0) = i)$.

В зависимости от совпадения индексов i и j получаем два тождества:

- При $i \neq j$:

$$Q_{ij} = \lim_{h \rightarrow +0} \frac{\mathbb{P}(X(h) = j \mid X(0) = i)}{h} = q_{ij}.$$

- При $i = j$:

$$Q_{ii} = \lim_{h \rightarrow +0} \frac{\mathbb{P}(X(h) = i \mid X(0) = i) - 1}{h} = -q_i.$$

Полученные выражения в точности совпадают с классическими определениями интенсивностей переходов цепи Маркова непрерывного времени.

Пример: Вычисление математического ожидания процесса

Рассмотрим марковский процесс $X(t)$, описывающий число заявок в системе в момент времени t . Пусть поступление новых заявок образует пуассоновский поток с интенсивностью $\lambda > 0$, а интенсивность обработки пропорциональна текущему числу заявок и составляет $\mu X(t)$. Требуется найти математическое ожидание $m(t) = \mathbb{E}X(t)$ при заданном начальном состоянии $X(0) = s_0$.

Решение. Найдем действие инфинитезимального генератора Q на произвольную ограниченную функцию $f: S \rightarrow \mathbb{R}$. Вычислим математическое ожидание $\mathbb{E}_{\vec{e}_i} f(X(h))$, раскладывая вероятности переходов за малое время h с точностью до $o(h)$:

$$\begin{aligned} (Qf)(i) &= \lim_{h \rightarrow +0} \frac{\mathbb{E}_{\vec{e}_i} f(X(h)) - f(i)}{h} \\ &= \lim_{h \rightarrow +0} \frac{1}{h} \left[f(i+1)\mathbb{P}(X(h) = i+1 \mid X(0) = i) + f(i-1)\mathbb{P}(X(h) = i-1 \mid X(0) = i) \right. \\ &\quad \left. + f(i)\mathbb{P}(X(h) = i \mid X(0) = i) - f(i) + o(h) \right] \\ &= \lim_{h \rightarrow +0} \frac{1}{h} \left[f(i+1)\lambda h + f(i-1)\mu i h + f(i)(1 - \mu i h - \lambda h) - f(i) + o(h) \right]. \end{aligned}$$

Сокращая на h и переходя к пределу, получаем выражение для генератора:

$$(Qf)(i) = \lambda(f(i+1) - f(i)) + \mu i(f(i-1) - f(i)).$$

Применим формулу Дынкина к функции $f(s) = s$. Подставляя эту функцию в найденное выражение, находим значение (Qf) в произвольном случайном состоянии $X(s)$:

$$(Qf)(X(s)) = \lambda(X(s) + 1 - X(s)) + \mu X(s)(X(s) - 1 - X(s)) = \lambda - \mu X(s).$$

Тогда по формуле Дынкина для математического ожидания получаем интегральное уравнение:

$$\begin{aligned} \mathbb{E}f(X(t)) &= \mathbb{E}X(0) + \int_0^t \mathbb{E}[(Qf)(X(s))] ds \\ m(t) &= s_0 + \int_0^t \mathbb{E}[\lambda - \mu X(s)] ds \\ &= s_0 + \int_0^t (\lambda - \mu m(s)) ds. \end{aligned}$$


Дифференцируя обе части по t , переходим к классической задаче Коши для линейного дифференциального уравнения первого порядка:

$$\begin{cases} m'(t) = \lambda - \mu m(t), \\ m(0) = s_0. \end{cases}$$

Решая это дифференциальное уравнение, окончательно находим математическое ожидание числа заявок в системе:

$$m(t) = s_0 e^{-\mu t} + \frac{\lambda}{\mu} (1 - e^{-\mu t}).$$

Проиллюстрируем характер сходимости переходного процесса к стационарному режиму. Положим интенсивность обслуживания $\mu = 1$, тогда отношение λ/μ совпадает с параметром нагрузки $\rho = \lambda$. Динамика математического ожидания $m(t)$ для различных начальных состояний $s \in \{0, 2, 5, 10\}$ и варьируемой нагрузки ρ приведена на графиках ниже.



! Замечание 1 !

При $t \rightarrow \infty$ математическое ожидание числа заявок стремится к величине λ/μ , не зависящей от начального состояния s_0 . Рассмотренный марковский процесс строго соответствует модели системы массового обслуживания $M/M/\infty$ с параметрами λ и μ , поскольку суммарная интенсивность обслуживания кратна числу заявок в системе. Найденный асимптотический предел в точности совпадает со средним числом заявок в стационарном режиме работы такой системы.

Обратим внимание, что в классической теории массового обслуживания (по нотации Кендалла) система $M/M/\infty$ описывает математическую модель с бесконечным числом обслуживающих приборов. При этом не важно, конечна или бесконечна очередь. Поскольку число серверов ничем не ограничено, любая

поступающая в систему заявка немедленно занимает свободный прибор и начинает обрабатываться.

Классическим физическим примером такой модели выступает идеализированная система самообслуживания или автостоянка с бесконечным числом мест.

— ! Замечание 2 ! —

Аппарат полугрупп операторов и вытекающая из него формула Дынкина позволяют анализировать переходные процессы в системе. Ранее использованные методы, основанные на решении алгебраического уравнения $Q^T \pi = 0$, давали исключительно стационарные (предельные) характеристики. Новый подход дает явные зависимости моментов распределения от времени.